申请代码	F0215
接收部门	
收件日期	
接收编号	6247072975



国家自然科学基金

申 请 书

（2 0 2 4 版）

NSFC 2024

资助类别：面上项目

亚类说明：

附注说明：

项目名称：面向主动健康的高性能人体运动感知与理解技术

申 请 人：金磊　　BRID：08091.00.28908

办公电话：18810464495

依托单位：北京邮电大学

通讯地址：北京市海淀区西土城路10号北京邮电大学

邮政编码：100876　　单位电话：62282612

电子邮箱：jinlei@bupt.edu.cn

国家自然科学基金委员会

基本信息

申请人信息	姓　　名	金磊	性别	男	出生年月	1994年03月	民族	汉族
	学　　位	博士	职称	副研究员				
	是否在站博士后	否		电子邮箱	jinlei@bupt.edu.cn			
	办公电话	18810464495		国别或地区	中国			
	申请人类别	依托单位全职						
	工　作　单　位	北京邮电大学/电子工程学院						
	主 要 研 究 领 域	机器视觉，多媒体分析，人工智能及其应用						

依托单位信息	名　　称	北京邮电大学		
	联　系　人	江海涛	电子邮箱	jianghaitao@bupt.edu.cn
	电　　话	62282612	网站地址	www.bupt.edu.cn

合作研究单位信息	单 位 名 称
	清华大学 || 华南师范大学

项目基本信息	项目名称	面向主动健康的高性能人体运动感知与理解技术		
	英文名称	High-Performance Human Motion Perception and Understanding Technology for Active Health		
	资助类别	面上项目	亚类说明	
	附注说明			
	申请代码	F0215.计算机与其他领域交叉	F0210.计算机图像视频处理与多媒体技术	
	研究期限	2025年01月01日 -- 2028年12月31日	研究方向：计算机与其他学科的交叉	
	申请直接费用	56.5000万元		
	研究属性	目标导向类基础研究		

中文关键词	关键技术；主动健康；人工智能；机器视觉；人体运动感知与理解
英文关键词	Key Technology; Active Health; Artificial Intelligence; Machine Vision; Human Motion Perception and Understanding

NSFC 2024

中文摘要	后疫情时代国民健康意识明显提高，而疫情带来的后遗症影响仍在持续，主动健康所提倡的“健康关口前移”、“防未病”的思想正符合当前人民健康发展需求。然而，传统的公共健康管理方式难以满足便捷化、协同化、定制化、精准化、智能化的发展目标。针对此问题，本项目面向主动健康与人工智能相结合的应用场景，以突破高性能人体运动感知与理解技术为牵引，搭建一个面向主动健康应用的智能服务系统，为提升国民体质健康水平提供新模式。本项目重点研究无约束场景下有先验人体运动分析、主动交互行为引导的开集人体解析、面向多级任务的标准化人体行为理解、基于体适能分析的运动处方定制，并与生成式模型、多任务联合优化等技术有机结合，应对智能主动健康场景中运动感知模型性能要求高、运动理解内容复杂任务难、个体间体质及需求差异大的挑战。此外，无约束场景下人体感知与理解问题的研究与应用可以为区域安防、智能生产、自动驾驶等相关领域提供参考。
英文摘要	In the Post-COVID-19 era, the national health awareness has been significantly improved, while the sequelae brought by the epidemic are still ongoing. The ideas of "moving the health gateway forward" and "preventing disease before it occurs" advocated by active health are in line with the current needs of people's health development. However, the traditional public health management methods are difficult to meet the development goals of convenience, collaboration, customization, precision and intelligence. In view of this problem, this program is oriented to the application scenario for the combination of active health and artificial intelligence. It strives for breakthroughs in high-performance human motion perception and understanding technology to build an intelligent service system for active health applications, providing a new pattern for improving the overall physical fitness and health level of the population. This program focuses on the study of prior human motion analysis in unconstrained scenarios, active interactive behavior-guided open-world human parsing, standardized human activity understanding for multiple tasks, and exercise prescription customization based on physical fitness analysis. In addition, it organically combines with generative model, multi-task joint optimization and other technologies to address the challenges of high performance requirements for motion perception model, difficult tasks for motion understanding with complex content, and large differences in physical fitness and needs between individuals in intelligent active health scenarios. Moreover, the research and application of human motion perception and understanding in unconstrained scenarios can provide reference for regional security, intelligent production, autonomous driving and other related fields.

NSFC 2024

主要参与者（注：主要参与者不包括项目申请人）

编号	姓名	出生年月	性别	职 称	学 位	工作单位	项目分工	办公电话	证件号码
1	赵昊	1991-10-08	男	助理研究员	博士	清华大学	算法设计及系统开发	82151160	3**********5
2	杨园	1990-08-01	女	研究员	博士	华南师范大学	运动处方及标准制定		4**********3
3	王广进	1973-10-15	男	副教授	博士	华南师范大学	动作标准制定		4**********7

总人数统计（注：包括项目申请人、主要参与者及其他参与人员；勿重复计数）

总人数	高级职称	中级职称	初级职称	博士后	博士生	硕士生	本科生及其他学生	其他
19	3	1			3	8	4	

NSFC 2024

国家自然科学基金项目资金预算表

项目申请号：6247072975　　项目负责人：金磊　　金额单位：万元

序号	科目名称	金额
1	一、项目直接费用合计	56.5000
2	1、 设备费	13.0000
3	其中：设备购置费	9.0000
4	2、 业务费	24.7000
5	3、 劳务费	18.8000
6	二、 其他来源资金	0.0000
7	三、 合计	56.5000

注：请按照项目研究实际需要合理填写各科目预算金额。

NSFC 2024

预算说明书

（请按照《国家自然科学基金项目申请书预算表编制说明》等的有关要求，按照政策相符性、目标相关性和经济合理性原则，实事求是编制项目预算。填报时，直接费用应按设备费、业务费、劳务费三个类别填报，每个类别结合科研任务按支出用途进行说明。对单价≥50万元的设备详细说明,对单价＜50万元的设备费用分类说明，**对合作研究单位资质及资金外拨情况、自筹资金进行必要说明。**）

本项目拟申请直接经费 **56.50 万元**，合作单位无外拨经费，直接经费具体明细说明如下：

1、设备费：共13.00万元

项目组需要到外地进行系统试点，目前项目组还不具备轻量级易部署的工作站，因此在已有硬件条件外，需再购置 1 台高性能工作站，此外，还需要进行人体运动数据的采集、处理与存储，计划购置 4 台专用数据处理终端，参考价格为京东商城询价。

（1）专用数据处理终端：用于项目中数据处理计算和存储。参考型号戴尔（DELL）OptiPlex7010MT 终端，1T+128G 固态硬盘，主机+E2417H 24 英寸显示器。参考单价 0.80 万元，数量 4 台，共计 3.20 万元。

（2）高性能工作站：用于系统试点验证。参考型号戴尔（DELL）R750XS 机架式服务器主机，CPU 可扩展处理器（支持 2 颗 CPU，H330-RAID 卡/DVD/1100W*1 个电源/GPU 运算卡套件含风扇和 2 条供电线/2*英伟达 3090TI 显卡 11G）。参考单价 5.80 万元，数量 1 台，共计 5.80 万元。

项目研究过程中需要租赁云服务器对算法及模型进行训练和测试，并需要对必要服务进行部署，主要包括：

（3）高性能 GPU 云服务器：用于算法测试及模型运行，参考型号：阿里云轻量级 GPU 实例 1*NVIDIA V100 32G，参考价格 0.5 万/台/月，数量 5 台/月，共计 2.50 万元。

（4）高性能 CPU 云服务器：用于应用服务的测试及部署，参考型号：阿里云通用型 g64vCPU，16G，参考价格 0.3 万/台/月，数量 5 台/月，共计 1.50 万元。

以上费用合计：3.20 万元+5.80 万元+2.50 万元+1.50 万元=13.00 万元。

2、业务费：共24.70万元

（1）材料费：共1.38万元

项目研究所需的材料费和低值易耗材料费等支出，主要用于课题研究过程中搭建实验环境进行数据采集和处理的各种电子元器件以及其它相应耗材等费用。包括：

1）测试摄像头：用于项目图像数据采集。参考单价 0.05 万元，数量 10 个，共计 0.50 万元。

2）智能手环：用于终端数据采集与测试。参考单价 0.01 万元，数量 8 个，共计 0.08 万元。

3）移动数据存储设备等耗材：用于数据的存储。参考单价 0.08 万元，数量 10，共计 0.8 万元。

以上费用合计：0.50 万元+0.08 万元+0.80 万元=1.38 万元。

（2）差旅/会议/国际合作与交流费：12.62 万元

差旅费：9.82 万元

1）预计参加国内学术会议共 4 人次，平均每次 3 天，出差地交通费约 2000 元/人

次，出差地人均食宿交通费标准550元/天/人次，共（550元/天/人次×3天+2000元/人次）×4人次=1.46万元。

2）预计境内短程出差10人次，平均每次出差时间3天，出差地人均食宿交通费标准550元/天/人次，城市间交通费600元/人次，共（550元/天/人次×3天+600元/人次）×10人次=2.25万元。

3）预计境内长程出差8人次，平均每次出差时间3天，出差地人均食宿交通费标准550元/天/人次，城市间交通费1000元/人次，共（550元/天/人次×3天+1000元/人次）×8人次=2.12万元。

4）预计参加国际学术会议共3人次，平均每次6天，出差地交通费约10000元/人次，出差地人均食宿交通费标准550元/天/人次，共（550元/天/人次×6天+10000元/人次）×3人次=3.99万元。

会议费：2.80万元

会议费主要用于项目研发过程中举行的调研和学术交流的各种研讨会所需的场地租用、设备使用等费用。会议费的标准严格按照《中央和国家机关会议费管理方法》（国管财[2013]286号）的相关规定执行。会议费围绕项目的开题中期检查和结题等工作展开：预计4次会议以上，每次会议费预计7000元左右，合计4次大约2.80万元。

以上费用合计：9.82万元+2.80万元=12.62万元。

（3）出版/文献/信息传播/知识产权事务费：10.70 万元

用于研究过程中支付学术论文（著作）发表版面费，专利申请等方面费用。

1）研究成果在国内外发表学术论文：目前国际学术会议论文版面费约为8000元/篇，部分期刊/国内会议论文发表费约为5000元/篇。按照课题任务书目标，计划发表国际学术会议论文4篇，国内召开的国际会议或部分期刊论文6篇，则课题组所需的论文版面费共计约为0.80万元/篇×4篇+0.50万元/篇×6篇=6.20万元。

2）专利申请费：本课题需提交5项国内专利。所有专利申请都必须经过第三方专利代理公司进行。根据当前的平均价格，国内专利约为0.70万元/项，总计约5项×0.70万元/项=3.50万元。

3）技术资料复印打印、专业书籍购买、会议海报制作、论文印刷和装订、检索费等：1.00 万元。

以上费用合计：6.20万元+3.50万元+1.00万元=10.70万元。

3、劳务费：18.80万元

（1）项目组成员劳务费：15.20万元

测算依据如下：博士1800/月，硕士1000/月，本科生500/月

劳务费用明细表

序号	人员类别	人月	劳务标准（元）/月/人	专项经费（万元）
1	博士研究生	40	1800	7.20
2	硕士研究生	60	1000	6.00
3	本科生	40	500	2.00
合计				15.20

以上费用合计：7.20万元+6.00万元+2.00万元=15.20万元。

（2）专家咨询费：3.60 万元

邀请国内外专家指导交流的费用

级别	单价（万元/人*天数）	天数	人次	总价（万元）
高级	0.40	1	6	2.40
中级	0.20	1	6	1.20
合计				2.40

以上费用合计：2.40 万元+1.20 万元=3.60 万元。

项目直接经费总计：13.00万元+24.70万元+18.80万元=56.50万元。

NSFC 2024

报告正文

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。**请勿删除或改动下述提纲标题及括号中的文字。**

（一）立项依据与研究内容（建议 8000 字以下）：

1. 项目的立项依据（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；

1.1 研究背景及意义

近年来，随着“人口红利”减弱与疾病图谱改变，我国持续面临人口老龄化、慢病年轻化的巨大压力。当前正处于后疫情时代，国民健康意识相比疫情前明显提高，而据调查显示，大多数国民新冠后仍感觉有后遗症状，其中睡眠质量不佳达 29.7%，焦虑、紧张情绪达 13.9%，34%的人仍感觉有咳嗽等呼吸系统症状。《“健康中国 2030”规划纲要》中强调“通过关口前移积极应对健康问题”，并且主动健康被纳入国家“十四五”规划纲要中，以主动健康理念推动体卫融合健康促进体系建设成为必然趋势。**主动健康是通过对人体主动施加可控刺激，增加人体微观复杂度，促进人体多样化适应，从而实现人体机能增强或慢病逆转的医学模式。**此外，以人工智能、物联网、虚拟现实等技术为代表的新技术正在驱动世界进行新一轮技术与产业的变革，将科技创新作为提高健康水平的有力支撑为主动健康的发展指明了方向。

然而，主动健康涵盖全周期健康服务链，强调连续、全面、动态、实时地监测反馈人体的健康状况。在人工智能与主动健康结合的应用中，现有人工智能技术能否针对主动健康场景需求，实现相应适配仍然是一个亟待解决的问题。而且实际系统往往处于**无约束场景，即外在因素（光照、视角、分辨率等）和内在要素（姿态、性别、年龄等）不受约束**，模型在应用场景中的鲁棒性成为关键。此外，如何将人工智能技术覆盖全周期健康管理仍然困难重重。总的来说，构建智能主动健康服务系统主要面临以下三方面挑战。

挑战一：个体间体质及需求差异大，如何面向不同人群定制运动处方，并建立反馈体系。由于年龄、职业、慢性病等因素导致不同个体身体素质差异较大，特别是青少年和老年人，需要根据体适能制定个性化运动处方。此外，还需要跟踪处方实施效果，对运动处方进行及时调整。最后，仅采集个体某一时期的体质数据，而不形成连续有效的数据链，将失去大数据的意义，因此必须建立用户健

NSFC 2024

康档案，避免数据断层。这需要人工智能技术专家与运动医学领域专家通力合作，制定面向不同人群的体适能评估标准，并利用人工智能技术进行全流程保障。

挑战二：运动感知模型性能要求高，在更侧重对特定人体部位及状态感知精度的要求下，如何兼顾感知模型的轻量化与精准化。首先，主动健康涉及全面实时监测人体运动信息，因此对模型的速度与精度有较高要求，其次更关注对特定部位的解析，例如，青少年经常出现的骨盆前倾、驼背、高低肩等体态问题。目前的感知模型大多注重通用性，对于人体特定部位、特定姿态的感知精度还无法满足实际需要。针对这一问题，必须结合业务特点，如运动的高重复性、用户的可交互性，来帮助算法在保障轻量化的同时，提升精准度。

挑战三：运动理解内容复杂任务难，如何实现人体运动感知到理解的过渡。智能主动健康场景中，需要对个体运动情况进行识别、评估、建议，并对运动能力进行反馈，完善下一阶段运动处方规划。因此，单一的人体运动感知无法满足实际需求，需要从人体运动感知层面上升到理解层面。以 ChatGPT、SAM 为代表的大模型技术的发展，证明了人工智能技术在内容理解任务上的优越性，而面向主动健康场景的内容理解模型的开发可以借鉴其相关研究思路。

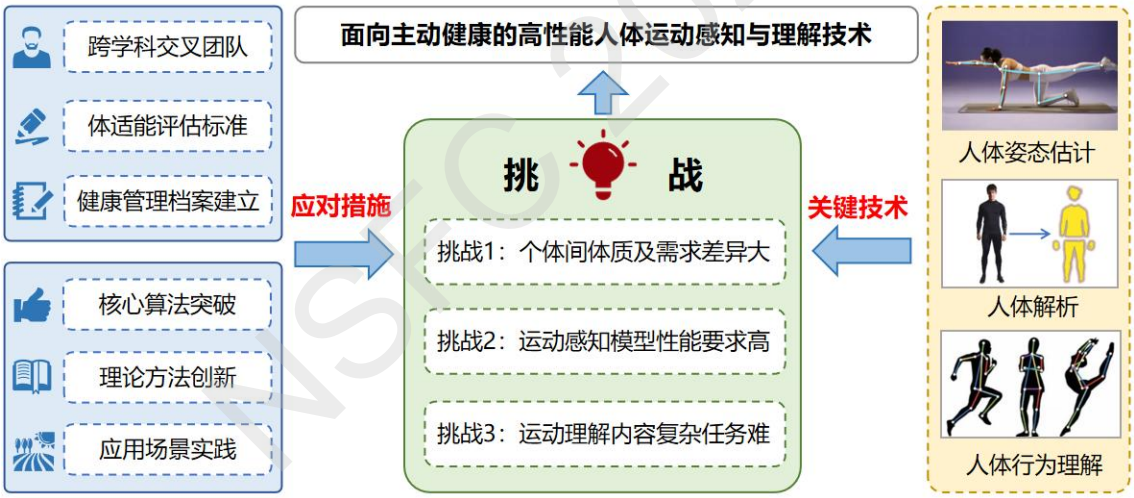


图 1 三大挑战及应对措施

综上所述，本项目关注国民体质健康问题与日常运动需求，响应国家“健康中国 2030”与“十四五”规划纲要，以人体运动感知与理解等人工智能技术为抓手，推动构建智能主动健康服务平台，集体适能评估、运动处方定制、智能监测、健康档案管理于一体，成为由“治已病”向“防未病”和“以疾病治疗为中心”向“以人民健康需求为中心”改革的新突破口。**本项目将从前述挑战入手，以人体姿态估计、人体解析、人体行为理解等人体运动感知与理解算法为驱动，**与视频生成模型、视觉语义对齐模型等有机结合、协同优化，结合实际业务特点，提升通用算法性能，设计行为感知到理解的技术框架；**以申请团队特有的跨学科研究背景以及在人像感知与理解、运动医疗等相关研究为基础，**构建出人体运动感知与理解驱动的主动健康服务系统；**以体卫融合思想提升国民安全性、科学性、终身性的健康管理意识，**进而全面保障并促进国民体质健康水平的提高。此外，本项目研究内容以

用促研，将进一步推动无约束场景下人像感知与理解问题的解决和发展，为公共安全、安全生产监测等其他应用领域提供研究范本。

1.2 国内外研究现状及发展动态分析

本项目涉及对人体体质水平、运动状态等进行持续跟踪分析，此外需要保障实际应用的便捷化与精准化，以视觉输入为主的人体运动感知与理解技术可以在保证算法精度与速度的同时，覆盖更多的应用场景，从而满足大多数人的使用需求。因此，项目组针对运动感知任务重点研究关键点级的人体运动分析技术和像素级的人体解析技术；针对运动理解任务重点研究人体行为理解技术。下面将从上述核心关键技术出发，结合相应的技术路线分别展开调研：

1.2.1 无约束场景下有先验人体运动分析

通过计算机视觉技术处理输入视频得到人体姿态序列并进行运动分析是主动健康体医融合[128]应用的重点，这项技术有以下潜在应用场景：1）在康复医学中，准确评估患者的运动功能是至关重要的，通过深度学习模型对人体姿态的识别和分析，可以实现对患者的步态、关节活动度等指标的定量评估，从而为医生提供更准确的康复效果反馈；2）在远程医疗场景中，医生可以通过深度学习模型分析患者的运动模式，以评估其健康状况和诊断潜在的疾病。这种非侵入性的检查方式可以为偏远地区的患者提供便捷的医疗咨询；3）在运动辅助场景中，针对特别需要关注的群体，如老年人或儿童，人体运动分析模型可以帮助监测其运动过程，及时发现异常的姿态行为并提供必要的干预和矫正。要实现这些应用，需要模型具备处理和分析大量图像和视频数据的能力，同时也要注意数据隐私和安全的问题。另外，由于深度学习模型的精度和泛化能力在很大程度上取决于训练数据的规模和质量，建立一个标注准确的训练数据集也是一项重要任务。因此，本研究点拟从人体姿态的视频训练数据生成、人体姿态估计模型、人体姿态序列优化这三个方面来提升人体姿态识别的精准性。

（1）基于姿态辅助的视频数据生成模型

首先，针对本项目对大量无约束场景中的训练数据需求，拟使用视频生成模型进行数据层面扩展。视频生成模型可以根据给定的输入（例如文本描述、图像或其他视频片段）生成新的视频。以下是一些视频生成模型的研究现状：

基于生成对抗网络（GAN）的视频生成模型。生成对抗网络已经被广泛用于图像生成任务，然后被扩展到视频生成。通过使用两个神经网络，即生成器和判别器，GAN 可以通过对抗训练生成逼真的视频序列。VGAN（Video GAN）[1]是

一种最早被提出的基于GAN的视频生成模型，它采用了类似于图像GAN的框架，其中生成器网络生成视频帧序列，而判别器网络则尝试区分真实视频和生成视频。TGAN（Temporal GAN）[2]是一种专门设计用于生成连续视频序列的模型，它引入了时序判别器，以捕捉视频帧之间的时序一致性，生成器网络通过生成连续的视频帧序列来尽量欺骗判别器。MoCoGAN（Motion Conditioned GAN）[3]是一种以动作条件为基础的视频生成模型，它通过将视频生成任务分解为外观和动作两个条件，分别生成外观和动作编码，然后将它们结合起来生成最终的视频。VEEGAN（Variational Encoder-Decoder GAN）[4]是一种结合了变分自编码器（VAE）和GAN的视频生成模型，它利用VAE的编码器网络将输入视频序列映射到潜在空间，并使用GAN的生成器网络从潜在空间中生成新的视频序列。

基于变分自编码器（VAE）的视频生成模型。变分自编码器是一种生成模型，它通过学习数据的潜在分布来生成新的样本。在视频生成中，VAE可以学习视频的潜在表示，并生成与输入数据类似的新视频。SV2P（Stochastic Variational Video Prediction）[5]是一种基于VAE的视频生成模型，它采用了时序变分自编码器（Time-VAE）的结构，通过学习视频的潜在表示来预测下一个视频帧。SV2P能够生成连贯的视频序列，并且具有一定的预测性能。SVG（Stochastic Video Generation）[6]是一种通过组合变分自编码器和递归神经网络来生成视频的模型，它引入了一个递归神经网络结构，用于对视频序列的时序关系建模。TGAN-VAE（Temporal Generative Adversarial Networks with Variational Autoencoders）[7]结合了GAN和VAE的思想，用于生成高质量的视频序列。它利用VAE编码器将视频序列映射到潜在空间，并使用GAN生成器从潜在空间中生成新的视频序列。

基于注意力机制的视频生成模型。注意力机制可以帮助模型在生成视频时集中于关键的对象或区域。通过引入注意力机制，视频生成模型可以更加准确地生成具有丰富细节的视频。TGAN[8]是结合了VAE和注意力机制的视频生成模型，利用VAE的编码器将视频序列映射到潜在空间，并使用解码器生成新的视频序列，通过引入注意力机制，使得在生成视频序列时能够关注重要的对象或区域。

基于流的视频生成模型。流是指将视频序列建模为一个连续的函数，可以通过对这个函数进行采样来生成新的视频。流模型可以处理不同长度和分辨率的视频，并且在生成过程中可以实现较高的灵活性和可控性。FlowNet[9]是一种基于光流的视频生成模型，它通过学习视频帧之间的光流场来估计运动信息，并利用这些估计的光流场进行视频合成。VoxelFlow[10]是一种基于体素流的视频生成模型，它将视频帧表示为3D体素网格，并学习视频帧之间的体素流场。通过估计和应用体素流场，VoxelFlow可以生成具有连贯运动和相关细节的视频序列。Stable Video Diffusion[11]是一种基于流的视频生成模型，它利用扩散过程来生成逼真的视频序列，通过逐步扩散噪声来逼近目标视频分布。该模型通过应用流动操作，将噪声序列逐渐转化为逼真的视频序列。在扩散过程中，它采用了可微分的流动模型，使得生成的视频序列具有连贯性和真实性。Text2Video-Zero[12]基于Stable Diffusion，实现了文本-视频生成扩散模型，基于生成的图像帧的latent 特征空间

进行运动动态编码，并使用跨帧注意力来重新编码帧级别的 Self-Attention，以保持生成场景和背景的一致性。FlashVideo[13]将 RetNet 架构引入视频生成，针对快速的文本-视频生成需求，减少了推理过程的时间复杂度。

表 1 视频生成模型对比

方法	数据集	输入信息	技术特点
VGAN[1]	Unfiltered Unlabeled Videos	100 维高斯噪声	使用初代 GAN 网络
TGAN[2]	Moving MNIST	图像	连续视频序列
VEEGAN[4]	Synthetic Dataset	视频序列	映射序列到潜在空间
SV2P[5]	Human3.6M	图像	有预测性能
SVG[6]	SM-MNIST	图像	建模时序关系
FlowNet[9]	KITTI	图像	光流场估计运动信息
VoxelFlow[10]	UCF-101	视频序列	估计体素流场
SVD[11]	UCF-101	文本、图像	连贯性，真实性
Text2Video-Zero[12]	UCF-101	文本	文本视频生成扩散
FlashVideo[13]	UCF-101	文本、图像	推理时间快

综合以上调研，现有的视频生成模型对同时生成数据与标签还没有涉及，仍然需要较高的数据集标注成本。因此，本研究点拟基于扩散模型构建视频生成网络，利用人体运动姿态序列引导动作视频生成，并通过文本描述等信息提升视频生成质量，从而实现带标签的人体运动视频数据生成，为后续研究提供数据基础。

（2）基于姿态知识库的姿态序列优化算法

在得到针对主动健康场景的视频训练数据后，可以提升人体姿态估计网络[38-41]在此场景下的识别准确性。然而目前的人体姿态估计网络存在一定的缺陷：以图像作为输入的网络，如[14-24]，消耗较少的计算资源，但是识别视频数据得到的人体姿态序列存在肉眼可见的抖动；以视频作为输入的网络，如[25-31]，以较高的计算资源为代价，结合多张连续图像信息进行姿态序列识别，然而由于其较高的资源消耗，难以实际应用于主动健康场景，针对人体姿态估计以及其优化算法的研究现状如下（表 2）：

以图像为输入的人体姿态估计网络。图像数据的场景分布广泛，计算资源需求相对较少，训练出的网络效果对于场景变换不敏感。Hourglass[39]以其独特的沙漏结构网络来循环多次处理图片的全局以及局部信息。Pif-Paf[41]利用关节点之间的方向向量来组合关键点到个体，通过预测关键点间的方向和距离信息，实现对人体姿态的预测。AdaptivePose[40]基于单阶段的框架，通过构建新的人体姿态表征，利用自适应中继节点提高姿态估计的精度和鲁棒性。AlphaPose[38]通过引入注意力机制和多任务学习策略，提升人体姿态估计算法效率。HRNet[36]的每个阶

NSFC 2024

段都能同时获得全局和局部信息，增强了模型的表示能力。HigherHRNet[37]利用高分辨率特征图和多尺度信息融合技术，提高了姿态估计的准确性和鲁棒性。DecenterNet 的分支（位置图）通过作为损失的权重来动态代表网络对于各个姿态的置信度，从而选择到置信度较高的姿态作为候选姿态。然而，由于以图像为输入的人体姿态估计网络缺乏时序信息，对于视频数据的识别往往存在大量抖动。

表 2 人体姿态估计准确率对比

方法	输入类型	输入帧数	MPVE	MPJPE	PA-MPJPE
HMR[14]	图片	1	-	88	56.8
SPIN[15]	图片	1	82.3	59.4	39.3
I2L-MeshNet[17]	图片	1	-	55.7	41.7
HybrIK[18]	图片	1	58.1	47.4	30.1
METRO[19]	图片	1	-	54	36.7
Mesh Graphormer[20]	图片	1	-	51.2	34.5
PyMAF[21]	图片	1	-	57.7	40.5
CLIFF[22]	图片	1	-	47.1	32.7
FastMETRO[23]	图片	1	-	52.2	33.7
VisDB[24]	图片	1	-	51	34.5
TemporalContext[25]	视频	32	-	77.8	54.3
HMMR[26]	视频	20	-	-	56.9
DSD-SATN[27]	视频	9	-	59.1	42.4
VIBE[28]	视频	16	-	65.6	41.4
TCMR[29]	视频	16	-	62.3	41.1
MAED[30]	视频	16	84.1	60.4	38.3
MPS-Net[31]	视频	16	-	69.4	47.4
GFPose[42] (+SPIN[15])	图片+优化	1+1	-	58.8	39.2
HuMoR[43] (+SPIN[15])	图片+优化	1+16	-	47.3	37.0
SmoothNet[32] (+SPIN[15])	图片+优化	1+32	-	43.2	35.6

以视频为输入的人体姿态估计网络。视频数据往往场景分布较集中，计算资源消耗多，但是识别姿态序列较平滑。TemporalContext[25]采用运动特征学习框架，将视频帧序列转化为单帧处理，提高了姿态估计的准确性和实时性。HMMR[26]结合深度和光流信息，从视频中提取时空特征，提高对人体姿态预测的准确性和鲁棒性。DSD-SATN[27]引入非局部自注意力机制，使网络能够关注视频中重要的时空区域。MPS-Net[31]将长短期记忆网络（LSTM）与卷积神经网络结合，处理视频中的时序信息，保障人体姿态的时间连续性。VIBE[28]使用一个序列生成对抗网络，从视频中预测 SMPL 人体模型的参数，同时利用一个动作判别器来区分真实和生成的人体姿态序列，从而提高姿态的真实性和连续性。SPIN[15]使用一个卷积神经网络，从图片中提取特征，然后使用一个人体参数回归器，从特征中回

NSFC 2024

归 SMPL 人体模型的参数，同时利用一个形状判别器来约束形状的分布，从而提高输出结果的合理性。TCMR[29]是在 VIBE 的基础上进行了改进，增加了三个 GRU 层，从目标帧临近的若干个连续帧中找到更加稳定的特征，然后从稳定的特征中回归 SMPL 人体模型的参数，从而提高姿态的稳定性和一致性。

姿态序列优化算法。将以图像为输入的人体姿态估计网络与姿态序列优化算法结合使用，往往会取得不错的效果，且计算资源消耗远小于以视频为输入的人体姿态估计网络。Savitzky-Golay 滤波器[33]是一种局部多项式插值滤波器，旨在平滑数据，同时减少数据中的噪声。它通过在数据点周围定义局部窗口，并使用多项式来拟合该窗口中的数据，实现平滑效果。Gaussian 1d 滤波器[34]是一种一维高斯函数滤波器，主要用于平滑信号。该滤波器通过将一维高斯函数与信号进行卷积，实现信号的平滑。One-Euro 滤波器[35]是一种自适应滤波器，用于处理具有随机特性的时间序列数据。它通过结合随机振动模型和滤波器的自适应调整，能够根据数据的特性自动调整滤波器 k 的参数，从而得到最优的平滑效果。SmoothNet[32]仅针对时间维度的标量利用全连接网络进行平滑处理，相较于传统滤波器，在多个人体姿态序列数据集上取得了较好的结果，但是没有充分考虑空间维度信息。此外姿态序列优化算法中还包括先验模型。MVAE [44]和 HuMoR [43]使用自回归条件变分自编码器（VAE）来学习在给定历史状态的情况下合理的姿势轨迹。GFPose[42]考虑了人体姿态的空间维度信息，可以利用已有的先验知识修复不合理的错误姿态，但是采样次数参数的设置需要合理调整，太高太低都会导致修复姿态与真实姿态的偏差。

综合以上调研，以图象为输入的人体姿态估计网络配合轻量化姿态序列优化算法是综合考虑准确率和效率的最优组合。然而，目前的姿态序列优化算法受限于小模型的能力无法结合相似姿态进行姿态序列优化，而运动场景中同一动作的人体姿态序列又具有一定的相似性。本研究点拟采用外置向量知识库的方式为姿态序列优化算法提供**辅助先验**，之后利用自注意力机制进行多个姿态间的信息提取，最终完成姿态序列优化。

1.2.2 主动交互行为引导的开集人体解析

研究主动交互行为引导的开集人体解析对主动健康中体型评估与分析具有实际应用意义。**通过精确地分析多个人的体型和体态特征，该技术可以帮助用户更好地了解自身的身体状况，发现体型方面存在的问题，明确改善目标和方向。**基于体型评估结果，可以为个体提供个性化的饮食、锻炼和塑形建议，制定更加精准和有效的健康管理方案。此外，人体解析技术还可以用于监测和分析个体体型变化，体适能变化，促进科学健身并预防运动损伤。通过动态监测个体的体型变化和健康进展，可以及时调整健康管理计划，保障运动目标实现。同时，该技术还有助于推动相关领域的研究和发展，为体型与健康之间的关联提供更加科学和全面的技术与理论支持。随着技术的不断进步和应用范围的扩大，人体解析技术

将在主动健康领域发挥更加重要的作用，为人们的健康生活带来更多便利。

（1）像素级特征对齐的开集人像形体解析算法

人体解析算法（Human Parsing，HP）任务的目标是在图像中对每个人体的各个部分进行像素级的细粒度分割。这个任务需要同时识别出实例级别的人物和类别级别的人体部位。随着深度学习技术的广泛应用，人体解析已经取得了显著的进展，并在虚拟试穿、人机交互和场景理解等应用中发挥了重要作用。目前，人体解析的方法大致可以分为三类：自底向上、自上而下和单阶段方法。

自底向上的方法（bottom-up methods）首先解析图像中的所有人体部位，然后根据诸如人体边缘、姿态等线索将它们分组到相应的实例中。自底向上的方法通常首先预测像素的语义标签，然后根据实例信息对它们进行分组。一些研究工作 [45]，[46] 应用基于 GAN 的网络来提高模型对实例和语义特征的学习能力。其他研究工作利用额外的 ground-truth 信息，如姿态[47]和边缘[48]，来帮助模型学习实例特征。然而，在自底向上的方法中，实例和语义信息是独立处理的，因此需要额外的分组步骤。

自上而下的方法（top-down methods）先使用检测器识别出人体实例，然后对每个实例的人体部位进行单独的解析。自上而下的方法通常依赖于检测器来定位实例的边界框，然后在检测到的区域内进行单人解析。经典的自上而下方法包括 Parsing RCNN [49]和 RP-RCNN [50]，它们首先生成一个边界框，并利用额外的上下文编码模块来获得更精细的语义像素特征。还有一些方法[51]，[52]，[53]专注于挖掘新的约束，以增强模型提取实例上下文特征的能力。SNT [54]依赖于 Mask RCNN 来区分人体实例，通过人体部位的属性在第二阶段内预测人体部位，并可以降低预测难度。然而，自上而下的方法由独立的检测器和单人解析器组成，导致无法进行端到端的优化。为了解决这个问题，一些研究开始探索将检测器和解析器集成到一个统一的框架中。这种方法可以同时优化实例检测和解析任务，从而在整体上提高性能。一种常见的做法是使用多任务学习（Multi-task Learning）的方法，将检测器和解析器视为共享特征提取网络的不同输出任务。通过联合训练这两个任务，模型可以在两个任务之间共享有用的特征，并提高性能。

单阶段方法（single-stage methods）则同时预测人体实例和人部位掩模，通常需要经过非极大值抑制（NMS）过程以获得最终结果。单阶段方法旨在通过一次遍历完成任务，而不需要涉及 ROI 检测和分组过程。一些代表性的研究包括 SMP [55]、ReSParser [56]和 CID [57]。SMP 通过点集和偏移量来模拟多人解析任务，用偏移量的索引替换分组过程，通过条件核生成人体解析结果。然而，由于需要通过质心、卷积核和掩模重复表示类别语义，计算上仍然存在冗余。ReSParser 和 CID 类似，它们首先通过实例核激活特征来获取相关实例特征，然后基于这些特征对每个语义类别进行解析预测。最终的解析阶段需要解析头同时获取实例和类别语义。这给最终的分割头带来了巨大的任务负担，需要大量的参数。因此，它们的

最终预测头设计非常复杂。它们仍然依赖于复杂的模块来增强特征提取能力或在推理过程中进行非可微分的后处理。

总体而言，自上而下方法中的边界框、自底向上方法中的分组线索以及单阶段方法中的中心偏移量等属于实例级信息；而对人体部位的细粒度语义分割属于类别级信息。尽管之前的研究在性能上表现出色，但它们以不同的形式分别处理实例和类别信息。此外，由于使用了检测器、分组线索和 NMS 过程，整个管道并不是联合优化或真正的端到端。因此，之前的研究框架效率低下且冗余，缺乏对最终结果的直接监督和一个纯粹的端到端过程，此外，目前的算法模型都桎梏在闭集条件下，无法处理更加接近现实世界的开放环境，面对较大的环境变化或新类别的识别需求，当前的研究方法都不能完善的应对。

当前主流的面向开放世界的细粒度可交互图像分割算法的研究方向集中于两种任务即：（1）面向开放世界的可交互分割方法；（2）面向开放世界的细粒度分割方法。

面向开放世界的可交互分割方法。近年的研究热点主要集中于 Meta AI 提出的 Segment Anything Model（SAM）[58]方法和数据集。其利用大量的实例分割图片数据，通过循环的人工标注优化和模型训练，得到了一个 class-agnostic 的实例分割模型，其优点是具有强大的泛化性，基于 SAM-1B 的图像数据训练后，即使是未知实例也能根据其图像特点进行精准分割，并且面对大数量级和大尺度方差的图像样本依旧能够较好地完成分割工作，其证明了在无语义信息的指导下，模型能够成功地根据实例自身的相关特性进行分割。此外，由于其先进的 Transformer 类架构，使 SAM 拥有了处理不同形式 prompt 的能力，SAM 可以接受用户的点击，框选等不同形式的输入 prompt 进行指定实例的分割，而且 SAM 对同一输入的 prompt 可以响应出不同细粒度的实例分割结果。但由于 SAM 训练时不涉及语义相关的信息，因此 SAM 没有语义分割的能力，无法为每个实例分割结果赋予类别。这距离理想的视觉大模型仍有一定距离。

为了弥补语义的缺失，研究者们又提出了许多新的框架方法。威斯康星-马迪森分校和微软联合提出的 SEEM[1]采用 X-decoder[59]的模型结构，引入了文本 query，和其他视觉 query 联合训练一个文本-视觉特征空间。通过这种方式，SEEM 不需要额外提供实例目标的类别标注进行语义训练，在以文本 query 作为 prompt 进行分割的同时，文本-视觉联合特征空间已经隐性地学习到了语义信息，因此 SEEM 可以直接根据文本特征直接输出实例的语义类别。但与 SAM 相比，SEEM 更依赖于带有文本 prompt 的数据集，在 class-agnostic 的分割能力上有所欠缺，并且不具有多粒度的分割能力。还有其他研究者尝试利用 SAM 的分割能力将其与其他的具有分类能力的模型相结合组成一个新的框架使其同时具有强泛用分割能力和强语义分类能力，如 IDEA-Research 的 Grounded-SAM 就将开集文本视觉检测器 Grounding-DINO[60]与 SAM 结合，利用 Grounding-DINO 强大的开集语义目标检测能力和 SAM 的实例分割能力实现了带有语义分类的多类 prmopt 输入的分割框架。

面向开放世界的细粒度分割方法。2023 年 4 月，Meta AI 提出了 VLPart[61] 模型，首次将多粒度的部位分割与开放世界结合起来，实现了多粒度下的开集部位分割。VLPart 模型主要参考了 Mask RCNN，并引入了 CLIP 文本-视觉空间的泛化性实现对未知部位的分割。对于新的部位（novel part），VLPart 会计算得出其语义最接近的已知部位类（base part），并在二者之间建立语义相关性，从而辅助新部位（novel part）的分割。此外，利用文本 prompt，VLPart 可以设定同一类目标不同的细化粒度。

表 3 人体解析代表性算法

方法	开集	粒度	结构	特点
Parsing RCNN[49]	×	多粒度	自上而下 两阶段	经典多粒度，自上而下 两阶段算法
RP RCNN[50]	×	多粒度	自上而下 两阶段	利用多级金字塔网络强化上下文特征提取
PGN[48]	×	多粒度	自底向上 两阶段	利用边缘 组合细粒度语义分割结果
MHParser[46]	×	多粒度	自底向上 两阶段	利用图结构 强化人体特征提取
NAN[45]	×	多粒度	自底向上 两阶段	利用 GAN 网络实现不同粒度上的特征提取
SNT[54]	×	多粒度	自上而下 两阶段	将人体结构 多级细化分类
AIParsing[51]	×	多粒度	自上而下 两阶段	利用边缘信息强化人体实例特征提取
ReSparser[56]	×	多粒度	单阶段	通过融合人体和部位特征提高模型能力
SMP[55]	×	多粒度	单阶段	通过点集和偏置完成对人体和部位的表征
CID[57]	×	多粒度	单阶段	通过实例重心特征区分 实例表征
SAM[58]	√	多粒度	编解码器	Transformer 结构的纯实例分割器
X-Decoder[59]	√	单粒度	编解码器	引入文本向量实现多视觉任务的统一实现
Grounding DINO[60]	√	单粒度	编解码器	引入自监督，挖掘像素特征相关性，对齐语义实体
VLParts[61]	√	多粒度	编解码器	利用实例和部位的逻辑相似性，提高模型对未知部位处理能力

综合以上调研，结合人体解析算法在实际应用中场景复杂、穿着多样的特点以及提示信息可以增强算法鲁棒性的实验结果，本研究点拟结合文本特征设计开集人体解析算法，将文本特征与图像特征在特征空间中实现对齐，利用文本特征空间的强鲁棒性特点解决人体解析算法在实际应用环境中面临的多变难点，以获得对人体体型的精准解析，为后续主动健康应用提供支持。

NSFC2024

（2）面向人体解析算法的交互式辅助增强技术

在实际应用中，交互行为可以增强系统的鲁棒性与实用性，提升用户体验和服务质量。交互式分割技术的目标是在提供有限的用户交互信息的情况下，完成对目标物体的精准分割。将交互辅助技术引入人体解析算法，主要用于实现对特定身体部位的人体解析和评估记录。**通过采用用户点击辅助的形式，用户能够有选择性地指定感兴趣的身体部位，从而在分割和分析的过程中减少不必要的计算步骤，使算法更加专注于用户关心的区域。这一技术的应用旨在降低计算负担，提高运行效率，并更好地满足用户的个性化需求。**针对面向人体解析算法的交互式辅助增强技术的研究现状如下（表 4）：

交互式图像分割是一个长期存在的问题，目前已经有研究提出了较好的解决方法。早期的方法[62，63，64，65]使用基于图片像素定义的图形来解决这个问题。然而，这些方法只关注底层的图像特征，因此往往难以处理复杂的对象。随着大规模数据集的出现，卷积神经网络[66，67，68，69，70]已经发展成为高质量交互式分割的主导架构。基于卷积网络的方法已经探索了各种交互类型，如边界框[69]、多边形[71]、点击[68]和涂鸦[72]。基于点击的方法是最常见的，因为它们简单且建立良好的训练和评估指标。Xu 等人[70]首先提出了一种点击模拟策略，并被后续的研究延用[66，73，68]。DEXTR[74]通过指定目标对象的四个极值点（最左、最右、顶部、底部像素）来提取目标对象。FCA-Net[75]证明了第一次点击对于得到更好的分割结果具有关键作用。

与卷积神经网络相比，基于 ViT 的方法[79，80，81，76，82]在图像分割任务上表现出了优越的性能。原始的 ViT[83]是一种非分层架构，始终只维持单尺度特征映射。SETR[84]和 Segmenter[81]使用原始 ViT 作为语义分割的编码器。为了实现更高效的分割，Swin Transformer[78]通过转移窗口注意力，在原始的 ViT 架构中重新引入了计算层次结构，从而形成了高效的分层 ViT 主干。SegFormer[76]在原始 ViT 的基础上使用重叠补丁合并设计分层特征表示，并结合轻量级 MLP 解码器进行高效图像分割。HRViT[79]将高分辨率多分支架构与 ViT 集成，以学习多尺度表征。在 MAE[85]预训练和窗口注意力的帮助下，原始的 ViT 被广泛用于语义分割[86]和目标检测[87]的研究中。

近年来，ViTs 已渐渐被应用于交互式分割。FocalClick[66]使用 SegFormer[76]作为骨干网，以较高的计算效率获得了最先进的分割结果。iSegFormer[77]使用 Swin Transformer[78]作为骨干网对医学图像进行交互式分割。除了对主干的贡献之外，一些研究正在探索在主干上构建的精细细化模块。FocalClick[66]和 FocusCut[67]提出了类似的局部细化模块，以实现高质量的分割。PseudoClick[73]提出了一种通过估计下一次点击来模仿点击的机制，以进一步降低人工标注成本。

综合以上调研，视觉 Transformer（ViT）适用于密集预测任务，其允许使用原始 ViT 作为基础模型，可以对下游任务进行微调，而无需重新设计用于预训练的分层主干。**这种设计虽简单有效，但现有工作并没有对与交互信息高效融合从而**

提升模型性能展开研究，结合交互信息对人体特定部位分割结果优化仍然是一个需要解决的问题。因此，本研究点不同于以往的基于点击的方法，拟使用简单的、非分层的 ViT 作为主干，引入一个对称的补丁嵌入层，将点击编码到骨干网中，并对骨干网本身进行轻微的修改。通过将普通主干网络预训练为掩码自动编码器（MAE），预达到最先进的性能，提升系统实用性。

表 4 交互式图像分割代表性算法

方法	数据集	网络结构	指标		技术特点
			NoC85	NoC90	
DIOS[70]	Pascal	FCN	-	6.04	点击次数少，泛化能力好
FCA-Net[75]		ResNet-101	-	2.08	首次提出点击注意力网络
LD[88]	SBD	VGG-19	3.2	4.79	保持了与交互式分段界面的兼容性
BRS[89]		DenseNet	2.6	3.60	接受用户对目标物体和背景的注释
RITM[81]		HRNet-18	1.76	2.04	采用简单前馈模型，允许外部蒙版进行校正
RITM[81]	COCO+LVIS	HRNet-32	1.46	1.56	
CDNet[90]	SBD	ResNet-34	1.86	2.18	对用户的点击信息进行推广
	COCO+LVIS		1.40	1.52	
PseudoClick[73]	SBD	HRNet-18	1.68	2.04	提出模仿点击机制，降低人工成本
	COCO+LVIS	HRNet-32	1.36	1.50	
FocalClick[79]	SBD	HRNet-18s	1.86	2.06	较高的计算效率
	COCO+LVIS	SegF-B0	1.40	1.66	
FocusCut[80]	SBD	ResNet-50	1.60	1.78	局部细化模块，实现高质量分割

NSFC 2024

1.2.3 面向多级任务的标准化人体行为理解

因个体体适能情况差异，需要个性化的运动处方定制。目前，大多数人群缺乏专业知识，很难完整又准确的完成既定动作，容易出现运动损伤引起反作用。因此，主动健康场景中需要对运动完成情况进行分析，形成反馈再提升。**对个体完成的动作视频进行理解，检测识别动作类型，评估动作完成度，并给出改进意见是本项目的基本工作。**项目难点在于如何针对持续时间长、重复度高的人体动

作视频进行高效特征提取，以及如何联合人体行为理解中涉及的多级任务，实现跨任务训练优化。因此，本研究点关注于面向视频的人体行为理解，从两方面展开研究，一方面从针对视频数据的特征提取入手，研究视频向量化建模方法，另一方面面向下游多级任务研究标准化人体行为理解框架，构建统一化的输入输出结构，实现联合优化。

（1）基于视觉句子的图像向量化建模方法

面向视频数据的人体行为理解，首先需要针对视频数据进行有效的特征提取，而人体行为理解下游任务种类繁多，如何构建一个适用于多任务的特征编码器是一个亟待解决的关键问题。随着 GPT [91] and LLaMA [92]模型的逐渐发展，自然语言处理领域的大模型已经取得了显著的进步，这些大模型具有强大的语言生成和理解能力，能够处理复杂的语言任务，如文本生成、问答、对话等。由于视频数据比文本数据更加复杂，包括图像、音频和骨骼点序列等多个维度。其次，视频中的动作和行为比文本中的词语和句子更加难以定义和描述，视觉基础模型仍需要进一步的研究发展，目前计算机视觉领域的基础模型研究现状如下（表 5）：

基于视觉句子序列建模的视觉基础模型。LVM[93]提出了一种新的序列建模方法，该方法可以在不使用任何语言数据的情况下训练大型视觉模型。为此，LVM 模型定义了一个通用格式“视觉句子”，其中可以表示原始图像、视频以及带注释的数据源，例如语义分割和深度重建的标注图像，而不需要除像素之外的任何元知识。通过将各种各样的视觉数据表示为序列，然后以最小化下一个标记预测的交叉熵损失为目标训练模型。并且在各种规模的模型架构和多样数据上进行训练，证明了 LVM 模型的可扩展性。在测试时设计合适的视觉提示，可以解决各种不同的视觉任务。

基于视频掩码预训练的视觉基础模型。基础模型在计算机视觉领域的各种下游任务上表现出色。但大多数现有的视觉基础模型仅关注图像层次的预训练，这在一定程度上难以完成动态且复杂的视频层次理解任务。基于上述问题，InternVideo[94]利用生成式和判别式自监督视频学习的优势，提出了一种通用视频基础模型。InternVideo 将掩码视频重建和视频-语言对比学习作为预训练目标，并以可学习的方式选择性地协调这两个互补框架的视频任务，以提升在各种视频任务性能。在没有额外设计的情况下，InternVideo 在视频动作识别/检测、视频-语言对齐和开放世界视频应用等任务中实现了最先进的性能。另外，VideoMAE V2[95]提出了一种高效预训练的双掩码策略，其中编码器对视频标记的子集进行操作，而解码器处理视频标记的另一个子集。VideoMAE V2 模型还使用渐进式训练范式，包括对不同的多源未标记数据集进行初始预训练，然后对混合标记数据集进行后期预训练。此外，VideoMAE V2 在各种下游任务上对预训练视频 ViT 模型进行广泛验证，证明了其作为通用视频表示学习器的有效性。

结合文本信息的视觉基础模型。InstructCV[96]提出了一种计算机视觉任务的语言接口，该接口抽象出特定于任务的设计选择，并通过遵循自然语言指令来执行任务。InstructCV 模型主要将多个计算机视觉任务转化为文本到图像的生成任务，文本是描述任务的指令，生成的图像是可视化编码的任务输出。为了训练模型，InstructCV 采用常用的计算机视觉任务的数据集，包括图像分割、目标检测、深度估计和图像分类等，并使用大型语言模型来转述模板，这些模板传达在每个图像上执行的特定任务，通过该过程，InstructCV 创建了一个多模式、多任务的训练数据集，包括输入和输出图像以及注释指令。CogVideo[98]提出了一种具有 9B-参数量的 Transformer 架构，通过继承预训练的文本到图像模型 CogView2[97]进行训练，并涉及了多帧速率分层训练策略，以更好地对齐文本和视频片段。作为大规模预训练文本到视频模型，CogVideo 在机器和人工评估方面优于其他模型。

综合以上调研，针对主动健康场景中的运动视频具有时间长、重复性高的特点，本研究点拟采用基于视觉句子的图像向量化建模方法，构建一个标准化视觉数据集，从而通过训练完成逐帧图像特征映射，此外，可以通过减少图像特征维度降低算法复杂度，实现对长运动视频的分析理解。

表 5 视频基础模型对比

模型	特色	适用任务	技术特点
LVM[93]	视觉句子序列建模	目标检测 实例分割 视频分割 3D 重建等	提出一种统一的视觉大模型数据集，并基于视觉句子进行建模
InternVideo[94]	视频掩码预训练	动作识别 动作定位 视频语言对齐任务开放世界应用等	采用视频掩码预训练
VideoMAE V2[95]		动作识别 动作检测 动作定位等	采用双掩码策略进行高效预训练
InstructCV[96]	文本信息	图片分割 视频分割 实例分割等	提出多模式、多任务的训练数据集及注释指令。
CogVideo[98]		视频生成 文本到视频生成	基于 Transformer 架构预训练

（2）基于查询的标准化人体行为理解框架

随着技术的不断进步，人体行为理解技术在主动健康相关应用中可以为用户运动后提供运动评估指导，形成闭环反馈。人体行为理解是计算机视觉领域中的

一项重要技术，它旨在从视频中深入分析人体的行为。这个领域涵盖了多个关键任务，包括动作识别、动作分割、动作定位和动作评估等。通过这些技术，模型能够自动识别和理解视频中人的动作，将动作从背景中分离出来，定位动作发生的精确位置，并评估动作的质量或效果。下面针对人体行为理解中几个具有代表性的关键任务研究现状总结如下（表 6）：

动作识别的目标是识别修剪后的视频中的人类动作类别。对于修剪后的视频 $X \in R^{T\times C\times H\times W}$，动作识别模型从 n 类标签集 $\{C_1, C_2, \ldots, C_n\}$ 中预测其标签 C_i。

关于如何设计有效的网络来从视频中提取时空特征，先前工作已经进行了许多尝试，这些工作可以分为两类，即基于 3D CNN 的和基于 Transformer 的。基于 3D CNN 的方法采用 3D CNN 来提高时空信息的建模能力，例如 I3D[99]、Non-Local[100]、SlowFast[101]、X3D[102]等。基于 Transformer 的方法使用 Transformer 来提取时空特征，例如 TimeSformer[103]、Video Swin Transformer[104]、Multiscale Vision Transformer[105]等。基于 3D CNN 的方法的潜力受到卷积算子的小感受野的限制。尽管这可以通过 Transformer 的自注意机制来缓解，但由于缺乏归纳偏差，基于 Transformer 的模型需要更多的训练数据才能获得与基于 3D CNN 的算法相当的结果。

动作分割任务旨在对长时间未剪辑视频中的活动进行分割。给定视频的特征 $X = [x_1, \ldots, x_T] \in R^{T\times D}$，其中 T 是视频中的帧数，D 是特征维度，目标是预测所有帧的类别 $C = [c_1, \cdots, c_T]$。根据所采用的神经网络类型，主流的分割方法可分为三类：基于 TCN 的、基于 GNN 的和基于 Transformer 的。MS-TCN[106]首先采用堆叠多级时间卷积网络来捕捉长视频中帧之间的关系。最近在这一领域的研究，如 MS-TCN++[107]、BCN[108]、C2F-TCN[109]，都集中在减少过度分割误差和逐步细化分割结果上。Global2Local[110]利用全局局部搜索方案来找到有效的感受野，用于组合时间卷积，而不是手工设计的模式。基于 GNN 的代表性方法是 DTGRM[111]。它设计了一个有效的 GCN 模块来建模帧之间的时间关系和依赖关系。作为基于 Transformer 方法的先驱，ASFormer[112]率先探索了基于 Transformer 模型在动作分割任务中的应用，并取得了显著的性能。

时序动作检测旨在定位未修剪视频中动作的开始帧和结束帧。给定视频的特征 $X = [x_1, \ldots, x_T] \in R^{T\times D}$，其中 T 是视频中的帧数，D 是特征维度，目标是预测一个或多个动作实例的开始结束帧及其对应的动作类别 $p_t = (p(a_t), d_t^s, d_t^e)$。时序动作检测方法大致可分为两类：两阶段方法和单阶段方法。两阶段方法主要基于为视频中的动作实例生成建议的时间动作建议生成网络，即基于提议的方法[113，114，115，116，117]。这些方法的第一阶段生成视频中动作实例的建议，而第二阶段细化这些建议并识别相应的类别标签。例如，BSN[118]预测每个片段的开始和结束概率，以生成时间动作建议。BMN[119]通过引入边界匹配置信图进一步改进了 BSN[118]。G-TAD[116]和 PGCN[115]应用图卷积网络来学习用于提议细化的语义和时间上下文。单阶段方法直接预测视频中时间边界和相应类别的动作实例，并支持端到端训练。TadTR[120]和 React[121]提出了一种用于时序动作检测的类似

DETR[122]的方法，该方法引入了可学习查询，以自适应地学习动作表示，而无需额外的后处理。ActionFormer[123]使用局部窗口自关注层和下采样来设计 FPN，以提取视频表示并进一步预测多尺度动作实例。TriDet[124]进一步提出了一种有效的 SGP 层，以通过相对概率分布来缓解自关注问题（例如秩损失问题）和建模边界。

表 6 人体行为理解代表性算法

任务/指标	方法	指标		数据集	技术特点
动作识别 Acc 1/Acc 5	I3D[99]	71.1	89.3	K400	提出双流膨胀 3D 卷积神经网络。
	SlowFast[101]	78.9	93.5		提出快慢双通道关注不同语义
	TimeSformer[103]	78	93.7		使用 Transformer 架构捕捉时空依赖性
	Video Swin Transformer[104]	80.6	94.5		引入 Swin Transformer 解决时空适应问题
动作分割 Acc / Edit	MS-TCN[106]	65.1	61.4	Breakfast	提出堆叠多级时间卷积网络
	DTGRM[111]	68.3	68.9		提出 GCN 模块
	ASFormer[112]	73.5	75.0		将 Transformer 架构引入动作分割
动作评估 Spearman Correlation	I3D+MLP[99]	89.21		MTL-AQA	引入 MLP 层
	DAE-MLP[128]	92.31			提出 DAE 编码器
	CoRe[127]	93.41			提出群体意识回归树回归得分
	DAE+CoRe[128]	95.89			
动作定位 Avg mAP	BMN[119]	32.2		Thumos14	生成提议，并细化
	ReAct[121]	55.0			引入 Query
	TadTR[120]	56.7			端到端训练
	Actionformer[123]	66.8			多尺度关注边界
	TirDet[124]	69.3			细化边界

动作评估的目标是评估人体完成动作的表现情况，并为其打分。在过去几年中，先前工作已经做出了许多工作来解决该问题。大多数传统方法[125]将动作评估公式化为回归问题，并直接预测动作得分。然而，他们的表现受到动作得分标签潜在模糊性的限制。CoRe[126]提出了一种新的对比回归框架，通过成对比较来学习相对分数，而 DAE[127]考虑了分数噪声，并开发了即插即用模块分布式自动编码器。

综合以上调研，人体行为理解任务目标呈多级化，下游任务模型结构也各不

NSFC 2024

相同，难以实现多任务联合优化。本研究点拟基于 **Transformer** 网络设计标准化人体行为理解框架，将不同的任务目标抽象为不同类型的 **Query**，通过统一的解码器根据任务目标得到相应的输出，从而实现跨任务联合优化。

参考文献

[1] Vondrick C, Pirsiavash H, Torralba A. Generating videos with scene dynamics[J]. In NeurIPS, 2016, 29.

[2] Saito M, Matsumoto E, Saito S. Temporal generative adversarial nets with singular value clipping[C]. In ICCV, 2017: 2830-2839.

[3] Tulyakov S, Liu M Y, Yang X, et al. Mocogan: Decomposing motion and content for video generation[C]. In CVPR, 2018: 1526-1535.

[4] Srivastava A, Valkov L, Russell C, et al. Veegan: Reducing mode collapse in gans using implicit variational learning[J]. In NeurIPS, 2017, 30.

[5] Babaeizadeh M, Finn C, Erhan D, et al. Stochastic variational video prediction[J]. arXiv preprint arXiv:1710.11252, 2017.

[6] Denton E, Fergus R. Stochastic video generation with a learned prior[C]. In ICML, 2018: 1174-1183.

[7] Desai A, Freeman C, Wang Z, et al. Timevae: A variational auto-encoder for multivariate time series generation[J]. arXiv preprint arXiv:2111.08095, 2021.

[8] Ding Z, Liu X Y, Yin M, et al. Tgan: Deep tensor generative adversarial nets for large image generation[J]. arXiv preprint arXiv:1901.09953, 2019.

[9] Dosovitskiy A, Fischer P, Ilg E, et al. Flownet: Learning optical flow with convolutional networks[C]. In ICCV, 2015: 2758-2766.

[10] Liu Z, Yeh R A, Tang X, et al. Video frame synthesis using deep voxel flow[C]. In ICCV, 2017: 4463-4471.

[11] Blattmann A, Dockhorn T, Kulal S, et al. Stable video diffusion: Scaling latent video diffusion models to large datasets[J]. arXiv preprint arXiv:2311.15127, 2023.

[12] Khachatryan L, Movsisyan A, Tadevosyan V, et al. Text2video-zero: Text-to-image diffusion models are zero-shot video generators[J]. arXiv preprint arXiv:2303.13439, 2023.

[13] Lei B, Ding C. FlashVideo: A Framework for Swift Inference in Text-to-Video Generation[J]. arXiv preprint arXiv:2401.00869, 2023.

[14] Kanazawa A, Black M J, Jacobs D W, et al. End-to-end recovery of human shape and pose[C]. In CVPR, 2018: 7122-7131.

[15] Kolotouros N, Pavlakos G, Black M J, et al. Learning to reconstruct 3D human pose and shape via model-fitting in the loop[C]. In ICCV, 2019: 2252-2261.

[16] Choi H, Moon G, Lee K M. Pose2mesh: Graph convolutional network for 3d human pose and mesh recovery from a 2d human pose[C]. In ECCV, 2020: 769-787.

[17] Moon G, Lee K M. I2l-meshnet: Image-to-lixel prediction network for accurate 3d human pose and mesh estimation from a single rgb image[C]. In ECCV, 2020: 752-768.

[18] Li J, Xu C, Chen Z, et al. Hybrik: A hybrid analytical-neural inverse kinematics solution for 3d human pose and shape estimation[C]. In CVPR, 2021: 3383-3393.

[19] Lin K, Wang L, Liu Z. End-to-end human pose and mesh reconstruction with transformers[C]. In CVPR, 2021: 1954-1963.

NSFC2024

[20] Lin K, Wang L, Liu Z. Mesh graphormer[C]. In ICCV, 2021: 12939-12948.
[21] Zhang H, Tian Y, Zhou X, et al. Pymaf: 3d human pose and shape regression with pyramidal mesh alignment feedback loop[C]. In ICCV, 2021: 11446-11456.
[22] Li Z, Liu J, Zhang Z, et al. Cliff: Carrying location information in full frames into human pose and shape estimation[C]. In ECCV, 2022: 590-606.
[23] Cho J, Youwang K, Oh T H. Cross-attention of disentangled modalities for 3d human mesh recovery with transformers[C]. In ECCV, 2022: 342-359.
[24] Yao C H, Yang J, Ceylan D, et al. Learning visibility for robust dense human body estimation[C]. In ECCV, 2022: 412-428.
[25] Arnab A, Doersch C, Zisserman A. Exploiting temporal context for 3D human pose estimation in the wild[C]. In CVPR, 2019: 3395-3404.
[26] Kanazawa A, Zhang J Y, Felsen P, et al. Learning 3d human dynamics from video[C]. In CVPR, 2019: 5614-5623.
[27] Sun Y, Ye Y, Liu W, et al. Human mesh recovery from monocular images via a skeleton-disentangled representation[C]. In CVPR, 2019: 5349-5358.
[28] Kocabas M, Athanasiou N, Black M J. Vibe: Video inference for human body pose and shape estimation[C]. In CVPR, 2020: 5253-5263.
[29] Choi H, Moon G, Chang J Y, et al. Beyond static features for temporally consistent 3d human pose and shape from a video[C]. In CVPR, 2021: 1964-1973.
[30] Wan Z, Li Z, Tian M, et al. Encoder-decoder with multi-level attention for 3d human shape and pose estimation[C]. In ICCV, 2021: 13033-13042.
[31] Wei W L, Lin J C, Liu T L, et al. Capturing humans in motion: Temporal-attentive 3D human pose and shape estimation from monocular video[C]. In CVPR, 2022: 13211-13220.
[32] Zeng A, Yang L, Ju X, et al. Smoothnet: A plug-and-play network for refining human poses in videos[C]. In ECCV, 2022: 625-642.
[33] Press W H, Teukolsky S A. Savitzky-Golay smoothing filters[J]. In CIP, 1990, 4(6): 669-672.
[34] Simon E, Bertino L. Gaussian anamorphosis extension of the DEnKF for combined state parameter estimation: Application to a 1D ocean ecosystem model[J]. In J MARINE SYST, 2012, 89(1): 1-18.
[35] Hohmeyer K, Wolff J. A fistful of euros: Is the German one-euro job workfare scheme effective for participants?[J].In Int J Soc Welf, 2012, 21(2): 174-185.
[36] Sun K, Xiao B, Liu D, et al. Deep high-resolution representation learning for human pose estimation[C]. In CVPR, 2019: 5693-5703.
[37] Cheng B, Xiao B, Wang J, et al. Higherhrnet: Scale-aware representation learning for bottom-up human pose estimation[C]. In CVPR, 2020: 5386-5395.
[38] Fang H S, Li J, Tang H, et al. Alphapose: Whole-body regional multi-person pose estimation and tracking in real-time[J]. In TPAMI, 2022, 45(6): 7157-7173.
[39] Newell A, Yang K, Deng J. Stacked hourglass networks for human pose estimation[C]. In ECCV, 2016: 483-499.
[40] Xiao Y, Wang X J, Yu D, et al. Adaptivepose: Human parts as adaptive points[C]. In AAAI, 2022 36(3): 2813-2821.
[41] Kreiss S, Bertoni L, Alahi A. Pifpaf: Composite fields for human pose estimation[C]. In CVPR, 2019: 11977-11986.
[42] Ci H, Wu M, Zhu W, et al. Gfpose: Learning 3d human pose prior with gradient fields[C]. In CVPR, 2023: 4800-4810.

NSFC 2024

[43] Rempe D, Birdal T, Hertzmann A, et al. Humor: 3d human motion model for robust pose estimation[C]. In ICCV, 2021: 11488-11499.

[44] Ling H Y, Zinno F, Cheng G, et al. Character controllers using motion vaes[J]. In TOG, 2020, 39(4): 40: 1-40: 12.

[45] Zhao J, Li J, Cheng Y, et al. Understanding humans in crowded scenes: Deep nested adversarial learning and a new benchmark for multi-human parsing[C]. In ACM MM, 2018: 792-800.

[46] Li J, Zhao J, Wei Y, et al. Towards real world human parsing: Multiple-human parsing in the wild[J]. arXiv preprint arXiv:1705.07206, 2017: 3193-3202..

[47] ZHOU T, WANG W, LIU S, et al. Differentiable Multi-Granularity Human Representation Learning for Instance-Aware Human Semantic Parsing[C]. In CVPR, Nashville, TN, USA. 2021.

[48] GONG K, LIANG X, LI Y, et al. Instance-level Human Parsing via Part Grouping Network[C]. In LNCS, 2018: 805-822.

[49] YANG L, SONG Q, WANG Z, et al. Parsing R-CNN for Instance-Level Human Analysis[C]. In CVPR, Long Beach, CA, USA. 2019.

[50] YANG L, SONG Q, WANG Z, et al. Renovating Parsing R-CNN for Accurate Multiple Human Parsing[C].In LNCS, 2020: 421-437.

[51] ZHANG S, CAO X, QI G J, et al. AIParsing: Anchor-free Instance-level Human Parsing[J]. In TIP, 2022.

[52] LI P, XU Y, WEI Y, et al. Self-Correction for Human Parsing.[J]. In TPAMI, 2022: 3260-3271.

[53] Ruan T, Liu T, Huang Z, et al. Devil in the details: Towards accurate single and multiple human parsing[C]. In AAAI, 2019, 33(01): 4814-4821.

[54] JI R, DU D, ZHANG L, et al. Learning Semantic Neural Tree for Human Parsing[J]. arXiv preprint arXiv, 2019.

[55] Chu J, Jin L, Fan X, et al. Single-Stage Multi-human Parsing via Point Sets and Center-based Offsets[C].In ACM MM, 2023: 1863-1873.

[56] Dai Y, Chen X, Wang X, et al. ReSParser: Fully Convolutional Multiple Human Parsing with Representative Sets[J]. In TMM, 2023.

[57] WANG D, ZHANG S. Contextual Instance Decoupling for Instance-Level Human Analysis[J]. In TPAMI , 2023, 45:8.

[58] KIRILLOV A, MINTUN E, RAVI N, et al. Segment Anything[C]. In ICCV, 2023.

[59] ZOU X, DOU Z Y, YANG J, et al. Generalized Decoding for Pixel, Image, and Language[C]. In CVPR, 2023.

[60] LIU S, ZENG Z, REN T, et al. Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection[J]. arXiv preprint arXiv:2303.05499 , 2023.

[61] SUN P, CHEN S, ZHU C, et al. Going Denser with Open-Vocabulary Part Segmentation[C]. In ICCV, 2023.

[62] Boykov Y Y, Jolly M P. Interactive graph cuts for optimal boundary & region segmentation of objects in ND images[C]. In ICCV, 2001.

[63] Grady L. Random walks for image segmentation[J]. In TPAMI, 2006, 28(11): 1768-1783.

[64] Gulshan V, Rother C, Criminisi A, et al. Geodesic star convexity for interactive image segmentation[C]. In CVPR, 2010: 3129-3136.

[65] Rother C, Kolmogorov V, Blake A. " GrabCut" interactive foreground extraction using iterated graph cuts[J]. In TOG, 2004, 23(3): 309-314.

[66] Chen X, Zhao Z, Zhang Y, et al. Focalclick: Towards practical interactive image segmentation[C] In CVPR, 2022: 1300-1309.

NSFC 2024

[67] Lin Z, Duan Z P, Zhang Z, et al. Focuscut: Diving into a focus view in interactive segmentation[C] In CVPR, 2022: 2637-2646.

[68] Sofiiuk K, Petrov I A, Konushin A. Reviving iterative training with mask guidance for interactive segmentation[C]. In ICIP, 2022: 3141-3145.

[69] Xu N, Price B, Cohen S, et al. Deep grabcut for object selection[J]. arXiv preprint arXiv:1707.00243, 2017.

[70] Xu N, Price B, Cohen S, et al. Deep interactive object selection[C]. In CVPR, 2016: 373-381.

[71] Acuna D, Ling H, Kar A, et al. Efficient interactive annotation of segmentation datasets with polygon-rnn++[C]. In CVPR, 2018: 859-868.

[72] Wu J, Zhao Y, Zhu J Y, et al. Milcut: A sweeping line multiple instance learning paradigm for interactive image segmentation[C]. In CVPR, 2014: 256-263.

[73] Liu Q, Zheng M, Planche B, et al. PseudoClick: Interactive image segmentation with click imitation[C]. In ECCV, 2022: 728-745.

[74] Maninis K K, Caelles S, Pont-Tuset J, et al. Deep extreme cut: From extreme points to object segmentation[C]. In CVPR, 2018: 616-625.

[75] Lin Z, Zhang Z, Chen L Z, et al. Interactive image segmentation with first click attention[C]. In CVPR, 2020: 13339-13348.

[76] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers[J]. In NeurIPS, 2021, 34: 12077-12090.

[77] Liu Q, Xu Z, Jiao Y, et al. iSegFormer: interactive segmentation via transformers with application to 3D knee MR images[C]. In MICCAI, 2022: 464-474.

[78] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. In ICCV, 2021: 10012-10022.

[79] Gu J, Kwon H, Wang D, et al. Multi-scale high-resolution vision transformer for semantic segmentation[C]. In CVPR, 2022: 12094-12103.

[80] Khan S, Naseer M, Hayat M, et al. Transformers in vision: A survey[J]. In CSUR, 2022, 54(10s): 1-41.

[81] Strudel R, Garcia R, Laptev I, et al. Segmenter: Transformer for semantic segmentation[C]. In CVPR, 2021: 7262-7272.

[82] Yuan Y, Fu R, Huang L, et al. Hrformer: High-resolution vision transformer for dense predict[J]. In NeurIPS, 2021, 34: 7281-7293.

[83] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv 2020[J]. arXiv preprint arXiv:2010.11929, 2010.

[84] Zheng S, Lu J, Zhao H, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers[C]. In CVPR, 2021: 6881-6890.

[85] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners[C]. In CVPR, 2022: 16000-16009.

[86] Chen W, Du X, Yang F, et al. A simple single-scale vision transformer for object localization and instance segmentation[J]. arXiv preprint arXiv:2112.09747, 2021.

[87] Li Y, Mao H, Girshick R, et al. Exploring plain vision transformer backbones for object detection[C]. In ECCV, 2022: 280-296.

[88] Li Z, Chen Q, Koltun V. Interactive image segmentation with latent diversity[C]. In CVPR, 2018: 577-585.

[89] Jang W D, Kim C S. Interactive image segmentation via backpropagating refinement scheme[C]. In CVPR, 2019: 5297-5306.

NSFC 2024

[90] Chen X, Zhao Z, Yu F, et al. Conditional diffusion for interactive segmentation[C]. In CVPR, 2021: 7345-7354.
[91] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. In NeurIPS, 2020, 33: 1877-1901.
[92] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.
[93] Bai Y, Geng X, Mangalam K, et al. Sequential modeling enables scalable learning for large vision models[J]. arXiv preprint arXiv:2312.00785, 2023.
[94] Wang Y, Li K, Li Y, et al. Internvideo: General video foundation models via generative and discriminative learning[J]. arXiv preprint arXiv:2212.03191, 2022.
[95] Wang L, Huang B, Zhao Z, et al. VideoMAE V2: Scaling Video Masked Autoencoders with Dual Masking Supplementary Material[J].
[96] Gan Y, Park S, Schubert A, et al. InstructCV: Instruction-Tuned Text-to-Image Diffusion Models as Vision Generalists[J]. arXiv preprint arXiv:2310.00390, 2023.
[97] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. In NeurIPS, 2017, 30.
[98] Hong W, Ding M, Zheng W, et al. Cogvideo: Large-scale pretraining for text-to-video generation via transformers[J]. arXiv preprint arXiv:2205.15868, 2022.
[99] Carreira J, Zisserman A. Quo vadis, action recognition? a new model and the kinetics dataset[C].In CVPR, 2017: 6299-6308.
[100] Wang X, Girshick R, Gupta A, et al. Non-local neural networks[C]. In CVPR, 2018: 7794-7803.
[101] Feichtenhofer C, Fan H, Malik J, et al. Slowfast networks for video recognition[C]. In ICCV, 2019: 6202-6211.
[102] Feichtenhofer C. X3d: Expanding architectures for efficient video recognition[C]. In CVPR, 2020: 203-213.
[103] Bertasius G, Wang H, Torresani L. Is space-time attention all you need for video understanding?[C]. In ICML. 2021, 2(3): 4.
[104] Liu Z, Ning J, Cao Y, et al. Video swin transformer[C]. In CVPR, 2022: 3202-3211.
[105] Fan H, Xiong B, Mangalam K, et al. Multiscale vision transformers[C]. In ICCV, 2021: 6824-6835.
[106] Farha Y A, Gall J. Ms-tcn: Multi-stage temporal convolutional network for action segmentation[C]. In CVPR, 2019: 3575-3584.
[107] Li S J, AbuFarha Y, Liu Y, et al. Ms-tcn++: Multi-stage temporal convolutional network for action segmentation[J]. In TPAMI, 2020.
[108] Wang Z, Gao Z, Wang L, et al. Boundary-aware cascade networks for temporal action segmentation[C]. In ECCV, 2020: 34-51.
[109] Singhania D, Rahaman R, Yao A. Coarse to fine multi-resolution temporal convolutional network[J]. arXiv preprint arXiv:2105.10859, 2021.
[110] Gao S H, Han Q, Li Z Y, et al. Global2local: Efficient structure search for video action segmentation[C]. In CVPR, 2021: 16805-16814.
[111] Wang D, Hu D, Li X, et al. Temporal relational modeling with self-supervision for action segmentation[C]. In AAAI, 2021, 35(4): 2729-2737.
[112] Yi F, Wen H, Jiang T. Asformer: Transformer for action segmentation[J]. arXiv preprint arXiv:2110.08568, 2021.
[113] Liu X, Hu Y, Bai S, et al. Multi-shot temporal event localization: a benchmark[C]. In CVPR, 2021: 12596-12606.

NSFC 2024

[114] Ren Y, Xu X, Shen F, et al. Multi-scale dynamic network for temporal action detection[C]. In ICMR , 2021: 267-275.

[115] Ren Y, Xu X, Shen F, et al. CAA: Candidate-Aware Aggregation for Temporal Action Detection[C]. In ACM MM, 2021: 4930-4938.

[116] Xu M, Zhao C, Rojas D S, et al. G-tad: Sub-graph localization for temporal action detection[C]. In CVPR, 2020: 10156-10165.

[117] Zeng R, Huang W, Tan M, et al. Graph convolutional networks for temporal action localization[C]. In ICCV, 2019: 7094-7103.

[118] Lin T, Zhao X, Su H, et al. Bsn: Boundary sensitive network for temporal action proposal generation[C]. In CVPR, 2018: 3-19.

[119] Lin T, Zhao X, Su H, et al. Bsn: Boundary sensitive network for temporal action proposal generation[C]. In ECCV, 2018: 3-19.

[120] Liu X, Wang Q, Hu Y, et al. End-to-end temporal action detection with transformer[J]. In TIP, 2022, 31: 5427-5441.

[121] Shi D, Zhong Y, Cao Q, et al. React: Temporal action detection with relational queries[C]. In ECCV, 2022: 105-121.

[122] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]. In ECCV, 2020: 213-229.

[123] Zhang C L, Wu J, Li Y. Actionformer: Localizing moments of actions with transformers[C]. In ECCV, 2022: 492-510.

[124] Shi D, Cao Q, Zhong Y, et al. Temporal action localization with enhanced instant discriminability[J]. arXiv preprint arXiv:2309.05590, 2023.

[125] Parmar P, Morris B T. What and how well you performed? a multitask learning approach to action quality assessment[C]. In CVPR, 2019: 304-313.

[126] Yu X, Rao Y, Zhao W, et al. Group-aware contrastive regression for action quality assessment[C].In ICCV, 2021: 7919-7928.

[127] Zhang B, Chen J, Xu Y, et al. Auto-encoding score distribution regression for action quality assessment[J]. In Neural. Comput. Appl, 2023: 1-14.

[128] Agbaje A O, Perng W, Tuomainen T P. Effects of accelerometer-based sedentary time and physical activity on DEXA-measured fat mass in 6059 children[J]. In Nat. Commun. , 2023, 14(1): 8232.

NSFC 2024

2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）；

2.1 研究内容

本项目针对基于计算机视觉的人体运动分析、人体解析、人体行为理解等技术进行系统化探究，研究其在智能主动健康场景中的综合应用。以实现**人体运动感知理解技术与主动健康应用深度适配**为目标，关注**运动感知模型性能要求高、运动理解内容复杂任务难、个体间体质及需求差异大**的挑战，围绕**探究算法输出与相应任务状态之间映射机理**的科学问题，构建**面向主动健康应用的智能服务系统**，根据不同个体体适能不同定制个性化运动处方，并结合高性能算法实现全周期健康管理。拟从四个方面展开研究（图 2）：研究点 1 关注于人体运动分析问题，基于姿态辅助生成多场景运动视频数据，为本项目提供数据基础，并构建姿态知识库优化姿态估计算法的输出序列，为本项目提供关键点级别的人像感知信息；研究点 2 进一步细化至像素级感知，研究面向复杂场景的人体解析算法，并引入主动交互信息辅助，为本项目提供人体体型信息；研究点 3 建立在前两个研究点的感知基础上，实现从感知到理解，对实际应用中的人体运动进行分析理解，从而实现定位、识别、评估、运动建议等功能；研究点 4 为前面研究点与全周期健康管理提供系统应用基础，运动前结合体适能分析结果，为不同个体定制个性化运动处方，运动中提供运动辅助引导，运动后提供运动分析，并根据运动成效更新运动处方，完成闭环反馈，进而为综合提升国民体质健康水平提供新模式。

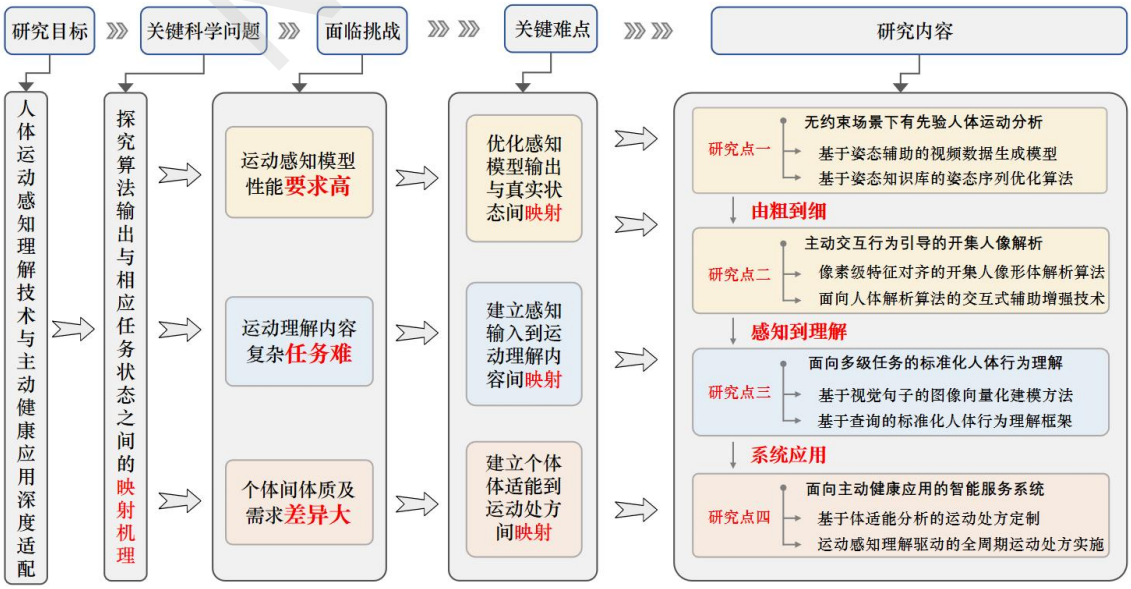


图 2 研究内容框图

2.1.1 无约束场景下有先验人体运动分析

由于智能化主动健康中人体运动分析具有场景多样、姿态识别精度要求高、人体姿态重复率高的特点，本研究点旨在降低计算复杂度以及设备硬件要求的同时，提升面向主动健康场景的人体运动分析精度。针对主动健康应用中无约束场景下的人体姿态估计任务，拟设计生成模型生成大量姿态相似、背景丰富、带标签的人体姿态识别训练数据，为本项目提供数据基础。针对实际应用中的时序姿态抖动问题，拟根据采集的人体姿态搭建基于向量搜索的先验姿态知识库，为人体运动姿态序列优化提供相似姿态作为先验。具体研究点如下：

（1）**基于姿态辅助的视频数据生成模型**：针对实际应用中人体运动环境复杂多样的特点，拟设计基于姿态辅助的视频数据生成模型，生成大量多场景人体动作视频训练数据。首先将多场景下的输入图像通过 VAE 和 CLIP 分别进行特征提取，并将输入姿态序列同样编码生成特征，之后进行特征融合、噪声添加、网络降噪进而生成视频，视频内容为输入图像中的人物按照输入姿态进行运动，从而为人体姿态估计网络提供多场景的数据增强，提高其在无约束场景下的识别精度。

（2）**基于姿态知识库的姿态序列优化算法**：由于拥挤、遮挡、光照等外部因素，识别到的时序人体姿态序列通常存在抖动或偏移等误差，拟构建基于向量搜索的先验姿态知识库为解决误差提供相似的参考姿态序列，将输入姿态序列与相似姿态序列在自注意力网络中分别进行独立的局部编码和相互关联的全局编码，使得输入姿态与库内样本形成参照进而实现序列优化。此外，优化过的姿态序列可以根据网络评分来决定是否添加到先验姿态知识库中，完成闭环在线学习，最终实现轻量化姿态序列优化。

2.1.2 主动交互行为引导的开集人体解析

针对主动健康对人体进行长期动态健康跟踪的需求，本研究点拟设计一种主动交互行为引导的开集人体解析算法，利用便携设备上的 RGB 摄像机和触摸屏实现对人像形体的解析、评价和记录。由于长期动态健康跟踪的高使用频次、应用环境多变等特点，高性能的人体解析算法需要同时兼顾轻量化与精准度，还应具备面向开放世界的能力。此外，实际应用中往往需要满足用户交互需求，并且常规的人体解析算法是对全身进行解析，可能造成计算冗余，降低解析效率，因此，拟提出交互式辅助增强技术，利用便携设备采集用户点击行为实现对指定部位的人体解析和评估记录，进一步减少计算量，提高运行效率，满足用户特定需求，为主动健康应用中其他模块提供长期准确的数据支持。具体研究点如下：

（1）**像素级特征对齐的开集人像形体解析算法**：针对主动健康应用中对像素级人像感知信息获取与用户形体跟踪分析的需求，拟开发一种像素级特征对齐的开集人体解析算法。该算法拟通过 RGB 摄像头获取用户图像，并增加文本数据，利用视觉-文本特征对齐实现开放环境下的像素级人体解析。该开集训练方式包括

实例感知的像素表征学习、多模态相关性度量学习和基于开集语义的特征对齐，利用文本特征空间的强鲁棒性特点提升模型在无约束场景的鲁棒性和泛化性，保证其在复杂多变的现实场景中能够不受背景、着装等外在因素干扰。

（2）**面向人体解析算法的交互式辅助增强技术**：针对现有模型对交互性利用不足的缺点，拟设计一种面向人体解析算法的交互式辅助增强技术，采用基于 ViT 的主干网络作为视觉编码器、特征金字塔和轻量级 MLP 解码器，以实现高效的多尺度特征提取和图像分割。此外，用户通过点击来提供指导信息，这些点击将被编码为双通道映射，还能够与之前的分割结果共同作为网络输入，以进一步改善分割结果。整体设计通过在 ViT 主干上进行轻微调整，以最小的改动成本实现交互式分割，充分利用预训练权重，从而提升人体解析算法的实用性和高效性。

2.1.3 面向多级任务的标准化人体行为理解

主动健康运动完成后需要准确及时识别人体行为并进行评价反馈，实现从感知到理解，本研究点旨在设计高效的标准化人体行为理解框架。针对人体运动视频具有数据规模庞大、场景复杂多样、帧间冗余性高的特点，拟设计一种基于视觉句子的图像向量化建模方法，实现面向视频的高效强泛化逐帧特征提取。针对人体行为理解相关应用任务目标多级化且模型结构复杂多样的特点，拟设计一个基于查询的标准化人体行为理解框架，通过调整查询类别对人体行为进行分析，从而实现面向不同任务目标输出不同结果，为主动健康应用中的多级任务提供统一化技术基础。具体研究点如下：

（1）**基于视觉句子的图像向量化建模方法**：针对人体运动视频场景复杂、冗余度高的特点，首先拟提出一个基于视觉句子的数据标准化方法，然后收集现有人体动作的图像、视频等数据，构建一个大规模多模态混合视觉数据集。由于不同模态数据复杂多样的特点，设计一个预训练视觉模型进行图像向量化建模，为从不同角度捕捉鲁棒的视觉表示拟采用混合向量编码器结构。最后，结合标准化视觉数据，通过预训练即可得到一个高效率、强泛化能力的视觉编码器，从而有效提高下游子任务模型的性能上限。

（2）**基于查询的标准化人体行为理解框架**：当前人体行为理解应用的相关任务目标各不相同，相应设计的模型也变化多样，缺乏通用性，拟构建一个基于查询的标准化人体行为理解框架，不同任务共享特征提取器，实现跨任务优化。针对不同任务的需求，调整查询类别，并通过一个统一的解码器模块输出对应的结果。该标准化框架能够有效降低多个子任务模型的设计成本，降低网络复杂度与参数量，并通过多任务联合优化实现更高的性能。

2.1.4 面向主动健康应用的智能服务系统

主动健康实际应用覆盖运动全流程，从运动前的基于体适能的运动处方制定，

到运动中的规定动作引导及辅助，再到运动后的动作评估反馈以及后期体质健康监控，本研究点旨在解决智能化主动健康服务系统的研制与应用。针对个体因年龄、职业、慢性病等因素不同而导致的体质状况不同，本研究点拟提出基于体适能分析的运动处方定制，实现对不同个体不同运动需求的个性化运动处方推荐。针对运动前中后全周期主动健康管理与智能化技术如何有效结合问题，本研究点拟提出运动感知理解驱动的全周期运动处方实施，形成用户体质健康跟踪机制，提高其健康意识与自我管理行为。具体研究点如下：

（1）**基于体适能分析的运动处方定制**：针对不同人群因年龄、职业、慢性病等因素带来的身体素质差异，首先制定相应的体适能评估方法，然后，拟构建面向不同年龄段、区分健身与医疗目标属性的运动处方库，根据不同个体体型数据、体适能评估结果以及是否存在慢性病，定制个性化的运动处方，保证不同个体的运动处方与运动能力、自身需求相匹配。

（2）**运动感知理解驱动的全周期运动处方实施**：为保障对个体的运动处方实施全周期进展跟踪，拟采用运动感知与理解技术驱动个体运动辅助反馈，设计运动处方实施与智能技术结合的应用实例，实现基于人体解析的体型检测、基于运动姿态分析的运动辅助、基于动作理解的总结反馈等系统功能，通过对个体运动前中后全周期保障，动态调整运动计划，综合提升其体质健康水平。

2.2 研究目标

本项目面向后疫情时代提升国民体质健康水平的国家发展战略，以主动健康理念和人体运动感知与理解技术为牵引，从运动分析、人体解析、行为理解、运动处方四个方面解决人体运动健康全周期管理问题，**以实现人体运动感知理解技术与主动健康应用深度适配为总体目标**，搭建主动健康智能服务系统。

（1）针对实际应用中无约束场景下人体姿态识别精度难以保障且关键点易抖动的问题，设计基于姿态辅助的视频数据生成模型，从而为本项目提供大量多场景的训练数据，提升模型鲁棒性。根据运动姿态存在重复的特性，构建姿态知识库，基于姿态相似性设计姿态序列优化算法，对姿态估计算法的输出结果进行模型未知的轻量后处理优化，进而实现高精度且高效的人体运动分析。

（2）针对主动健康应用中人像形体细粒度信息感知任务中存在的不同着装以及复杂背景干扰的问题，设计特征对齐的开集人体解析算法，将文本信息与像素信息进行对齐，增强算法鲁棒性，并提出交互式辅助增强技术，在提升系统交互性的同时，结合点击辅助信息提高对人体特定部位的解析精度。

（3）针对如何分析主动健康运动完成情况、形成运动建议、闭环反馈更新运动处方的难题，即实现感知到理解，提出面向多级任务的标准化人体行为理解框架，首先基于视觉句子的方法对视觉数据标准化，设计混合视觉编码器并利用大规模视觉数据对编码器进行预训练，优化特征提取，提升模型性能上限。然后，设计基于查询的标准化人体行为理解框架，能够根据不同查询输出不同类型结果，

从而对不同任务的解码器完成统一化，实现跨任务优化，增强模型理解能力。

（4）针对不同年龄、职业、慢性病等因素导致的个体差异，建立运动处方库，设计基于体适能分析的运动处方定制策略，为不同个体根据体质与需求不同推荐个性化运动处方，并结合运动感知与理解算法保障运动处方全周期实施，包括运动前的体适能评估与运动处方制定、运动中的动作引导与辅助、运动后的运动建议与总结反馈，搭建面向主动健康的智能服务系统。

2.3 拟解决的科学问题

本项目从主动健康角度出发，挖掘人工智能技术在提升国民体质健康相关应用的业务难点，形成面向主动健康的高性能人体运动感知与理解技术，建立各年龄段的体适能评估标准与运动处方库。项目涉及到多种算法输出，需要将输出结果和主动健康应用中相关状态匹配，例如，体型参数、运动评估结果、运动建议等。**在主动健康智能应用中探究算法输出与相应任务状态之间的映射机理，实现算法与实际应用的适配是本项目需要解决的关键科学问题。**本项目围绕一个关键科学问题展开，在研究过程中针对不同研究内容细分为以下几个关键难点：

（1）**优化感知模型输出与真实状态间的映射：**智能主动健康服务中的人体信息感知是一项高精度、高效率需求任务，因此针对通用的感知模型，需要优化在应用场景以及特定需求下模型的输出结果与真实状态间的映射。然而，无论是粗粒度/关键点级的人体姿态识别还是细粒度/像素级的人体体型解析均需要解决无约束场景中存在的复杂背景、着装、光照等多种因素干扰问题。如何在计算资源受限且有实时性需求的情况下，提升算法精准度；如何利用运动视频动作重复且相似等特点，增强模型性能，是本项目需要解决的一个关键难点。

（2）**建立感知到理解间的映射：**本项目不仅仅局限于对人体运动的感知，还需要在个体完成主动健康运动后，分析指定动作完成情况，并提供运动评估和总结反馈。因此必须基于传感器和模型感知到的信息，与相应动作理解内容建立映射，实现感知上升到理解。如何针对时间长、帧间冗余度高的视频进行高效特征提取，并控制特征维度减少计算复杂度；如何面向不同的人体行为理解任务目标实现模型统一化，从而相互促进、协同优化，构建由感知到理解的标准化范式是本项目需要解决的一个关键难点。

（3）**建立个体体适能到运动处方间的映射：**本项目针对不同个体体适能差异以及不同的运动诉求，智能化推荐专业运动处方，从而实现提升国民体质体能的目标，因此需要建立体适能分析结果与运动处方间的映射。如何评估不同年龄段人群体适能，并根据体适能分析结果有针对性地进行提升，制定个性化运动处方；如何利用人体运动感知与理解算法对个体在运动前中后全周期保障，根据运动成效，闭环反馈调整运动处方，设计基于体适能分析的运动处方定制并保障全周期实施是本项目需要解决的一个关键难点。

3. 拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）；

3.1 研究方案

3.1.1 无约束场景下有先验人体运动分析

本项目将基于人工智能的人体运动分析与主动健康的医学模式相结合，在慢性病情逆转、人体机能增强等需求下，为计算机视觉辅助的全生命周期健康管理提供研究基础。本研究点基于计算机视觉技术恢复出运动姿态序列，为后续的人体行为理解与体适能（Physical Fitness）分析提供**人体运动关键点级信息**。首先，本研究点针对当前人体姿态数据集环境单一、骨骼点格式不统一、数据标注难度大等问题，拟提出**基于姿态辅助的视频数据生成模型**，仅使用姿态序列以及丰富场景中的人体照片来生成人体运动视频，为本项目在无约束场景下人体运动姿态序列识别网络的训练以及其他研究点（人体解析、人体行为理解）提供多场景的合成数据支撑。此外，由于受到人体关节约束，人体运动姿态数据往往分布集中、具有较强的先验知识，本项目提出利用**基于向量数据查询的姿态知识库来优化识别到的人体运动姿态序列**，使用相似的人体姿态来修复识别到的姿态序列，将高置信度的姿态序列加入到姿态知识库中，并结合在线学习的特性提高人体姿态序列识别的准确性。图 3 为整体流程框架。

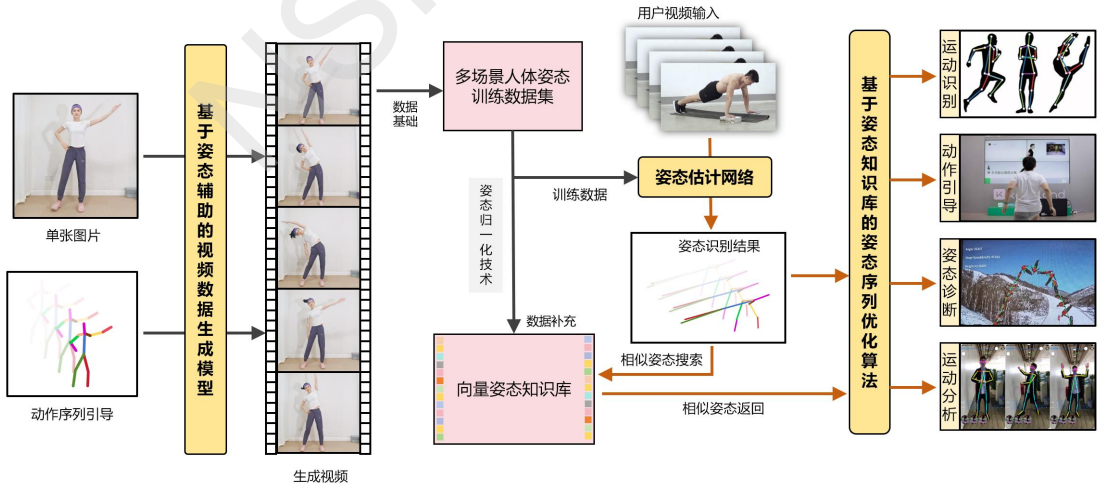


图 3 人体运动分析流程框架图

（1）基于姿态辅助的视频数据生成模型

主动健康相关应用场景通常是无约束的，并且其人体运动分析一般要考虑关节角度、绝对位置偏移等因素，因此需要解析 3D 姿态，而现有 3D 人体姿态数据

集场景单一、采集标注难度大。本研究点拟提出一种基于 3D 姿态辅助的视频数据生成模型，从而可以根据使用者上传的图片，生成大量带标签样本，用于提升模型检测精度和鲁棒性。

1）视频数据生成框架

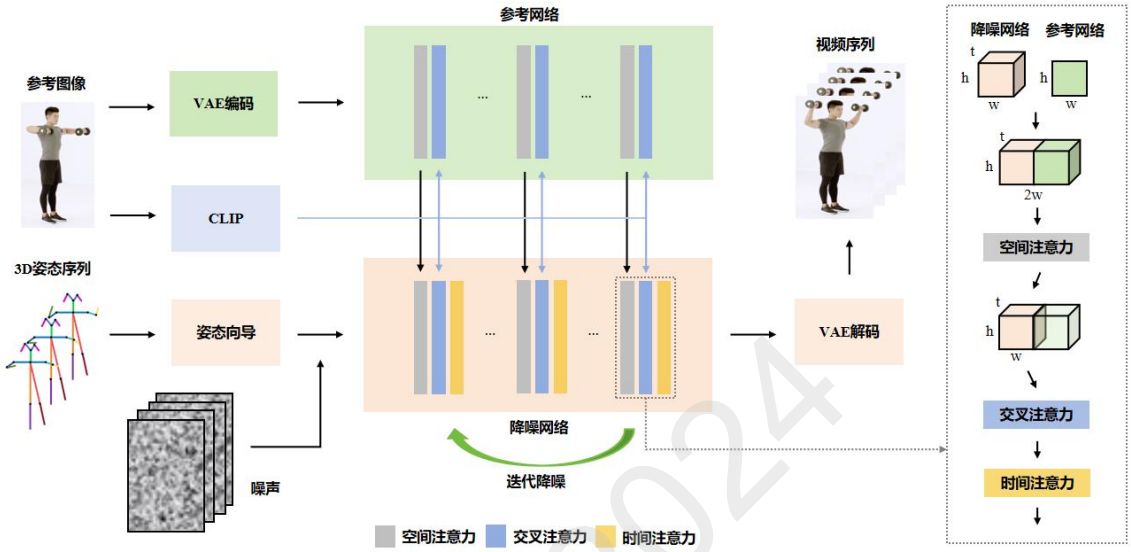


图 4 基于姿态辅助的视频数据生成模型

A. 整体框架

整体流程图如图 4 所示。拟采用基于注意力机制的视频生成模型。首先，将输入图像通过 VAE 和 CLIP 分别进行编码（即特征提取），然后将结果特征输入到参考网络（ReferenceNet）用来做空间注意力，通过 CLIP 得到的语义特征用来做交叉注意力，然后将交叉注意力出来的结果做时间注意力计算。对于下方的姿态序列，拟采用姿态向导模块来进行编码生成特征，然后将该特征与多帧噪声进行融合，形成加入噪声的新特征，然后将该特征送入到降噪网络（Denoising UNet）里面，最后将降噪网络的输出结果通过 VAE 解码器输出生成视频以及对应的 3D 姿态骨骼点标签。

B. 参考网络（ReferenceNet）设计

拟采用与降噪网络（Denoising UNet）相同的框架，但不包括时间层。类似于降噪网络，参考网络继承了原始 Stable diffusion 的权重，并且每个网络的权重更新是独立进行的。具体来说，如图 2 所示，用空间注意力层替换自注意力层。对于来自降噪网络的特征 x1 和来自参考网络的特征 x2。首先将 x2 复制 t 次，然后沿着 w 维度将其与 x1 拼接。然后，执行自注意力并提取特征图的前半部分作为输出。

C. 姿态向导模块设计

拟采用一个轻量级的姿势向导模块。该姿势向导模块利用四个卷积层（4×4 的卷积核，2×2 的步幅，使用 16、32、64、128 个通道，类似于 ControlNet 中的条件编码器）来将姿势图像与噪声潜在变量分辨率相同部分对齐。随后，将处理过

的姿势图像在输入降噪网络之前加到噪声潜在变量中。姿势向导模块使用高斯权重进行初始化，并在最后的投影层中采用零卷积。

D. 时序层设计

对于一个特征图 x，首先将其重塑为 x，然后执行时间注意力，即沿 t 维度的自注意力。时序层的特征通过残差连接合并到原始特征中。时序层仅在降噪网络的 Res-Trans 块中应用。对于参考网络，它为单个参考图像计算特征，并不参与时间建模。姿势向导模块实现连续角色移动的可控性，确保外观细节的时间平滑和连续性，消除对复杂运动建模的需求。

2）视频数据生成策略

A. 训练策略设计

拟设计两个阶段的训练过程。在第一阶段，使用单个视频帧进行训练。在去噪 UNet 中，暂时排除了时序层，模型以单帧噪声作为输入。ReferenceNet 和 Pose Guider 在这个阶段也在进行训练。参考图像是从整个视频剪辑中随机选择的。基于从 Stable Diffusion 预训练权重初始化去噪 UNet 和 ReferenceNet 的模型。Pose Guider 使用高斯权重进行初始化，除了最后的投影层使用零卷积。VAE 的编码器和解码器以及 CLIP 图像编码器的权重都保持不变。这个阶段的优化目标是使模型能够在给定参考图像和目标姿势的条件下生成高质量的动画图像。在第二阶段，将时序层引入先前训练好的模型，使用 AnimateDiff 的预训练权重进行初始化。模型的输入包括一个包含 24 帧的视频剪辑。此阶段只训练时序层，同时固定网络的其余权重。

B. 姿态视频数据生成方式

3D 姿态序列标签收集：3D 人体姿态数据集如 Human3.6M，CMU-MoCap，Aist++等包含大量多场景、多姿态的骨骼点序列，这些数据将为生成的人体动作视频带来多样性和鲁棒性。除此之外，针对主动健康场景的具体运动姿态，可以通过动作人员佩戴位置传感器采集完成，从而提高标签数据针对主动健康应用场景的精准性和专业性。

多场景图像数据收集：通过检测网络自动从互联网收集大量的姿态视频数据，包括多种人群的不同动作和姿态，以及各种现实环境和应用场景。为保证图像数据的多样性，使模型能够适应各种情况，本项目将采用 Phash 算法剔除相似图片，确保模型不会对单一场景出现过拟合失误。

数据增强：采集到的姿态标签数据可以通过仿射变换进行一定的数据增强，得到更多类型的标签数据。同样，图片数据也可以通过色彩、空间、明暗度的变换进行数据增强。两种数据可以通过人体姿态估计网络进行匹配和组合，进行下一步的动作视频生成。

动作视频生成：将采集数据通过视频生成算法网络进行推理，进而得到带有姿态标签的多场景下的人体动作视频，为主动健康应用中的人体姿态识别提供大量训练数据。

（2）基于姿态知识库的姿态序列优化算法

视频数据生成框架为人体姿态估计网络的训练提供了丰富的多场景训练数据，使得网络识别到的姿态序列在无约束场景下保持良好的准确率，而实际应用中，面向视频数据的姿态估计往往存在抖动问题，本研究点拟设计姿态序列优化算法在时间维度上进一步解决关键点抖动问题，优化预测出的人体姿态序列。

1）序列优化算法框架

姿态序列优化算法框架图如图 5 所示。姿态 1 被输入到姿态知识库中进行相似姿态的搜索，之后将输入姿态 1 和搜索姿态 2，3，4 一起输入到网络中，进行姿态序列优化并输出姿态 1 对应的优化序列，具体如下。

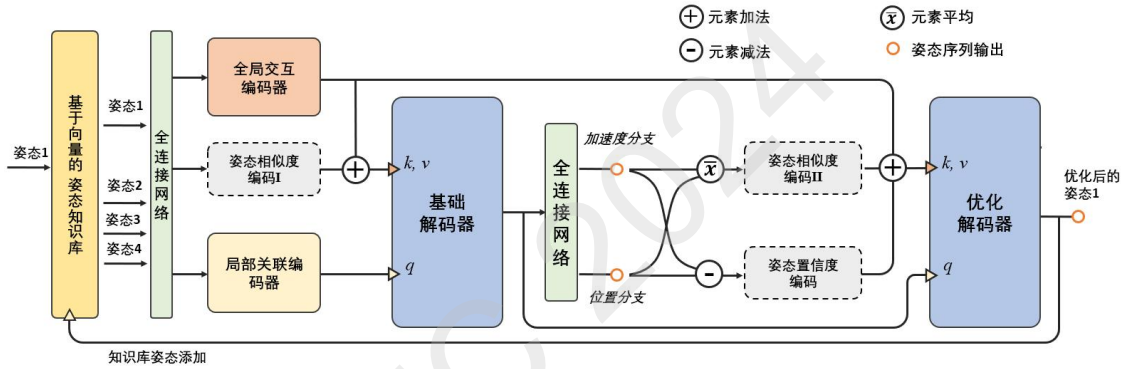


图 5 基于姿态知识库的姿态序列优化算法

A. 姿态知识库

首先，由姿态识别算法检测到的姿态 1 存在观察角度、观察距离、人体大小等差异，直接使用欧氏距离很难在有限的数据集中匹配到相似动作的姿态，然而使用神经网络对姿态进行动作理解又需要耗费大量的计算资源和推理时间。本研究点拟设计姿态归一化技术，利用模板姿态以及矩阵相似变换使得输入姿态的大小、角度向模板姿态靠拢，完成姿态知识库中姿态的归一化，进而根据此姿态数据完成向量搜索，得到搜索姿态 2，3，4。

B. 序列优化算法

其次，将得到的 4 个姿态序列分别通过全连接网络进行坐标到高维空间的映射，之后在基于 self-attention 技术的全局交互编码器和局部关联编码器中分别进行姿态 1，2，3，4 之间的动作互补学习以及姿态 1 的自我优化学习，其中姿态相似度编码 I 为知识库搜索返回的向量距离，旨在为动作互补学习提供相似度指引，最终，在解码器中解码得到分别偏向于平滑的加速度分支和偏向于位置准确度的位置分支。两个分支的输出差分可以进一步作为置信度编码，与再次计算的相似度编码 II 完成第二阶段的优化解码器解码，得到姿态 1 的优化序列以及对应的分数。最终根据分数决定是否将姿态 1 优化序列添加到姿态知识库中，进而完成在线学习框架，使得此序列优化算法拥有学习能力。

2）多骨骼点格式适应策略

上述的序列优化算法框架可以支持不同格式的骨骼点格式。如图 6 所示，在 AIST，MOCAP，H36M 数据集中，骨骼点数量依次为 14，31，17 个，虽然骨骼点格式不同，他们的姿态可能相似。多个格式的姿态序列只在骨骼点维度存在差异，在时间、空间维度是一致的，这为跨数据集训练提供了理论基础，多置信度格式骨骼点适应策略的具体实现如下。

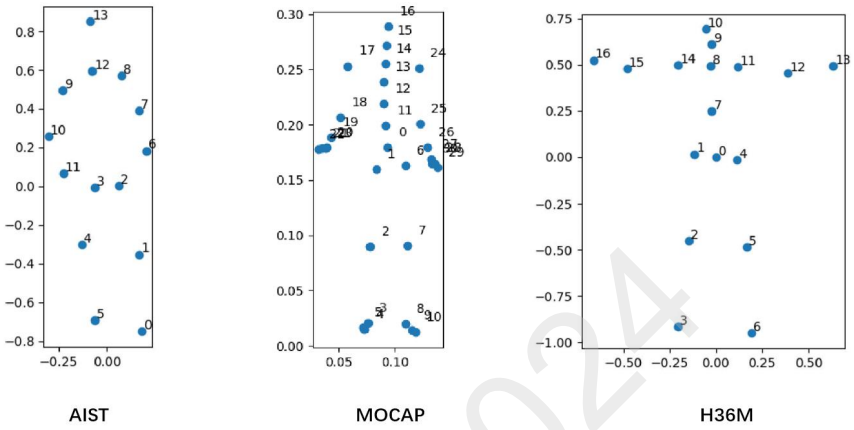


图 6 多数据集骨骼点示意图

A. 姿态归一化技术的多骨骼点格式适应策略

运动知识库的姿态归一化技术拟采用多个数据集中最少骨骼点的姿态格式，将输入的其他不同的骨骼点格式降维到统一的格式，方便进行相似姿态搜索。最终，运动知识库将向网络模块输入多个数据集原格式的姿态序列。

B. 神经网络的多骨骼点格式适应策略

如何在序列优化算法中处理不同骨骼点格式的姿态序列是研究难点之一。首先，算法中的全连接网络只处理时空维度，关注于每个骨骼点在空间中的运动，而不关注此骨骼点在人体中代表的意义，避免引入动态的骨骼点数量。其次，基于 self-attention 的编码器、解码器可以接受动态数量的骨骼点数，但是它没办法区分每个骨骼点代表的意义，本研究点拟提出骨骼点语义编码来给予骨骼点自身的意义，使得编码器、解码器可以进行对整体姿态的思考和处理，进而使得算法适应多种骨骼点格式。

3.1.2 主动交互行为引导的开集人体解析

实际运动医疗场景中，算法满足**交互需求**可以进一步提升其实用性和性能，例如用户指示重点关注的身体部位或提供额外辅助信息增强感知精准度，从而实现对用户提供更全面的健康管理。首先，本研究点拟采用主动交互行为引导的开集人体解析技术完成**像素级的人体特征信息感知**，为运动分析、体态监测等应用提供形体感知信息。拟利用 RGB 摄像头采集人体图像，通过**开集人体解析算法**细粒度解析人体各部位形态变化，包括面部、躯干、四肢等，从而为深入理解用户体态信息提供精准数据支持。由于实际生活环境多变且多样，采用多模态数据使得

人体解析算法面向开放环境时具备强大的稳健性，不受环境变化和个体衣着特点的干扰，适用于不同场景。因此，本研究点拟引入**主动交互行为的先验性信息**增加新的输入数据模态，提高解析效率。这一技术的优势在于丰富全面体态评估所需的数据基础，同时具备环境适应性、稳健性和高效性，使其更适用于实际应用中多样化的交互情境。图 7 为整体技术框架：

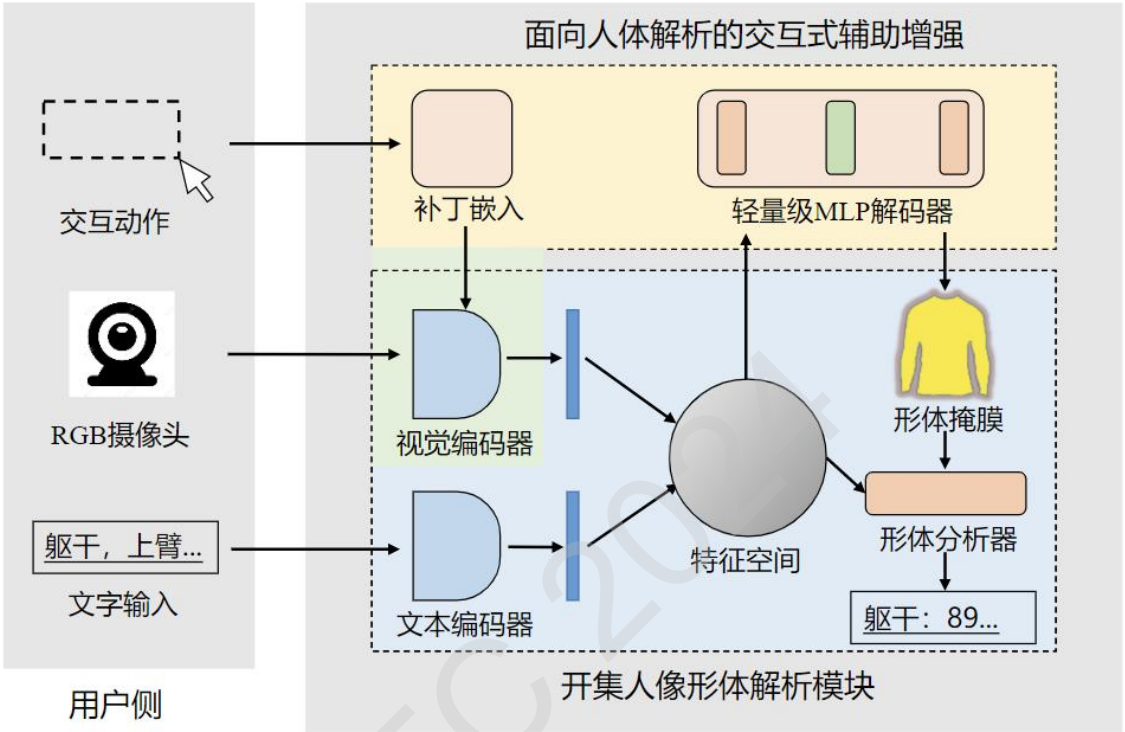


图 7 主动交互行为引导的开集人体解析技术框架

（1）像素级特征对齐的开集人像形体解析算法

针对用户形体跟踪分析问题，基于 RGB 摄像头采集到的用户个体图像，通过引入文本数据，令模型在开放环境下也能准确稳定地像素级解析人体体态图像，从而排除不同着装、背景的干扰，因此本研究点拟设计如图 8 网络模型以端到端的形式输出用户个体的人像形体解析。

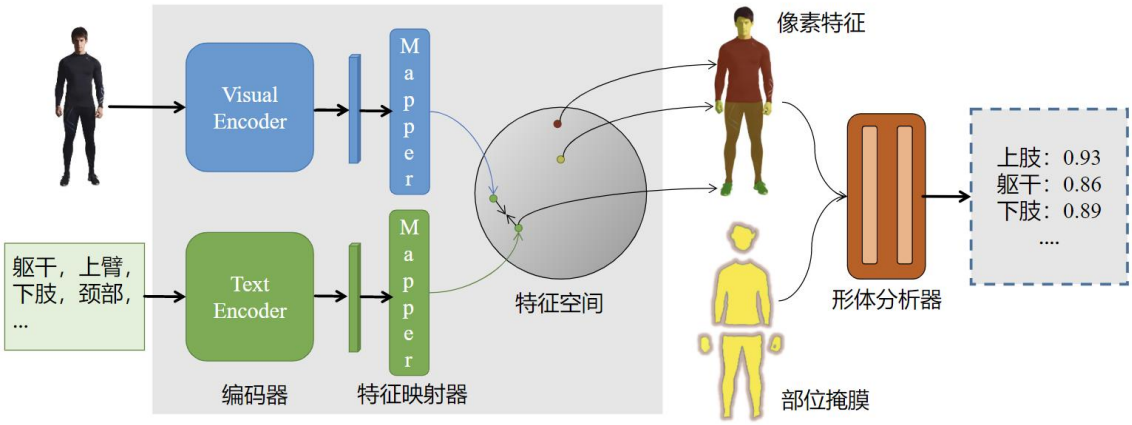


图 8 开集人像形体解析算法

1）网络结构

本算法拟采用的整体网络结构流程如图 8 所示。用户通过手机等移动智能设备所携带的 RGB 摄像头获取用户个体形体图像，同时以文字的形式指定所需分析记录的身体部位，并将其上传到模型算法接口。

A. 双模态特征编码器

模型在接收到用户个人图像和部位文本后，分别将其输入到对应的图像编码器（Visual Encoder）和文本语义编码器（Text Encoder）中。图像编码器通常以残差神经网络（ResNet）或视觉变换器（Vision Transformer）的形式存在，用于从输入的 RGB 图像中提取有关用户姿态和身体部位的特征。文本语义编码器则负责将用户提供的文字描述转化为模型可理解的语义表示，通常以语义向量的形式存在。

在图像编码器中，通过多层次的卷积和池化操作，模型能够逐渐捕捉到图像中的细节和抽象特征。这一过程使得模型能够理解用户的身体姿态、轮廓以及其他与分析记录相关的细节。同时，在文本语义编码器中采用了经过预训练的 BERT 模型，该模型提前经过网络上大量文本信息的训练，在词语字段之间的相关性上拟合良好，能够将用户提供的文字描述在语义向量空间中映射到合适位置。

B. 双模态特征空间对齐

相比于样本量较少的图像数据，文本样本数据数量大，涵盖范围广，泛化能力强，数据分布与实际生活场景接近，因此拟利用文本语义编码器中文本语义向量的强泛化性提升图像编码器的泛化能力。

文本语义编码器会将 N 个词语编码成形状为（N，C）的语义向量特征，其中 N 为词语数量，C 为向量维度数量；图像编码器会将大小为（H，W）的图片编码成形状为（H，W，C）的视觉向量特征，其中 H 为图片高度，W 为图片宽度，C 为向量维度数量。上述操作等价于文本编码器和图像编码器分别将每个词语和每个像素映射到维度为 C 的文本语义特征空间和视觉特征空间中。通过将文本特征与对应像素特征利用相似度进行对齐，可以完成文本语义特征空间和视觉特征空间的对齐，文本语义特征空间的强泛化性即可迁移到视觉特征空间中。因此本研究点拟利用全连接层组成两个独立的特征映射器，分别负责将像素视觉特征和文本语义特征映射到统一的特征空间中。

C. 基于像素特征的形体分析器

经过特征对齐后，像素特征中属于同一身体部位的彼此之间相似度高，不同部位的相似度低，可利用上述特征分布，以对应部位的文本特征作为 query，获得该部位的掩膜 Mask。由于文本特征训练样本量大，涵盖范围广，除人体部位外，还可对服饰、环境等文本进行编码映射，经过特征空间对齐后，像素特征同样拥有了对服饰、环境等类别的编码映射能力，因此本研究点以像素特征和部位掩膜 Mask 作输入，利用注意力模块和全连接层设计了形体分析器，输出对应身体部位的相对形体得分。

NSFC 2024

2）强泛化性的开集模型优化方式

A. 实例感知的像素表征学习

为了提高模型对未见过数据的泛化性，采用实例感知的像素表征学习方法。在训练过程中，以实例的角度入手，将同一实例内的像素视作正样本，其余像素则作为对抗性样本，通过度量这些像素之间的相似性，模型被引导学习到对实例内部的变化和噪声更为鲁棒的表征。这种方法使得模型能够更加关注个体实例的特定特征，而非仅仅依赖于整体类别信息。通过引入对抗性样本，促使模型更好地适应实际场景中的细微差异，从而提高其对于开集数据的适应能力。这种实例感知的训练方式有助于使模型更具有辨识力和鲁棒性，对于不同实例的变化能够有更敏感的感知和学习。模型拟采用余弦相似度作为实例感知的度量，尽可能拉近同实例像素在特征空间中的距离，令不同实例像素特征彼此远离。

$$loss=\begin{cases}1-(|x_i|*|x_j|), & i,j\in I\\ |x_i|*|x_j|, & i,j\notin I\end{cases},$$

其中 x_i，x_j 为图像中两像素特征，I 为实例。当两像素属于同一实例时，损失函数为两像素特征相似度与 1 的差值；若两像素不属于同一实例，则损失函数为余弦相似度。

B. 多模态相关性度量学习

为了更好地整合图像和文本信息，引入多模态相关性度量学习。通过在训练过程中最小化图像特征和文本特征之间的相关性度量误差，模型能够学到更有代表性的共享表示，使得图像和文本之间的关联更为准确和强化。这有助于提高模型对于用户提供的不同形式信息的综合理解，增强对复杂场景的泛化能力。

C. 基于开集语义的泛化性强化

引入基于开集语义的泛化性强化方法，通过对开集数据的语义信息进行挖掘和利用。在训练中，模型被暴露于一系列未见过的语义类别，以引导其学习更加普适的语义表示。这种方式使得模型能够更好地理解不同领域和场景中的语义信息，从而在应对新的开集数据时表现更为鲁棒和准确。通过结合实例感知的像素表征学习、多模态相关性度量学习和基于开集语义的泛化性强化，本算法在复杂多变的现实场景中取得更为鲁棒和高效的性能。

（2）面向人体解析算法的交互式辅助增强技术

交互式图像分割旨在让用户提供少量交互完成对目标物的分割。在学术研究中，交互方法的实现可以采用多种形式，其中点击（click）、划线（scribble）、画框（box）等方式是常见的选择。在这些交互形式中，点击操作通常被认为是主要形式之一。点击交互之所以被广泛采用，主要是因为其简单直观的特性，使其成为训练和评估生态系统中得到广泛认可的一种方式。在点击交互中，通过单击

鼠标或触摸屏等方式来与系统进行交互，这种形式的交互对于用户而言更加简便。

1）整体流程

本研究点拟采用的交互式辅助增强技术整体网络结构如图 9 所示。该网络主要包括三个主要模块:（a）基于 ViT 的主干网络，它在整个过程中保持单尺度特征映射;（b）由主干的最后一张特征图通过四个平行卷积或反卷积层生成的多尺度简单特征金字塔;（c）用于分割的轻量级 MLP 解码器。在用户交互方面，系统允许从现有的分割中获得输入。用户的点击行为被编码为双通道映射，然后与前面的分割结果结合作为网络的输入。这种交互式设计使得用户能够通过点击提供指导信息，有助于进一步改善分割性能。这个架构的设计可以平衡不同模块之间的关系，以实现高效的多尺度特征提取和分割任务。

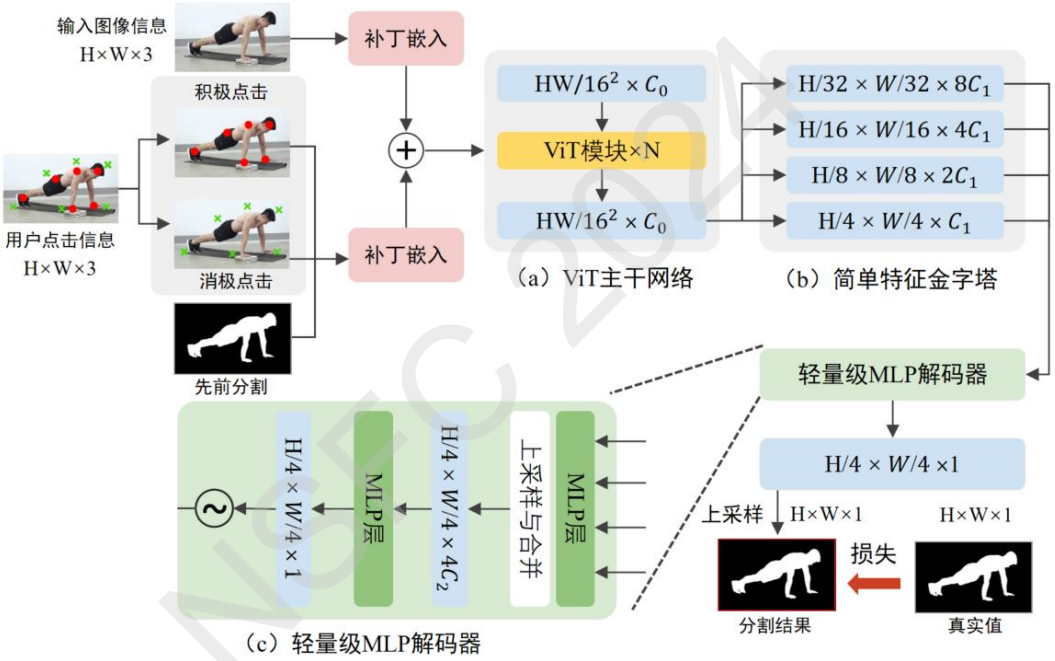


图 9 交互式辅助增强技术网络结构

A. ViT 主干网络

本研究点拟选用普通的 ViT 作为主干网络，其核心思想是在整个过程中保持单一尺度的特征图。ViT 的工作原理包括使用 Patch Embedding Layer 将输入图像划分为不重叠的固定大小的 patch，例如 ViT-B 模型使用的是 16×16 的 patch。每个 patch 被平铺并线性投影到一个固定长度的向量，ViT-B 模型中的向量长度为 768。这样得到的向量序列随后被传送到一个 Transformer 块队列中，例如 ViT-B 使用 12 个 Transformer 块。在这些块中，采用了自注意力机制，使得模型能够在序列中进行自关注，捕捉图像中的全局信息。这种自注意力机制允许模型在处理图像时有效地捕捉像素之间的关系，而无需依赖传统的卷积结构。

主干网络在 ImageNet-1k 数据集上利用自监督任务的目标感知误差（MAE）进行预训练。在微调过程中，引入一些全局自注意块，辅助处理非移位窗口注意力机制，从而使得预训练的主干网络能够更好地适应高分辨率的输入。微调阶段

的关键优化是引入全局自注意块，并辅助非移位窗口注意机制。这种设计旨在增强主干网络对更高分辨率输入的适应性，提高网络在微调任务中的性能。全局自注意块的使用能够捕捉图像中更大范围的关系，而非移位窗口注意机制则有助于应对更高分辨率下的信息处理需求。在构建多尺度特征金字塔时，由于最后一个特征映射受所有注意块的影响，从而该特征映射应该具有最强大的表示能力。因此，网络选择仅使用最后一个特征映射来构建简单的多尺度特征金字塔。这种策略有助于确保在进行下游任务时，网络能够充分利用最高层次的特征表示，以提高性能。

总体而言，ViT 模型通过将图像分割成固定大小的 patch，并在序列化之后使用 Transformer 块队列，实现对图像的特征提取和表示学习。通过使用不同的主干网络、全局自注意块和非移位窗口注意机制，该网络在预训练和微调过程中都能够更好地适应不同分辨率的输入，并构建了一个有效的多尺度特征金字塔。这些设计决策旨在提高网络的表示学习能力和性能。

B. 简单特征金字塔

在分层主干中，一般会利用特征金字塔网络（FPN）来生成特征金字塔，以整合来自不同阶段的特征。然而，对于 VIT 主干网络，生成特征金字塔可以采用一种更简单的方法：通过一组并行的卷积或反卷积层，仅使用主干网络的最后一个特征映射。如图 9 所示，在给定输入的 ViT 特征图的情况下，通过四次不同步进的卷积操作可以生成一个多尺度的特征图。这种简单的特征金字塔设计首次在 ViTDet 中被证明用于目标检测，并且在该工作中取得了显著的效果。通过仅使用主干网络的最后一个特征映射，以并行的方式进行卷积操作，生成多尺度的特征表示。这个简单特征金字塔的设计在提供多尺度信息的同时，保持模型的简洁性和高效性。它能够有效地捕捉不同尺度上的信息，为交互式分割任务提供更全面的视觉上下文。此外，这种设计已经在目标检测中得到验证，本研究点中将其应用于交互式分割任务，验证其在不同视觉任务中的通用性和有效性。

C. 轻量级 MLP 解码器

拟采用一种轻量级的分段头，只使用 MLP（多层感知机）层来实现。这个分段头利用简单特征金字塔生成了 1/4 比例的分割概率图，随后通过上采样操作将其恢复到原始分辨率。值得注意的是，这个分割头的设计避免了计算需求较高的组件，仅占用模型参数的 1%。关键是有了强大的预训练主干，一个轻量级的分割头就足以胜任交互式分割任务。

提出的全 MLP 分割头包含三个关键步骤。首先，来自简单特征金字塔的每个特征映射通过一个 MLP 层，将它们转换为相同的通道维度。其次，将所有特征映射上采样到相同的分辨率（即图中的 1/4），以便进行串联操作。第三，通过另一个 MLP 层将连接的特征进行融合，生成单通道的特征图。接着，通过 sigmoid 函数得到分割概率图，最后在给定预定义阈值的情况下将其转换为二值分割。

这个轻量级的全 MLP 分割头的设计在实现交互式分割任务时可以取得较好的性能，并且其精简的结构确保了计算效率。通过充分利用强大的预训练主干，这

个分割头能够在模型参数较小的情况下实现优越的分割效果，突显其在实际应用中的实用性和有效性。

2）对称补丁嵌入优化

为了将用户的点击信息融合到骨干网络中，本研究点拟引入一个与骨干网络中的补丁嵌入层相对称的补丁嵌入层，并在此基础上添加元素特征。用户的点击信息被编码在一个双通道的特征映射中，其中一个通道表示积极点击，另一个表示消极点击。具体而言，积极点击信息被放置在前景上，而消极点击信息则被放置在背景上。这种编码策略旨在清晰地区分人类点击对前景和背景的影响。

先前的分割结果和双通道点击图被连接成一个三通道图，用于补丁的嵌入操作。两个对称的嵌入层分别对图像和连接的三通道映射进行操作。输入数据被拼接、平面化并投射到两个相同维度的向量序列，然后在输入到自关注块之前进行元素加法操作。这个处理过程旨在确保人类的点击信息与图像的特征能够有机地融合在一起，以提供更加精准和有效的交互式分割结果。通过这种方式，可以将用户交互的信息引入到普通骨干网络中，为模型提供更多关于用户意图的有用信息。

本研究点的目标并非提出新的模块，而是以最小的修改并采用简单的 ViT 主干，实现交互式分割，以充分利用预训练 ViT 权重。这一设计旨在无需引入过多复杂的结构变化。通过在现有的 ViT 主干上进行轻微的调整，能够直接受益于预训练权重，提供一种高效而实用的方式，使用户能够高效地与系统进行互动。这种简化和利用已有资源的方法可以促使交互式分割技术更广泛地应用于实际场景，为用户提供更加便捷的体验。

3.1.3 面向多级任务的标准化人体行为理解

前两个研究点分别关注于关键点级和像素级人体感知，本研究点实现**从感知到理解**，主动健康场景中往往需要**对完成动作进行反馈**，因此涉及到人体动作的识别、定位、评估、描述等多种任务。人体连续动作视频序列数据量大，处理效率低，本研究点拟提出**基于视觉句子的图像向量化建模方法**，首先标准化现有视觉数据集，然后基于该数据集训练得到一个面向视频序列有强大泛化特征提取能力的视觉编码器，从而完成对视频数据中每一帧图像的向量化。此外，针对当前行为理解下游任务目标多样，而模型结构各不相同，本研究点拟提出**基于查询的标准化人体行为理解框架**，基于 Transformer 网络特点将不同任务目标抽象为不同的查询（Query），从而达到模型结构的统一，可以充分利用多域数据，并实现下游任务的统一化。本研究点整体技术框架如图 10 所示。

NSFC 2024

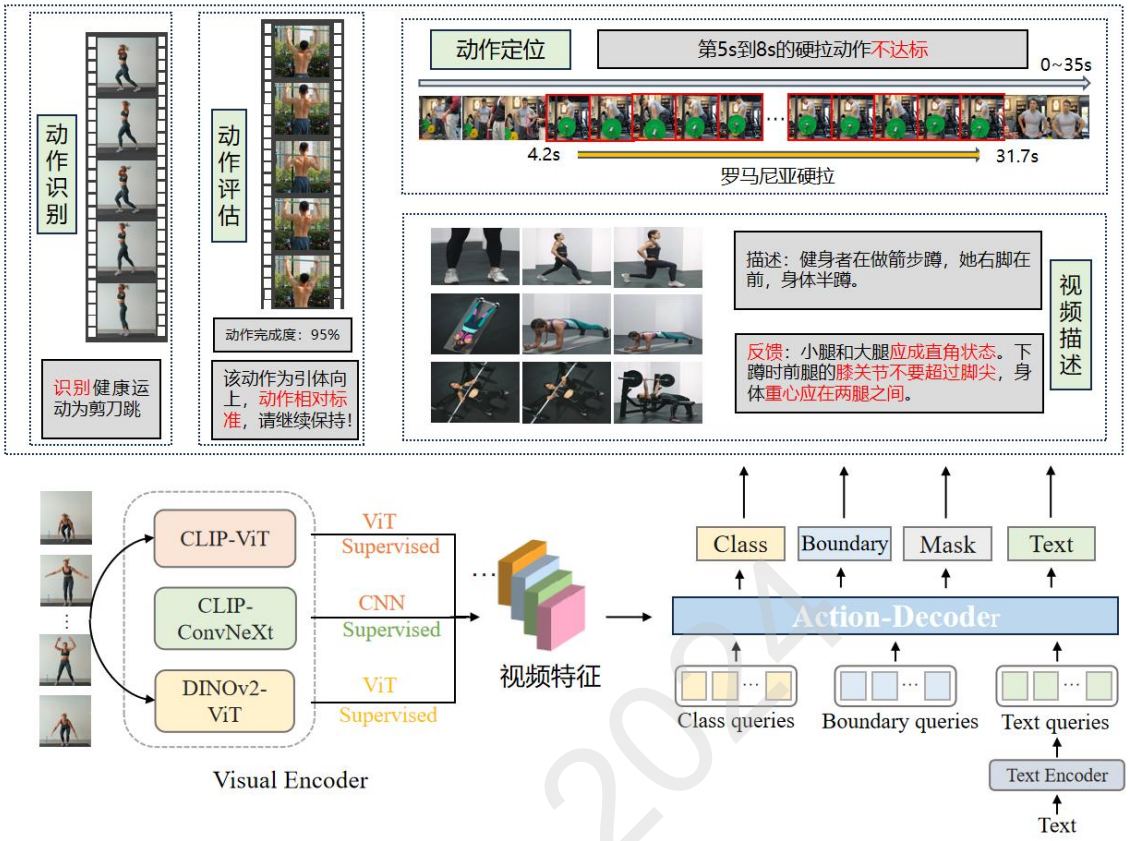


图 10 标准化人体行为理解整体框架

（1）基于视觉句子的图像向量化建模方法

大型语言模型如 GPT，LLaMA 等模型已经取得极大进展，这得益于自然语言的序列化结构以及 Transformer 对于序列型数据的处理优势。面向人体行为理解视频，如何统一整合复杂的视觉数据，本研究点拟提出一种基于视觉句子的图像向量化建模方法。类似于语言，该模型能够将视觉数据转换成一定顺序的视觉句子，基于 Transformer 架构，使用可学习的 tokens 提取特征来训练模型，以达到对于视觉数据有强大的泛化特征提取能力。

1）视觉数据标准化方法

任何大型预训练模型的关键要求都是必须在大量数据上进行训练，对于语言模型来说，非常大且非常多样化的数据集相当容易获得。例如，流行的 Common Crawl 存储库包含 2500 亿个横跨整个 web 的网页，包括语言翻译、问答等多种任务。在计算机视觉领域，现有研究离拥有一个大规模和多样的数据集还有一定距离。本研究点拟面向主动健康视频理解场景提出一种方法来标准化视觉数据源，构建统一视觉数据集。

统一视觉数据集由许多不同的视觉数据来源组成：（1）未标注的图像；（2）带有视觉注释的图像；（3）未标注的视频；（4）具有视觉标注的视频；（5）3D

合成对象。未标注图像占比较高，它代表了整个视觉世界的大部分内容，并以较低的质量为代价提供了所需的多样性。而带有注释的图像具有更受约束的分布，但通常具有更高的质量。视频数据甚至更受限制（通常是以人为中心的活动），但却是时间数据的重要来源。3D 合成对象的渲染是多样性最低的，但可以提供关于 3D 结构行为的有价值的提示。统一视觉数据集是一个纯视觉数据集，不包括非视觉元数据（如文本）。

与大型语言模型的另一个重要区别是，语言数据对所有数据都有一个自然、统一的一维结构——文本流。但是，视觉数据并非如此，不同的来源都有不同的结构。本研究点拟提出将视觉句子作为视觉数据的统一单元，因而能从不同的来源训练可扩展模型。视觉句子只是一个序列，包含一个或多个图像，后面跟着一个句子结尾（EOS）标记。（1）对于单张图片：单个图像本身代表了视觉句子的最简单形式——{图像，EOS}。（2）对于图像序列：图像序列是视觉句子的一种自然形式。本研究点通过从广泛的现有数据集中获取视频数据来创建这样的序列。通过以三个不同的步幅（10、20 和 30）对视频进行随机采样，形成 N 帧的视觉句子。（3）带有注释的图像：为了以统一的方式处理不同类型的图像注释，研究点选择将所有注释表示为图像。（4）带有注释的图像序列：当将带注释的视频数据转换为视觉句子时，本研究点拟采用对注释处理图像数据的方式：每个视觉句子都是通过连接帧及其注释（{frame1，annot1，frame2，annot2，…}）来构建的。

2）图像向量化建模

在标准化视觉数据的前提下，研究点拟提出一个预训练视觉模型进行图像向量化建模。为了将 Transformer 模型应用于图像，先前的研究通常会执行以下操作之一：1）将图像均等划分为块，并将其视为序列；2）使用预训练的图像编码器，将图像特征聚类到离散向量空间中，这些离散向量按照时间先后顺序转换为序列。本研究点拟采用后一种方法，因为模型的离散分类输出自然形成了一个概率分布，可以很容易地从中进行采样，从而能够在视觉句子中灵活且有条件地生成新图像。

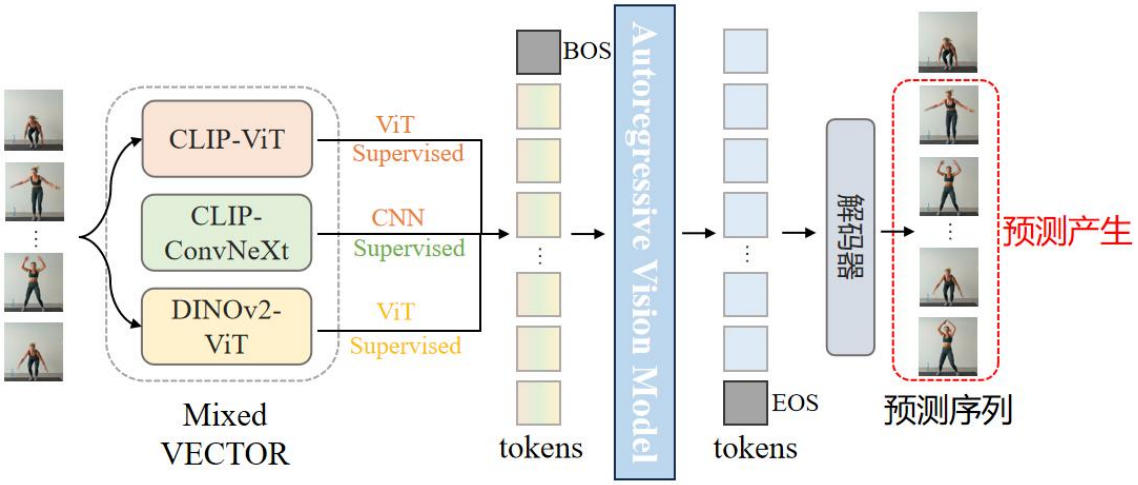


图 11 基于视觉句子的图像向量化建模

本研究点拟使用混合向量（Mixed Vector）编码作为图像编码器生成嵌入向量。

为了从不同角度捕捉鲁棒的视觉表示，本研究点集成各种视觉主干进行图像编码，具有不同特征的视觉主干的选择如下：1）混合的网络架构，由于 CNN 和 ViT 模型主要聚合不同类型的视觉外观，即相邻依赖和长程交互，所以本研究点分别采用了 CLIP-ViT，CLIP-ConvNeXt 和 DINOv2-ViT 作为图像编码器；2）混合的预训练模式，监督训练可以从文本标题或类别标签中强加明确的语义信息，而自监督学习则强制模型探索隐含的代理任务信息。此外，编码器中增加下采样模块以缩小输入的空间维度，解码器中拟使用 Transfomer Decoder 并增加上采样模块以将图像恢复到其初始大小。对于给定的图像或视频，混合向量编码生成高维离散向量，并独立地对单个图像进行操作，而不是同时对整个视觉句子进行操作。这种独立性使得编码器训练与下游特定任务模型解耦，从而可以在单个图像的数据集上训练编码器，而不必考虑视觉句子的分布。

在使用混合向量编码器将图像或视频转换为离散向量后，本研究点通过将来自多个图像的离散向量连接到 1D 序列中，将视觉句子视为统一序列。这样所有视觉句子处于同等地位——不使用任何特殊的标记来指示特定的任务或格式。然后，类似于语言模型的标准方法，使用交叉熵损失训练模型预测下一帧图像。在所有视觉句子上以相同的方式训练模型，使模型能够从上下文而不是从任务或格式特定的标记来推断图像之间的关系，因此模型可以扩展到其他未知的视觉句子结构。

（3）基于查询的标准化人体行为理解框架

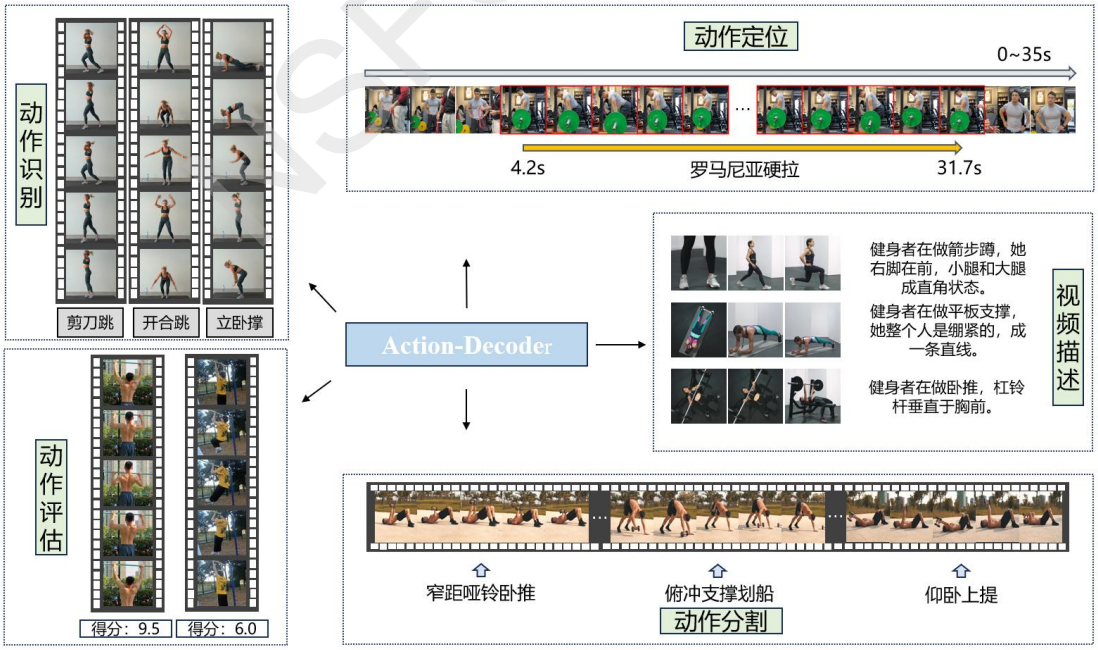


图 12 基于查询的标准化人体行为理解解码器

人体行为理解包含多类别任务，先前有关人体行为理解的工作一般针对各个不同任务而采取不同框架结构，由于 Transformer 的多功能性，用来构建通用模型可以充分利用多域数据，通过多任务学习、顺序解码或统一学习策略，模型可以

从一组不同的视觉或视觉语言任务中学习，并在多种任务上实现泛化应用。基于上述思想，本项目拟提出一种基于查询的标准化人体行为理解框架，该框架能够完成动作识别，动作定位，动作分割，动作评估等行为理解任务。

1）框架整体结构

本研究点模型拟遵循编码器-解码器架构的通用模型，如图 12 所示。给定一个输入的视频$V \in R^{H\times W\times 3}$，首先使用视频编码器$Enc_I$来提取特征$Z$。然后使用文本编码器$Enc_T$将文本查询$T$编码成长度为$n$的$Q^t = \langle q_1^t, \cdots, q_n^t \rangle$。其次设置类别查询$C$为$Q^c = \langle q_1^c, \cdots, q_m^c \rangle$，边界查询$B$为$Q^b = \langle q_1^b, \cdots, q_m^b \rangle$。随后将视觉特征，文本查询，类别查询，边界查询送入动作解码器以预测输出。

$$\langle O^c, O^l, O^s, O^a, O^t \rangle = \text{ActionDec}(\langle Q^c, Q^b, Q^t \rangle; Z) \text{。}$$

本研究点拟遵循 Mask2Former 来构建解码器架构。给定视频$V \in R^{H\times W\times 3}$，从$L$层中提取多层视觉特征：$Z = Enc_I(I) = \langle z_l \rangle_{l=1}^{L}$，$z_l \in V^{H_l \times W_l \times d}$和$\{H_l, W_l\}$是级别$l$的特征图大小，$d$是特征维度。这些多层的特征图对于不同尺度的视频理解非常重要。给定视觉特征Z，动作解码器使用一堆 Transformer 层来优化查询并呈现输出。在第l层，它首先交叉关注视觉特征，然后在类别查询，边界查询和文本查询之间进行自我关注：

$$\langle \hat{Q}_{l-1}^c, \hat{Q}_{l-1}^b, \hat{Q}_{l-1}^t \rangle = \text{CrossAtt}(\langle Q_{l-1}^c, Q_{l-1}^b, Q_{l-1}^t \rangle; Z) \text{，}$$

$$\langle Q_l^c, Q_l^b, Q_l^t \rangle = \text{SelfAtt}(\langle \hat{Q}_{l-1}^c, \hat{Q}_{l-1}^b, \hat{Q}_{l-1}^t \rangle) \text{，}$$

动作解码器让所有查询交叉关注视觉特征，对于非文本查询，根据任务的不同进行屏蔽交叉注意机制，对文本查询进行完全注意，并专门设计了自注意机制来促进任务的协同。动作解码器的输出分为四类：类别输出，边界输出，文本输出，以及掩码输出。解码器对于所有的非文本查询会生成掩码，而对于文本查询则会通过文本查询和对应的非文本查询预测输出以覆盖掩码识别和字幕生成。

本研究点的文本编码器由一系列 Transformer 层组成，给定短语或标题等原始文本，使用现成的标记器将其转换为离散标记，然后将其发送到文本编码器，同时应用具有因果关系的掩码来确保其输出与字幕解码兼容。

2）多任务实现细节

基于上述设计，动作解码器可以用于无缝统一不同的视觉和视觉语言任务，只需将不同的查询组合作为输入。后续，通过构建一定规模的包含运动类别、时间、评估以及运动建议的数据集，统一化训练，即可完成对模型的微调。此外，可以设计运动描述任务，侧重对不同类别动作不同注意要点的描述，描述用户动作与标准动作的差异，从而实现运动后的建议反馈。

NSFC 2024

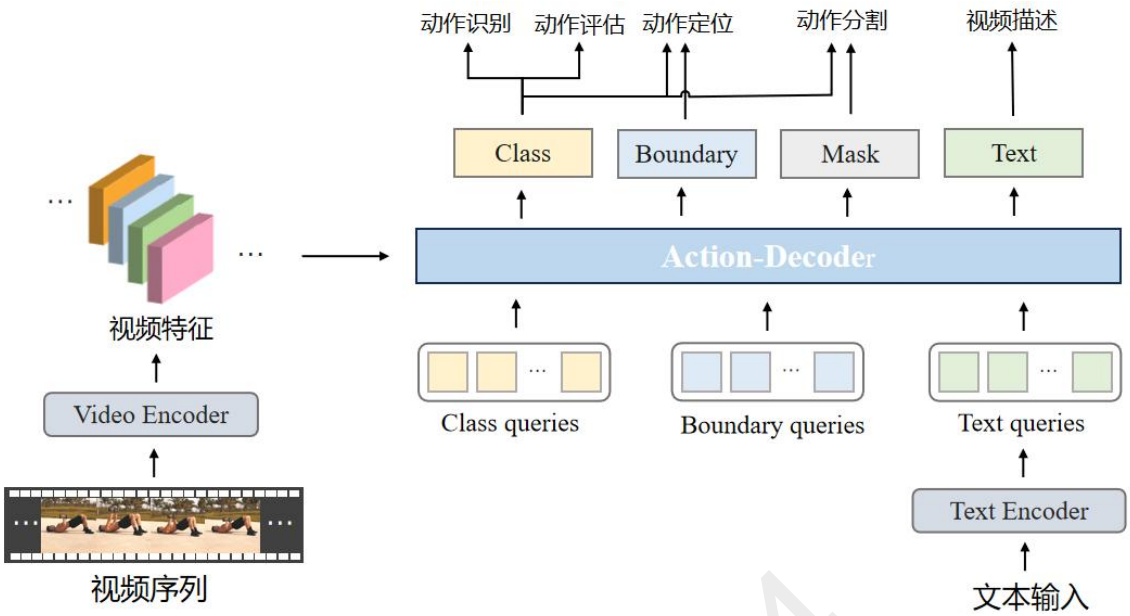


图 13 多任务模型结构细节图

A. 动作识别

动作识别旨在预测出一段视频中的动作实例的类别，对于此任务，动作解码器不需要额外的文本查询作为输入，只需要类别查询。

$$\langle O^c \rangle = \text{ActionDec}(Q^c; Z) \text{ 。}$$

如图 13 所示，类别查询与特征在解码器中交互得到预测的类别。

B. 动作定位

动作定位旨在预测出一段视频中的动作实例的开始结束时间以及对应动作类别，对于此任务，动作解码器不需要额外的文本查询作为输入，需要类别查询和边界查询。

$$\langle O^l, O^c \rangle = \text{ActionDec}(Q^c; Q^b; Z) \text{ 。}$$

如图 13 所示，类别查询，边界查询与特征在解码器中交互得到预测的时间片段以及对应动作的类别。

C. 动作分割

动作分割旨在对一段长视频中的不同动作实例及背景进行划分分割，对于此任务，动作解码器不需要额外的文本查询作为输入，需要边界查询及其掩码。

$$\langle O^s \rangle = \text{ActionDec}(Q^b; Z) \text{ 。}$$

如图 13 所示，类别查询与特征在解码器中交互得到预测的划分片段。

D. 动作评估

动作评估旨在对一段视频中的某个动作实例进行评分已评价其表现，对于此任务，动作解码器不需要额外的文本查询作为输入，需要类别查询。

$$\langle O^a \rangle = \text{ActionDec}(Q^c; Z) \quad \text{。}$$

NSFC 2024

如图 13 所示，类别查询与特征在解码器中交互得到预测的动作表现分数。

E. 动作描述

动作描述旨在对一段视频进行文本语言的描述，对于此任务，动作解码器需要额外的文本查询作为输入，需要类别查询。

$$\langle O^t \rangle = \mathrm{ActionDec}(Q^c; Q^t; Z) \text{ 。}$$

如图 13 所示，类别查询，文本查询与特征在解码器中交互得到文本描述。

本研究点的动作解码器对每个任务的适应性很高，基于这种统一框架，动作解码器可以使用合适的查询和损失组合，将解码器与所有任务联合预训练，并在没有任何额外头的情况下对单个任务进行进一步微调。正如前面所述，一系列的工作都拟用次序的编解码过程实现统一。本研究点希望通过功能而不是功能模块完成统一，即最大限度地共享不同任务的共同部分，同时保持单个任务的剩余部分不变。

3.1.4 面向主动健康应用的智能服务系统

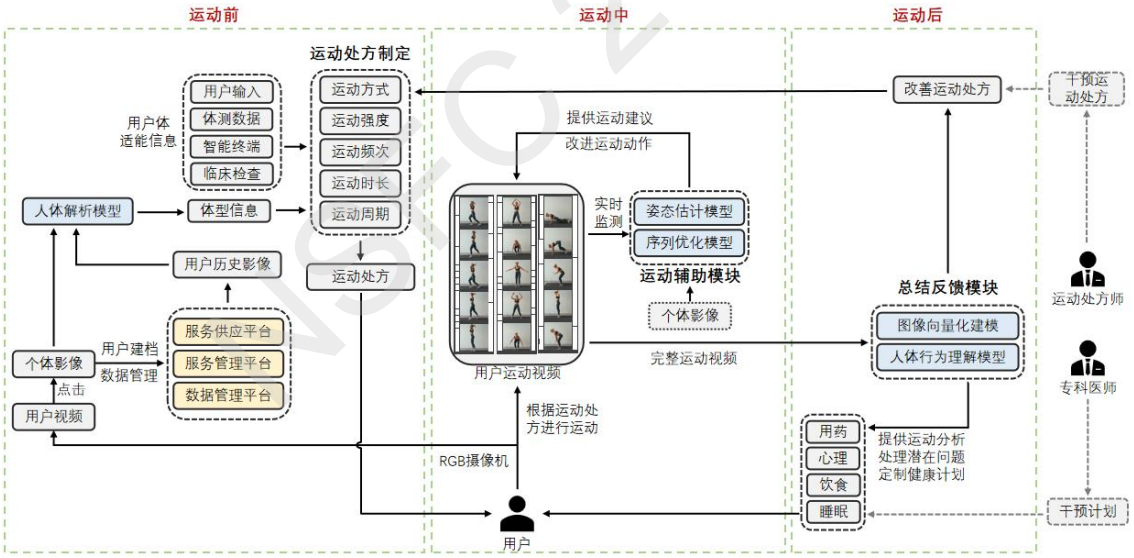


图 14 智能服务系统框架图

面向主动健康应用的智能服务系统框架图如图 14 所示，整个系统为用户提供运动前中后全周期健康管理。运动处方的制定根据用户体适能分析结果，体适能分析结果可以采集自用户输入、体测报告、智能算法监测等途径。通过个性化运动处方推荐，科学化便捷化用户主动健康行为，并在运动中对用户进行运动引导与辅助，运动后提供总结反馈，根据用户运动状况及时调整运动处方。此外，系统支持线上运动处方师和医师干预，进一步保障系统运行。本系统的开发涉及到前端、后台等，均使用十分成熟的技术框架，在此不在赘述，下面主要描述体适能分析、运动处方定制以及人体感知与理解技术应用的业务逻辑。

（1）基于体适能分析的运动处方定制

面向不同群体的主动健康需求差异明显，需要针对不同个体根据其运动目标、身体情况定制运动处方。**运动处方定制涉及运动频率、运动强度、运动时间、运动方式、运动总量及运动进阶等要素，是为不同年龄、不同体适能水平以及存在/不存在冠心病危险因素或冠心病的人群制定的，用于促进健康及防治慢病的运动锻炼指导方案。**本研究点拟根据个体的体型、体适能、慢性病等因素制定运动处方。

1）体型评测标准

体型评测标准是一个综合性的评估体系，旨在全面评估个体的体型状况。在进行体型评测时，需要综合考虑多个方面的测量数据和美感标准，以便得出准确的评估结果。**一般来说，体型评测标准包括身体质量指数 BMI，腰臀比以及体脂率。**表 7 给出了不同体型对应的 BMI 与体脂比例。

表 7 体型评测标准

体型	BMI 指数标准			体脂比例标准（百分比）	
	WHO 标准	亚洲标准	中国标准	女性	男性
偏瘦	＜18.5			12%-18%	4%-15%
正常	18.5-24.9	18.5-22.9	18.5-23.9	18%-25%	15%-25%
超重	≥25	≥23	≥24	25%-30%	25%-35%
偏胖	25.0-29.9	23-24.9	24-27.9	30%-39%	
肥胖	30.0-34.9	25-29.9	≥28		
重度肥胖	35.0-39.9	≥30		≥39%	≥35%
极度肥胖	≥40				

BMI 即身体质量指数，是用于衡量人体肥胖程度和是否健康的一个重要指标。身体质量指数是通过一个人的体重（千克）除以其身高（米）的平方来计算的，即 BMI=体重（千克）/身高（米）²。一般标准体重为体重（kg）=身高（cm）-105，正常人体重允许上下浮动在 10%以内，低于 10%为消瘦，超过 10%提示过胖。一般体重指数为体重指数=体重（kg）/身高（m^2），中国人的正常范围 18.5-24，低于 18.5 为消瘦，24 到 28 为超重，大于 28 为肥胖。

腰臀比也是一个很常见的测量指标，用来判定中心性肥胖，计算方法也很简单，腰臀比=腰围÷臀围。测量腰围臀围需要一把卷尺，腰围的测量方法是水平绕脐上 1cm 的位置一圈，卷尺和腹部尽量贴合，读取数值。臀围的测量位置是臀部向后最突出的部位，其他与腰围方法一致。 标准腰臀比为：女性不大于 0.85，男性不大于 0.9，在健康范围内，比值越小，越健康。

体脂率是指人体内脂肪重量在总体重中所占的比例，也称为体脂百分数。它反映人体内脂肪含量的多少，以及是否肥胖。体脂率的计算公式有多种，其中一

种公式为：体脂率=（身体脂肪总重量÷体重）×100%。成年女性的体脂率正常范围为18%～25%，成年男性的体脂率正常范围为15%～25%。

综上所述，体型评测标准是一个综合性的评估体系，需要综合考虑多个方面的测量数据和美感标准。通过科学合理的体型评测，个体可以全面了解自己的体型状况，并采取相应的措施来保持健康的体型。

2）体适能评测标准

由于本项目面向所有人群，针对不同年龄段的体适能测试，对应的标准和方法是不同的，其中，青少年体适能标准是有明确的相关规定的，针对中年及老年的体适能评测标准应当根据具体的身体情况指定特殊的标准，本项目拟采用以下几种相关的体适能评测方法。

针对青少年的体适能评测：根据明文规定，采取如下评测手段，并展开实际测试进行验证。

其中，每一项的具体评分细则可以参考《教育部关于印发〈学生体质健康监测评价办法〉等三个文件的通知》（教体艺〔2014〕3号）有关要求。

表8 青少年体适能评测项目

测试对象	单项指标	权重
小学一年级至大学四年级	体重指数（BMI）	15
	肺活量	15
小学一二年级	50米跑	20
	做立体前屈	30
	1分钟跳绳	20
小学三四年级	50米跑	20
	做立体前屈	20
	1分钟跳绳	20
	1分钟仰卧起坐	10
小学五六年级	50米跑	20
	坐立体前屈	10
	1分钟跳绳	10
	1分钟仰卧起坐	20
	50米×8折返跑	10
初中 高中 大学各年级	50米跑	20
	坐立体前屈	10
	立定跳远	10
	引体向上（男）/1分钟仰卧起坐（女）	10
	1000米跑（男）/800米跑（女）	20

而针对中年、老年人的体适能评判标准通常基于不同的方面，包括有氧耐力、肌肉力量、灵活性和身体组成，核心稳定，骨密度，心理健康等等。以下是一些常见的评判标准：

NSFC2024

表 9 中年、老年体适能评测项目

年龄段	中年	老年
身体形态 机能	体重指数（BMI）	皮褶测量
肌肉力量和耐力	腰腹力量	哑铃 弹力带力量测试
	上肢力量和耐力	背起
柔韧性	坐立体前屈	肩部伸展
	髋部伸展	髋部伸展
平衡能力	平板支撑	单脚站立
	俯卧撑	闭眼站立
协调性	灵敏度测试	手眼协调性测试
	平衡板测试	踏步测试
骨密度和骨健康	骨密度测量	骨密度扫描
日常活动水平	日记记录	日常生活能力评估工具
动作范围	快跑	上下楼梯
	跳跃	蹲下
疼痛和疾病管理	疼痛评估问卷	疼痛评估问卷
	医疗记录	医疗记录

综合来说，评估中年、老年人的体适能需要考虑多个方面，并综合个体的健康状况和目标进行评估，同时可以结合医生、健康专家或专业的健身教练，以获取更准确和个性化的评估结果和建议。总的来说，针对体适能评测标准下的不同项，需要分别综合群体得分，根据测量值得出一个最终得分，然后根据体适能评测结果进行运动处方制定。

3）运动处方制定流程

针对不同年龄段的个体，制定科学合理的运动处方和医疗处方是维护整体健康的关键。该系统旨在通过各种运动形式，从力量提升、耐力增强到各种慢性疾病的预防以及医疗，为个体提供全方位的健康管理支持。

青少年正处在身体是神经系统发育的关键时期，本项目的运动处方注重多样性和有效性，包括力量训练、有氧运动、体操等。通过这些活动，青少年能够更加全面的开发身体，提高力量、耐力以及协调性，促进骨骼健康以及心理健康。

同时，针对中老年人，本项目拟定的运动处方更关注关节保健、心血管健康和平衡训练，弹力带训练、快步走、太极拳等低冲击的运动形式被纳入处方，注重维护关节柔韧性、促进心血管健康、提高身体平衡性以及协调性，表 10 展示了部分健身运动处方。

另外，针对部分常见疾病，本项目拟制订医疗处方，通过运动来预防，或对其医疗起到积极影响。同样，针对不同年龄段的个体采取的医疗处方也有所不同。总之，该医疗处方旨在通过个体化的运动计划，辅助治疗并提高生活质量。表 11 列出了部分医疗运动处方。

NSFC2024

表 10 健身运动处方

	青少年		中老年	
目的	运动类型	功效	运动类型	功效
提升力量	深蹲	提高下半身肌肉力量，增强核心稳定性	深蹲椅起立	改善坐立功能
	卧推	提高上半身力量和稳定性	弹力带推胸	强化上肢肌肉，增强抗阻力
	硬拉	促进全身肌肉协同工作，提升整体力量	轻量哑铃侧平举	提高肩关节稳定性
提高耐力	跑步	增强心肺功能	快步走	促进全身肌肉的活动和协调
	游泳	提高身体耐力、柔韧性和协调性	游泳	提高心血管健康、促进血液循环
	骑自行车	强化下半身肌肉，锻炼心肺系统	慢跑	长期慢跑能增加骨密度，对预防骨质疏松有积极影响
提高灵活性	瑜伽	提高身体的柔韧性和关节的灵活性，同时提高核心稳定性，改善身体的姿势和平衡	太极拳	提高平衡感、关节柔软度以及核心稳定性
	体操	提高肌肉的协调性和全身力量	平衡训练	强化腿部肌肉，改善身体的空间感知能力，并提高身体的灵活性和协调性

表 11 医疗运动处方

疾病类型	常见疾病	运动类型	
		青少年	中老年
神经系统疾病	多发性硬化症	体操、舞蹈、瑜伽，注重活力和协调性	太极拳、平衡训练，采取缓慢而流畅的动作，提高平衡感
	帕金森病	高抬腿、游泳、太极拳，注重肌肉协调性	太极拳、慢步行，采取柔和的运动，改善步态和平衡
	抑郁症	有氧运动、团队体育，有助于提升心情，并促进社交互动，提升身心健康	低强度的有氧运动、舞蹈，促进社交互动并改善心情
呼吸系统疾病	慢性阻塞性肺病	踏板力量训练、有氧、慢跑，注重有氧训练	快步走、温和的有氧运动，注重呼吸和心肺健康
	哮喘	游泳、慢跑、瑜伽，注重提高耐力和呼吸控制能力	慢走、呼吸训练，注重呼吸肌肉的强化

NSFC 2024

	间质性肺病	长期高强度有氧结合抗阻运动，强化呼吸肌肉，提升呼吸效率	适度的有氧运动，提高心肺健康
心脑血管疾病	高血压	游泳、骑自行车、慢跑，注重心血管健康	游泳、快步走，采取适度的运动
	冠心病	轻度有氧运动，适度的力量训练，并关注医生指导	快步走、温和的力量训练，关注医生建议的有氧运动

总之，本项目不仅注重科学化和个性化，更考虑到不同年龄段的生理特点和需求，努力为个体提供更加全面、精准的健康管理方案。

运动处方的制定主要遵循以下五条基本原则：个性化原则、循序渐进与可调整原则、以全身耐力为基础的原则、安全性与有效性原则、体质基础与运动效果的特异性原则，同时需要明确是否用于治疗慢性疾病或运动损伤等医疗目的。医疗运动处方的制定需要依据对方的健康信息、基础运动状态、运动测试、医学检查与诊断等结果，兼顾治疗疾病和保持运动能力制定运动处方。运动处方的制定程序如下：临床检查、体适能分析、制定预训练处方、监督监测预处方效果、制定运动处方、实施运动处方、运动中的监督反馈、运动处方微调和修改。图 15 展示了本项目拟定的运动处方制定流程。

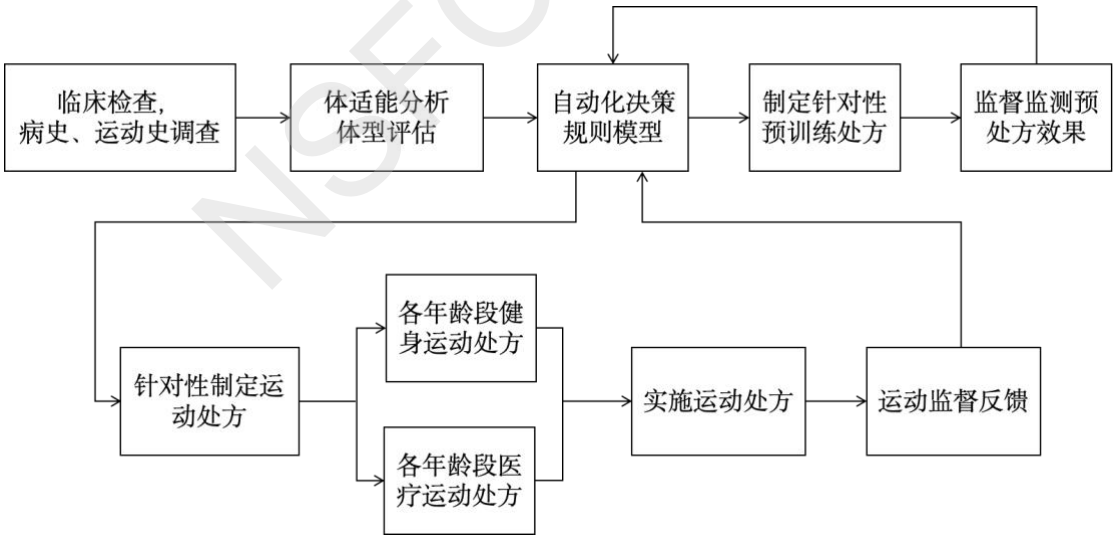


图 15 运动处方制定流程

医疗运动处方应重点关注可能造成心血管事件和运动损伤的各种因素，对因治疗，防治疾病。健身运动处方则重点关注运动总量，让运动不足或缺乏运动人群运动起来并养成习惯。

（2）运动感知理解驱动的全周期运动处方实施

运动处方的实施需要全周期的动态辅助、反馈和调整，来确保运动处方与个体的自身需求、运动能力相匹配。本研究点旨在以前三个研究点的运动感知理解技术为驱动，完成运动前的个体体型与运动能力的检查、运动中的实时姿态检测与辅助、运动后的动作理解以及阶段总结等功能，最终对不同个体的运动处方进行个性化推荐与调整，实现全周期的运动处方实施。运动感知技术与运动处方实施的具体结合如下：

（1）**基于人体解析的体型监测：**个体的体型可能随着时间发生变化，使得定制的运动处方不再适用。本研究点拟采用人体解析算法，通过用户点击交互的方式从图像中提取出个体的外貌影像，并与历史数据进行对比分析，对个体体型的变化调整相应的运动处方。此外，个体影像的特征还用于个体的实时追踪，减少背景噪声对于后续算法的影响。如下图所示，不同 BMI 的个体在体型上有明显区别，因此可以从视觉上利用人体解析算法识别身体各部位的相对比例。

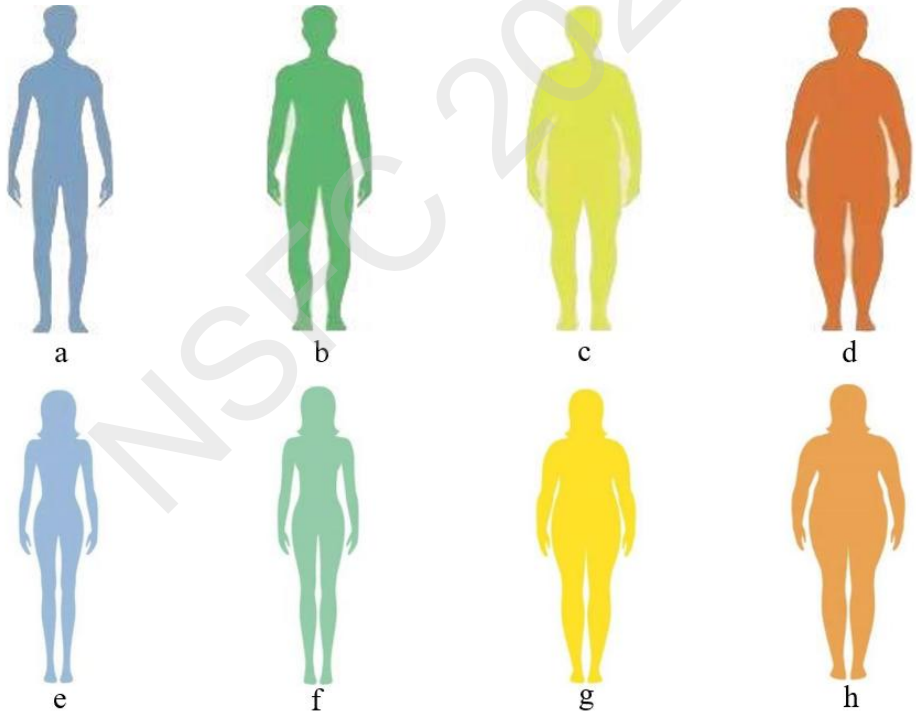


图 16 男女不同 BMI 体型对照表：图 ae，BMI<18.5，偏瘦；图 bf，BMI 18.5-23.9，正常；图 cg，BMI 24.0-27.9，偏胖；图 dh，BMI>28，肥胖

（2）**基于运动姿态分析的运动辅助：**长期的不规范训练反而会导致个体的运动慢性损伤，对个体运动姿态的实时检测与辅助是运动处方实施的关键。本研究点拟采用人体姿态估计算法与姿态序优化算法结合的形式，挂载对应的运动知识库，实现对运动处方内动作的精准识别，进而得到人体动作序列，监测个体运动是否与运动知识库中标准动作相符合，进而对个体运动实现实时反馈与辅助。

（3）**基于动作理解的总结反馈：**在运动后的总结阶段，本研究点拟采用动作

NSFC 2024

理解技术将为个体提供动作分析、潜在慢性病推测以及运动处方优化服务。首先，此技术可以为个体的动作视频提供索引，方便迅速跳转到指定片段进行分析。其次，个体的运动动作可能一直受到某部位的慢性病影响，导致在存在运动辅助的情况下依旧无法纠正，动作理解技术可以为个体指出意识不到的错误动作甚至潜在的慢性疾病。最终，结合上述信息可以针对性地处理潜在问题，改善运动处方。

3.2 可行性分析

本项目在后疫情时期国民对主动健康的需求下，结合运动医学、视觉感知理解、深度学习的发展，项目组进行了大量前期调研和相关研究工作，具备较强的研究基础。项目可行性主要基于以下几方面：

（1）**研究内容可行：**本项目基于大量国内外研究现状调研，针对各研究点已有工作：AIGC 相关领域的发展已经证明视频生成模型的可行性，此外，自动驾驶等垂直领域已经开始使用生成数据进行模型预训练，为本项目后期实施提供参考样例；在图像分割领域，可控条件下，面向开放世界的相关研究结果已经取得一定进展，进一步走向实用；在人体行为理解领域，已有大量工作在不同任务上展现优越的性能，并且随着 CLIP、VideoMAE 等视觉文本对齐模型的出现，为多模态融合提供基础。在上述背景下，项目组结合自身研究基础和研究创新点，提出了各点研究内容，从理论上保证项目切实可行。

（2）**技术路线可行：**本项目对所提到的人体姿态估计、人体解析、人体行为理解有明确的研究路线，研究方法主要通过理论分析、算法方案设计、仿真环境或实验平台验证的方式，属于较成熟的研究途径，且研究思路具有较高的创新性，搭建的系统具备很强的实用性。

（3）**软硬件环境：**本项目将在北京市重点实验室——北京邮电大学安全生产智能监控重点实验室进行，依托单位已具备研究所需要的软硬件条件。项目所使用的实验软件和实验设备均被国际通用和认可，可满足研究和实验需求，基于项目组现有的基础验证平台和实验环境通过改进和增强，能够为当前和今后的研究提供平台基础。

（4）**研究团队：**项目组成员以中青年教师和博士为主，并在人工智能、物联网、运动医疗、体育运动等相关领域进行了多年研究，有扎实的理论基础和长期的实践研究成果积累，已取得的研究成果和方法为本项目奠定了理论和技术基础。

（5）**相关研究基础：**本项目通过前期国家自然基金青年项目、科技部重点研发项目等项目的研究积累，在人体感知理解、物联网技术应用、运动医疗处方推荐等方面已经取得许多研究成果并积累了丰富的研究经验和实测数据。在基于计算机视觉的人体姿态估计、人体解析、人体行为理解等技术，项目组一直进行深入研究，在 CVPR 等国际顶会上提出了轻量化单阶段 3D 人体姿态估计算法和单阶段多人人体解析算法，可支持实时性应用，并均有自建数据集以及基线，在业内

已获得了一定关注。在系统搭建部署方面，项目组曾经完成了面向青少年的智慧体育服务系统和花样滑冰智能评分系统（助力 2022 北京冬奥会），并在“互联网+”、创新创业比赛上获奖。此外，项目组一直与体育运动课题组、运动医学课题组和国内外研究机构保持合作和经验交流，已经在广东省体育职业技术学院、广东省人民医院等单位获得了大量体测数据，为今后展开深入研究提供数据基础。

（6）**初步实验结果**：项目组在姿态序列优化任务上，已经验证了融合相似姿态进行训练和推理可以提升算法性能，后续将进一步构建姿态知识库，提升算法效率；在主动交互行为引导的开集人体解析研究中，已经验证了通过特征对齐，可以提升算法在开放世界中对未知类别的召回率，后续将探索更有效的交互信息融合方式；在面向多级任务的标准化人体行为理解研究中，已经验证了基于查询的 Transformer 架构可以在多个下游任务上达到最优。上述结果均初步验证了本项目技术方案的可行性。

4. 本项目的特色与创新之处；

本项目面向国民主动健康与人工智能技术结合的实际应用需求，以人体运动感知与理解技术为牵引，深入研究运动场景中高精度高效模型架构设计的基础理论方法，希望在运动视频生成模型、视觉文本多模态对齐、长时运动视频感知与理解等核心技术上实现突破，开发面向主动健康应用的智能服务系统平台。结合业务逻辑，本项目力图从基础理论、核心技术、系统应用等多个途径进行创新，切实推进项目核心技术突破与研究成果应用落地。

基础理论创新：项目重点关注**高效性与精准性的模型架构设计理论**。为提升姿态估计算法的精准度，设计轻量化姿态序列优化模型，实际应用中人体姿态往往变化多样，而运动场景存在姿态重复冗余，创新性地提出先验姿态知识库，并通过多骨骼点格式适应策略实现姿态归一化，利用姿态相似性提升姿态优化算法性能。为提升人体解析算法的效率，创新性地提出交互式辅助增强策略，结合用户点击交互，实现对指定部位解析与输出结果增强。为提升人体行为理解下游任务模型性能上限，首先提出标准化视觉数据，针对视频序列完成基于视觉句子的向量化建模，面向现有的大量视频数据设计混合的编码器架构和优化策略，从而利用视觉数据对基础特征编码器进行大规模预训练。

核心技术创新：项目基于**利用额外辅助约束和多任务融合架构的方式优化面向智能主动健康服务的关键技术**，利用多学科交叉激发技术创新活力。通过引入人体姿态约束到视频生成模型相关技术，进而生成符合实际场景的训练数据，为本项目提供无约束场景训练数据支撑，大幅提升模型鲁棒性。通过引入主动交互信息和类别文本信息，增强人体解析技术在开放场景中的泛化性，并提升算法性能。通过设计面向多级任务的标准化人体行为理解框架，进行多种数据源的联合训练，实现跨任务优化。在关键技术层面，基于已有研究基础，创新性地提出人体感知到理解的研究路线，为完成运动后的动作识别、评估、建议等需求提供技术基础。在运动处方制定与实施过程，设计面向不同人群的体适能分析标准，创新性地结合人体运动感知与理解技术保障运动处方全周期实施。

系统应用创新：本项目依托人工智能技术与物联网设备，评测国民体适能水平，围绕国家“健康中国 2030”发展要求，积极响应“将科技创新作为提高健康水平的有力支撑”的号召，**运用人体运动感知与理解技术建立通用的主动健康服务一体化系统，拟实现智能化提升国民体质健康水平**。针对不同年龄段，结合体适能分析结果，定制个性化运动处方，并创新性地设计了运动前体型体质分析、运动中运动辅助引导和运动建议、运动后总结反馈等人工智能技术应用场景，探索人工智能技术对国民运动健康全周期的辅助作用。

5. 年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）。

5.1 年度研究计划

本项目的年度研究计划如下：

（1）2025 年 1 月到 2025 年 12 月

- 开展第一项研究内容，即研究基于姿态辅助的视频数据生成算法，采集构建姿态数据库和知识库，研究基于姿态知识库的姿态序列优化算法。
- 整理代码，搭建无约束场景下的有先验人体运动分析模块，在实际场景中应用验证。
- 完成 3-5 篇高水平论文，申请 1-2 项专利，并调研人体解析算法。

（2）2026 年 1 月到 2026 年 12 月

- 开展第二项研究内容，即研究开集人像形体解析算法和面向人体解析算法的交互式辅助增强技术。
- 整理代码，搭建主动交互行为引导的开集人体解析模块，在实际场景中应用验证。
- 完成 3-5 篇高水平论文，申请 1-2 项专利，并调研人体行为理解算法。

（3）2027 年 1 月到 2027 年 12 月

- 开展第三项研究内容，即研究基于视觉句子的图像向量化建模方法和基于查询的标准化人体行为理解框架。
- 整理代码，搭建面向多级任务的标准化人体行为理解模块，在实际场景中应用验证。
- 完成 3-5 篇高水平论文，申请 1-2 项专利。
- 开放基于本项目搭建的数据集，并举办研讨会和挑战赛，与国内外相关领域同行深入交流，扩大项目组的知名度和成果影响力。

（4）2028 年 1 月到 2028 年 12 月

- 开展第四项研究内容，制定各年龄段体适能评估标准、完善体适能分析结果与运动处方映射关系，将各个算法模块整合，搭建面向主动健康应用的

NSFC2024

智能服务系统，完成系统试点。

- 完成 3-5 篇高水平论文，申请 1-2 项专利。
- 对项目标志性成果进行总结，并提交项目结项报告。

此外，在项目的执行期间，项目成员拟参加本领域权威国际会议 3-5 次，在会议上宣读论文并开展学术交流。项目申请人将邀请本领域的知名学者每年到项目组所在的北京邮电大学电子工程学院进行访问，开展实质性的交流与合作。同时，项目组成员也将联系本领域的国外知名研究机构（如新加坡国立大学、斯坦福大学等）进行短期的交流和访问，以保证本项目工作的先进性。

5.2 预期研究结果

本项目的预期研究成果如下：

（1）面向主动健康的高性能人体运动感知与理解技术算法库：包含与人体运动感知理解相关的各种算法模型，如基于姿态辅助的视频生成算法、基于姿态知识库的姿态序列优化算法、开集人像形体解析算法、面向人体解析的交互式辅助增强算法、基于视觉句子的图像向量化建模算法和基于查询的标准化人体行为理解框架等。同时以主动健康作为算法主要应用方向，产出各个算法在主动健康领域的专业化版本，并进行开源，推动领域发展。

（2）面向主动健康应用的智能服务系统：基于算法库和对主动健康技术的实际社会需求，设计高技术水平的、高可用性的、高普适性的面向主动健康应用的智能服务系统。系统能够利用算法辅助用户满足主动健康的各种需求，包括利用人体运动分析算法实现姿态矫正和运动辅助、利用人体解析算法实现体型监测和利用人体行为理解算法实现健康运动指导等。本项目研究取得的技术成果将争取在工业界寻求合作进行落地和产业化，目前已有数家相关企业对本项目研究方案中的部分模块和技术表达了浓厚的合作兴趣。

（3）人体运动感知与理解相关学术论文发表：为加强国内运动感知与主动健康技术的研究生态建设，项目在研究过程中产生的成果将分模块和阶段在领域内重要国际会议 NeurIPS、ECCV、ICCV、CVPR 等和国际期刊 TPAMI、TIP 等上进行投稿，预期总共发表文章 10 篇以上。

（4）人体运动感知与理解相关核心技术专利申请：项目在研究过程中产生的核心技术将申请国家专利，预计申请专利 5 项。

（5）人体运动感知与理解相关研究生培养：6 到 8 名研究生将参与到本项目的研究过程中，项目研究方案中的部分模块将作为他们的学位论文内容。

（6）参与人员职称晋升：本项目结项前，预计 2 名参与项目人员晋升至副教授、教授等高级职称。

（7）系统试点：基于构建的主动健康智能服务系统在广东省体育职业技术学院、广东省人民医院、广东省中医院等合作单位实行系统试点，招募 500 名以上

学生、病患等志愿者参与智能服务系统测试，通过一系列包括体适能测试、体重指数（BMI）、体型评估等参考数据采集后，制定个性化运动处方，利用智能服务系统对志愿者进行为期时长为 3 个月以上的健康管理跟踪，包括运动辅助、姿态矫正、智能化体型体质监控和健康运动指导等，并在引导期结束后重新评测志愿者体能水平，对比之前的测试数据，分析系统有效性及改进方向。

（二）研究基础与工作条件

1. 研究基础（与本项目相关的研究工作积累和已取得的研究工作成绩）；

1.1 学术成果

申请人依托自然科学基金青年项目在人体感知算法上已取得一定进展。

[1] 针对单阶段 2D 人体姿态估计算法的中心点置信度与姿态质量不一致性问题，提出了结构引导中心学习与基于代理的尺度适应学习，使得算法通过在 NMS 阶段保留质量更高的姿态取到更好的性能（代表作 1）。

[2] 针对自底向上的 2D 人体姿态估计算法中分组策略缺少位置信息的问题，提出了基于向心偏移的分组策略，相同条件下相比其他分组策略有明显的性能提升（代表作 2）。

[3] 针对当时 3D 人体姿态估计算法普遍采用两阶段方式而导致的效率降低问题，提出了单阶段 3D 人体姿态估计算法，在提升算法速度的同时并保障精度（代表作 3）。

[4] 将单阶段的思想引入多人人体解析任务，指导学生完成了单阶段人体解析算法，速度相比于此前最快的算法提升 102%（代表作 4）。

[5] 针对人体姿态估计算法在拥挤场景下鲁棒性差的问题，指导学生搭建了花样滑冰场景下的人体姿态数据集 SkatingPose，并提出了去中心化人体姿态表征，实验验证其相比于其他姿态表征方式有更优越的表现（代表作 5）。

此外，项目组成员在人体感知、动作理解、深度学习模型优化、运动医学等领域已有成果积累，为本项目提供技术支撑。详细如下：

期刊论文

[1] **Jin, L.**, Wang, X., Nie, X., Wang, W., Guo, Y., Yan, S., Zhao, J. Rethinking the Person Localization for Single-Stage Multi-Person Pose Estimation[J]. T-MM, 2023. （计算机图形学与多媒体领域重要国际期刊，中科院一区）「结构感知的人体姿态估计」

[2] **Jin, L.**, Wang, X., Nie, X., Liu, L., Guo, Y., Zhao, J. Grouping by center: Predicting centripetal offsets for the bottom-up human pose estimation[J]. T-MM, 2022，25: 3364-3374. （计算机图形学与多媒体领域重要国际期刊，中科院一区）「基于向心偏移的人体姿态估计」

[3] **Jin, L.**, Xu, C., Wang, X., Xiao, Y., Guo, Y., Nie, X., Zhao, J. Single-stage is enough: Multi-person absolute 3D pose estimation[C]. CVPR, 2022: 13086-13095. （计算机视觉领域顶级国际会议，CCF-A 类会议）「单阶段三维人体姿态估计」

[4] Chu, J.#, **Jin, L.# ***, Fan, X., Teng, Y., Wei, Y., Fang, Y., ..., Zhao, J. Single-Stage Multi-human Parsing via Point Sets and Center-based Offsets[C]. ACM MM, 2023: 1863-1873.（计算机图形学与多媒体领域顶级国际会议，CCF-A 类会议，共同一作为本人指导研究生）「轻量化单阶段人体解析」

[5] Wang, T.#, **Jin, L.# ***, Wang, Z., Fan, X., Cheng, Y., Teng, Y., ..., Zhao, J. DecenterNet: Bottom-Up Human Pose Estimation Via Decentralized Pose Representation[C]. ACM MM, 2023: 1798-1808.（计算机图形学与多媒体领域顶级国际会议，CCF-A 类会议，共同一作为本人指导研究生）「去中心化的人体姿态估计」

[6] Wang, T.#, **Jin, L.# ***, Wang, Z., Li, J. ..., Zhao, J. SynSP: Synergy of Smoothness and Precision in Pose Sequences Refinement[C]. CVPR, 2024. （计算机视觉领域顶级国际会议，CCF-A 类会议，共同一作为本人指导研究生）「姿态序列优化」

[7] Gan, Z.#, **Jin, L.# ***, Nie, L., Wang, Z., ..., Zhao, J. Asquery: A Query-based Model for Action Segmentation[C]. ICME, 2024.（多媒体领域旗舰国际会议，CCF-B 类会议，共同一作为本人指导研究生）「人体动作分割」

[8] Xiao, Y., Yu, D., Wang, X. J., **Jin, L.**, Wang, G., Zhang, Q. Learning quality-aware representation for multi-person pose regression[C]. AAAI, 2022, 36(3): 2822-2830. （人工智能领域顶级国际会议，CCF-A 类会议）「轻量化人体姿态估计」

[9] Xiao, Y., Su, K., Wang, X., Yu, D., **Jin, L.**, He, M., Yuan, Z. QueryPose: Sparse Multi-Person Pose Regression via Spatial-Aware Part-Level Query[C]. NeurIPS, 2022, 35: 12464-12477.（机器学习与神经计算领域顶级国际会议，CCF-A 类会议）「基于 Transformer 的人体姿态估计」

[10] Xiao, Y., Wang, X., Yu, D., Su, K., **Jin, L.**, Song, M., ..., Zhao, J. Adaptivepose++: A powerful single-stage network for multi-person pose regression[J]. arXiv preprint arXiv:2210.04014, 2022.（Extended from AdaptivePose in AAAI 2022）「多粒度人体姿态表征与估计」

[11] **Jin, L.**, Wang, X., Chu, J., He, M. Human activity recognition machine with an anchor-based loss function[J]. IEEE Sensors Journal, 2021, 22(1): 741-756. （工程技术领域重要国际期刊，中科院二区）「惯性传感器人体行为识别」

[12] Chu, J., **Jin, L.***, Xing, J., Zhao, J. UniParser: Multi-Human Parsing with Unified Correlation Representation Learning[J]. arXiv preprint arXiv:2310.08984, 2023. （Peer-reviewed in TIP）「基于关联表征学习的人体解析」

[13] Wang, X., Lv, T., Gan, Z., He, M., **Jin, L.** Fusion of skeleton and inertial data for human action recognition based on skeleton motion maps and dilated convolution[J]. IEEE Sensors Journal, 2021, 21(21): 24653-24664. （工程技术领域重要国际期刊，中科院二区）「惯性信号与深度信息融合的人体行为识别」

[14] Wu, X., Zhao, H., Li, S., Cao, Y., & **Zha, H.*** Sc-wls: Towards interpretable feed-forward camera re-localization[C]. ECCV, 2022: 585-601.（计算机视觉领域顶级国际会议，CCF-B 类会议）「基于前馈网络的摄像机重定位」

[15] Chen, X., Zheng, Y., Zheng, Y., Zhou, Q., **Zhao, H.***, Zhou, G., & Zhang, Y. Q. DPF: Learning Dense Prediction Fields with Weak Supervision[C]. CVPR, 2023: 15347-15357. （计算机视觉领域顶级国际会议，CCF-A 类会议）「复杂预测域的弱监督学习」

[16] Wu, Z., Liu, T., Luo, L., Zhong, Z., Chen, J., Xiao, H., ... & **Zhao, H.*** Mars: An instance-aware, modular and realistic simulator for autonomous driving[C]. CAAI, 2023: 3-15. （国内人工智能领域顶级会议，最佳论文 Runner-up 奖） [模块驱动的智能感知]

NSFC2024

[17] Jin, B., Liu, X., Zheng, Y., Li, P., **Zhao, H.***, Zhang, T., ... & Liu, J. ADAPT: Action-aware Driving Caption Transformer[J]. ICRA, 2023. （机器人领域顶级国际会议，CCF-B 类会议）[决策模型]
[18] **Yang, Y.**, Li, J. H., Xu, N. J., Yang, W. Y., Liu, J. Meta-analysis of elderly lower body strength: different effects of tai chi exercise on the knee joint-related muscle groups[J]. Evidence-Based Complementary and Alternative Medicine, 2021.「太极拳运动对下肢力量的影响探究」
[19] **Yang, Y.**, Xu, N. J., Li, J. H., Zeng, L. F., Liang, G. H., Zhang, F., ..., Liu, J. Exercise or Dietotherapy Is Not Better than Returning to a Regular Diet to Rebuild Lipid Homeostasis of Rats[J]. BioMed Research International, 2021: 1-9. 「饮食与运动对脂肪代谢的影响」
[20] **杨园**, 叶啟发, 杨翼. 运动调节衰老的表观遗传机制研究进展[J]. 中国运动医学杂志, 2019, 8.
[21] Seyedi, R., Zhong, Y., Song, W., **Yang, Y.*** Recovery Strategies on Lactate Removal and Heart Rate in Shortest Time after Fatiguing Exercise[J]. International Journal of Applied Exercise Physiology, 2019, 8(4): 54-61.「运动后恢复研究」

专利及软著

[1] **金磊**；吴昊；淦子良；王小娟；何明枢；一种基于多模态融合的人体动作识别方法及装置，2023-5-29，中国，CN202310615495.8
[2] 王小娟；**金磊**；何明枢；初佳明；阳柳；动作识别处理方法、装置及设备，2021-11-2，中国，CN202111291956.8
[3] 王小娟；何明枢；**金磊**；视频中人体动作切分方法及装置，2021-8-31，中国，CN202011415844.4
[4] 王小娟；何明枢；**金磊**；滕颖蕾；徐晨阳；人体姿态估计分组模型训练方法、姿态估计方法及装置，2021-5-7，中国，CN202110497324.0
[5] 王小娟；何明枢；**金磊**；关键帧识别模型训练方法、识别方法及装置，2020-12-7，中国，CN202011415820.9
[6] Yao, A., **Zhao, H.**, Lu, M., Guo, Y., Chen, Y. Methods and apparatus for discriminative semantic transfer and physics-inspired optimization of features in deep learning: U.S. Patent, 16609732. 2023-6-6.
[7] **王广进**；智能体测存证安全监控平台，9624523，原始取得，全部权利，2022-3-1.
[8] **王广进**； AI 体适能测评自动配置系统，9624524，原始取得，全部权利，2022-3-1.
[9] **王广进**；体测辅助分析系统 V1.0，9408223，原始取得，全部权利，2022-3-1.

1.2 数据基础

项目组拥有丰富的运动感知与理解实验的部署经验，在人体姿态估计、人体解析、动作理解等细分领域有完备的数据支持，其中包括 Microsoft、YouTube、Google 等诸多权威公司发布的通用数据集，并在十余种数据集上项目组团队已拥有算法验证模型以及实验分析结果，具体如表 12-14 所示，此外**具备自建数据集的基础和经验，加粗数据集为团队成员主导或参与搭建**，能够针对实际运动任务场景的需求，灵活调整实施策略，针对不同的人群、不同的训练目的，实现对视频流中目标人物的姿态估计、人体解析、运动标准化的辅助反馈、体适能评估和个性化运动处方的定制。

表 12 人体姿态估计数据集

数据集名称	样本数	2D/3D	关键点数	时间

MPII	25k	2D	16	2014
COCO	200k	2D	17	2014
Human3.6M	3.6m	3D	24	2014
3DPW	51k	3D	18	2018
CrowdPose	20k	2D	14	2019
COCO-WholeBody	330k	2D	133	2023
Human-Art	50k	2D	21	2023
SkatingPose	**17k**	**2D**	**17**	**2023**

表 13 人体解析数据集

数据集名称	目标	样本数	类别数	时间
CFPD	单人	2682	23	2013
PASCAL-Person-Part	多人	3533	7	2014
ATR	单人	7700	18	2015
Chictopia10k	单人	10000	18	2015
MHP-v1.0	**多人**	**4980**	**19**	**2017**
VIP	视频	21246	20	2018
MHP-v2.0	**多人**	**25403**	**59**	**2018**
COCO-DensePose	多人	27659	15	2018
CIHP	多人	38280	20	2018
HRHP	单人	7500	20	2021

表 14 动作理解数据集

数据集名称	任务	样本数	总时长	时间
UCF Sports	动作识别	150	16m	2008
Olympic	动作识别	800	-	2010
50Salads	动作分割	966	5.3h	2013
MIT-Diving	动作评估	159	15.9m	2014
Breakfast	动作分割	8456	77h	2014
Thumos14	动作定位	413	-	2014
ActivityNet	动作定位	19994	-	2015
Diving48	动作识别	18404	-	2018
EPIC-KITCHENS	动作分割	39596	55h	2018
AQA-7	动作评估	1189	1.4h	2018
MTL-AQA	动作评估	1412	1.6h	2019
Stroke	动作识别	22111	4.0h	2021
FenceNet	动作识别	652	-	2022
SkatingVerse	**多任务**	**87432**	**184.4h**	**2023**

1.3 业务基础

针对运动智能分析相关研究，如图 17 所示，申请人与广东省体育职业技术学

院（广东省体育职业技术学院相关团队已取得省级运动防护专业教学团队认证）、体质健康管理学会已有相关合作基础，如面向高尔夫的技术论证、健身国职考试等，并依托国家自然科学基金开发了**青少年智能体测系统**。此外，申请人与中国花样滑冰协会合作研发了**动作理解数据集与花样滑冰辅助评分系统**。上述系统均在 3S 杯全国大学生物联网技术与应用“三创”大赛中获得一等奖。申请人与前述团队的共享数据与算法可支持本项目中面向主动健康的人体姿态估计、人体解析和动作理解关键技术研究。在以往的项目中，申请人完成了动作识别在动作流和单帧动作的验证（体测动作和健身动作等），采集了对应动作的视频数据，定义了动作关键帧，在这些视频数据上进行细粒度的关键帧标注工作，并尝试应用于运动处方标准动作库中，对深蹲、交叉步、瑜伽等运动处方库动作进行了动作建模与标准制定。综上，申请人先进实验场地、高水平的专业素养以及丰富的算法研究基础，结合充足的项目经验和一定数据基础，确保了本次项目后续实施。



图 17 前期数据与业务基础

申请人与**合作单位华南师范大学体育科学学院**的相关团队在前期已针对体育+AI 应用在教育场景开展工作，并以“多模态数据下人工智能技术在体育教育中的应用”为题共同在第一届全国体育人工智能大会对工作成果进行汇报演讲。团队中**主要参与人杨园**，长期致力于中医药干预运动损伤与运动康复的基础及临床研究工作，侧重于研究运动骨骼肌在骨关节炎等运动医学相关疾病中的应用。后续，合作单位可以为本项目在运动医学上提供支撑。此外，申请人与**合作单位清华大学智能产业研究院**的相关团队针对体医融合智能系统开发与应用已开展多次交流。清华大学智能产业研究院（AIR）旨在面向第四次工业革命，实现国际化、智能化和产业化。该机构于 2020 年由多媒体和人工智能领域的世界级科学家和企业家张亚勤院士创建，其使命是利用人工智能技术推动产业升级和社会进步。AIR 通过大学和企业的合作创新，突破人工智能核心技术，培养智能产业领军人才，推动智能产业跨越式发展。AIR 面向世界科技前沿、经济主战场、国家重大需求和人民生命健康，布局了人工智能、大数据、云计算和边缘计算四个基础研究方向以及智慧交通、智慧物联和智慧医疗三个应用方向。自 2020 年成立以来，研究院已经在相关领域的顶级期刊和会议上发表论文 160 余篇，为本项目提供了深厚的理论基础和实验条件。团队中**主要参与人赵昊**于 CVPR， ICCV， ECCV，IJCV，T-IP，T-MM，NeurIPS，ICLR 等计算机视觉与机器人国际期刊和会议上发表近 30 篇论文，是清华大学最大的机器人社团“天空工场”的创始人和负责人之一，曾参与孵化 10 余家高新技术创业公司。合作单位作为高水平产学研示范机构，可以为本

项目在系统应用示范上提供支持。

1.4 项目基础

申请人主持的国家自然科学基金青年项目《基于人体体态与运动感知的体适能评估关键技术研究》可以为本项目提供技术和数据基础，其针对青少年的相关系统应用试点（广东省体育职业技术学院）为本项目积累了大量经验。此外，本项目涉及云边协同、物联网技术以及计算机视觉技术在主动健康中的应用，申请人主持/参与的相关项目研究成果（表 15 物联网技术/人工智能系统开发）为本项目提供物联网应用与系统开发基础。另外，项目还涉及到体育、医疗等领域，申请团队在相关方向均有核心成果产出（表 15 人工智能+医疗/运动训练）。

表 15 与本项目相关项目列表

类别	名称	项目来源
人工智能+体适能	基于人体体态与运动感知的体适能评估关键技术研究	国家自然科学基金
物联网技术	面向 OT 与 IT 融合的端边云互联集成理论与方法研究	科学技术部
人工智能系统开发	大数据背景下的区域性智慧服务应用平台	北京市其他项目
	花样滑冰辅助评分系统 v1.0/v2.0	北京科协“千人进千企”
	基于深度学习的智慧体育关键技术与行为评估系统	北京邮电大学行动计划
人工智能+医疗	融合知识图谱与智能推荐的中医临床路径构建与优化方法研究	国家自然科学基金
运动训练	运动性疲劳消除和伤病防治的新方法和新技术	广东省体育局科研项目
	现代五项激光跑新赛制下的体能康复综合服务	国家体育总局科技服务项目
	基于联合组学技术探讨补肾活血祛湿中药介导“TRPs-脂代谢-炎症”信号轴治疗湿邪所致 KOA 的机制研究	国家自然科学基金

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、国家重点实验室和部门重点实验室等研究基地的计划与落实情况）；

申请人所在的北京邮电大学成立于 1955 年，是我国第一所邮电高等学府，是一所以信息科技为特色、工学门类为主体、工管文理协调发展的多科性、研究型大学。近年来，获国家科技发明奖、国家科技进步奖、省部级科研奖励、电子学

会科学技术奖、通信学会科学技术奖近 90 项，居全国高校前列，科技创新的价值贡献度与社会影响力持续提升。

申请人所在的北京邮电大学电子工程学院具有综合学科背景，在电子科学、信号处理、人工智能、物联网等领域具备雄厚的研究基础，满足本项目的多学科交叉需求。本项目将在北京邮电大学电子工程学院 ICN&CAD 中心内完成，实验室和成员曾荣获国家科技进步一等奖、电子部科技进步奖一、二、三等奖、国家教委科技进步奖一等奖、二等奖、邮电部科技进步奖二、三等奖、中国商业联合会服务业科技创新奖特等奖等。该中心为北京邮电大学安全生产智能监控重点实验室的一部分，拥有博导、教授以及博士和硕士研究生近百人，此外还聘请了加拿大 Carleton 大学 Fei Richard Yu 教授，加拿大 University of Victoria 大学 Wei Li 教授和爱尔兰 DCU 大学 Xiaojun Wang 等教授担任兼职教授和导师。

申请人所在的学院有着独立自有的优良办公条件和实验场地，有开展本项目所必须的高性能 GPU 服务器近百台、高性能硬盘存储服务器、台式计算机、数据采集设备等。另外，申请人所在课题组自身就有高性能 GPU 服务器 10 余台、嵌入式开发系统平台 4 套、高档计算机 20 余台、HP 打印机若干台。本项目针对主动健康应用中人工智能+物联网的场景具备：

- **本地运算条件（GPU）**：服务器 12 台，拥有英特尔金牌 5218 系列处理器，GTX 3090 等显卡，128G 内存，支持 DDR4 2400，硬盘标配 8 个 3.5 盘位，并计划利用自然基金资金重点对 GPU 的运算能力进行提升。
- **本地运算条件（CPU）**：服务器 4 台 CPU 配置为 Xeon E7-2820（18MB 三级缓存，2.0GHz），并拥有 4 核英特尔至强处理器 Xeon E7-2820 v3（18MB 三级缓存，2.0GHZ），并计划利用自然基金资金租赁服务商云算力。
- **边缘运算条件：**计算设备 8 台，分别是 6 台 Jetson AGX Xavier 边缘设备，32TOPS，功耗最高可达 30W，2 个英特尔 Compute Stick“计算棒”，拥有平板电脑的硬件水准，可以插入 HDMI 接口，提供了 16GB 存储空间及 1GB 内存，并计划利用自然基金资金重点对边缘端的能力进行提升。
- **数据积累：**除公开数据集外，有自建面向姿态估计、人体解析、人体行为理解任务数据集各 1 套（已公开），6 小类体育行业的数据标注经验，深耕体育垂直领域；中科 SeeTaaS 自主可控人工智能生产平台（快速的数据预处理和标注，通用的视觉处理算法包）保证垂直领域的关联模块的快速研发。
- **小程序快速迭代条件：**具有用友 T+软件，采用浏览器/服务器（B/S 架构），只要搭建好服务器，就可以使仿真验证平台专注于核心模块，如姿态估计、行为理解等的研发。
- **物联网仿真条件：**搭建了一个新型的面向物联网的云平台系统架构，采用主流的 MQTT 协议，终端设备通过 Zigbee 无线组网，设备数据通过 Zigbee 网关统一接入到网络里，能够并发连接 500 台以上的终端设备。

本实验室承诺优先保证本项目所需的设备仪器和软硬件实验环境。

3．正在承担的与本项目相关的科研项目情况（申请人和主要参与

者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；

- 国家自然科学基金委员会，青年科学基金项目，62102039，基于人体体态与运动感知的体适能评估关键技术研究，2022-01-01 至 2024-12-31，30 万元。

与本项目关系：申请人主持的青年科学基金项目属于基于计算机视觉的智能感知算法研究与应用范畴，通过对人体体态与运动感知技术的研究，构建了一整套面向青少年智能体测与体适能评估的系统。在该项目的资助培养下，申请人**获得了北京邮电大学特聘副研究员，并成为硕士生博士生导师**。目前项目进展顺利，计划完成 5 篇以上高水平论文，**已完成 9 篇高质量论文，其中包括 5 篇 CCF-A 类会议，2 篇中科院一区期刊（CVPR×2、ACM MM×2、NeurIPS×1、T-MM×2、ICME×1、IEEE Sensor Journal×1，详见研究基础）**，申请专利 3 项。申请人在研究过程中发现，体适能评估后续可以与运动处方相配合保障科学化锻炼，然而人体运动感知模型不足以满足全运动周期管理的需求。因此，**本项目在青年基金项目的研究基础上，继续围绕视觉智能感知相关技术，并提出从感知过渡到理解，由体适能评估到运动处方定制**，以智能主动健康应用为目标，结合生成式模型、开放世界、多任务基础模型等核心技术，搭建受众更广、覆盖全运动周期、可理解反馈的服务系统。青年基金项目为本项目储备了大量算法、理论、体测数据基础，并积累了大量研究经验，深度学习模型轻量化与优化方法可以直接用于支撑本项目相关研究内容。此外，本项目可以借鉴青年基金项目中面向青少年的体适能评估标准，为本项目中国民各年龄段体适能评估与运动处方定制提供参照。

负责的内容：青年科学基金项目为申请人独立负责。

- 国家自然科学基金委员会，青年科学基金项目，82205147，基于联合组学技术探讨补肾活血祛湿中药介导“TRPs-脂代谢-炎症”信号轴治疗湿邪所致 KOA 的机制研究，2023-01-01 至 2025-12-31，30 万元。

与本项目关系：主要参与人杨园主持的青年科学基金项目关注医疗领域基础研究，保障本项目在运动医疗领域的专业性，可以为本项目在运动处方制定的安全性及可行性分析、运动生理生化指标监测提供理论支撑。

负责的内容：青年科学基金项目为参与人杨园独立负责。

- 国家自然科学基金委员会，面上项目，82274685，融合知识图谱与智能推荐的中医临床路径构建与优化方法研究，2023-01-01 至 2026-12-31，66 万元。

与本项目关系：申请人参与以上的面上项目，此项目主要研究针对脾胃病利用知识图谱和推荐算法构建中医临床路径的问题。此项目的合作单位中国中医科学院可以为本项目提供医院的相关资源以及医疗数据支持。此外，其在知识图谱和推荐算法的研究可以为本项目在第四个研究内容中的基于体适能分析的运动处方定制提供智能推荐相关技术的支撑。

负责的内容：知识图谱和推荐算法设计。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限 500 字）和相关成果详细目录）。

无

（三）其他需要说明的情况

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系）。

无

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无

3. 其他。

无

NSFC2024

金磊 （ BRID：08091.00.28908 ） 简历 2024版

北京邮电大学， 电子工程学院， 副研究员

教育经历：

（1）2015-09 至 2020-07，北京邮电大学，电子科学与技术，博士

（2）2011-09 至 2015-06，北京邮电大学，电子科学与技术，学士

博士后工作经历：

（1）2020-09 至 2022-08，北京邮电大学

科研与学术工作经历（博士后工作经历除外）：

（1）2022-09 至 今，北京邮电大学，电子工程学院，副研究员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

（1）国家自然科学基金委员会，面上项目，82274685，融合知识图谱与智能推荐的中医临床路径构建与优化方法研究，2023-01-01 至 2026-12-31，66万元，在研，参与

（2）国家自然科学基金委员会，青年科学基金项目，62102039，基于人体体态与运动感知的体适能评估关键技术研究，2022-01-01 至 2024-12-31，30万元，在研，主持

（3）国家自然科学基金委员会，面上项目，62071056，基于物联网协同计算的行为认知与隐私安全研究，2021-01-01 至 2024-12-31，64万元，在研，参与

（4）国家自然科学基金委员会，面上项目，61871046，面向数据增强的物联网无线传输与智能服务关键技术研究，2019-01-01 至 2022-12-31，59万元，结题，参与

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

（1）中华人民共和国科学技术部，国家重点研发计划，2021YFB3300100，面向OT与IT融合的端边云互联集成理论与方法研究，2022-01 至 2024-12，300万元，在研，参与

（2）中华人民共和国科学技术部，国家重点研发计划，2019YFB1802603，网络资源感知的智能路由协议与算法，2020-01 至 2023-12，356万元，结题，参与

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

（1）**Lei Jin**; Xiaojuan Wang; Xuecheng Nie; Wendong Wang; Yandong Guo; Shuicheng Yan; Jian Zhao ; Rethinking the Person Localization for Single-Stage Multi-Person Pose Estimation, *IEEE Transactions on Multimedia*, 2023, 26: 1436-1447 （**期刊论文**） （ 本人标注：唯一第一作者 ）

（2）**Lei Jin**; Xiaojuan Wang; Xuecheng Nie; Luoqi Liu; Yandong Guo; Jian Zhao ; Grouping by Center: Predicting Centripetal Offsets for the Bottom-up Human Pose Estimation, *IEEE Transactions*

on Multimedia, 2022, 25: 3364-3374 **（期刊论文）** （ 本人标注：唯一第一作者 ）

(3) **Lei Jin**; Chenyang Xu; Xiaojuan Wang; Yabo Xiao; Yandong Guo; Xuecheng Nie; Jian Zhao ; Single-Stage is Enough: Multi-Person Absolute 3D Pose Estimation, *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, New Orleans, 2022-6-18至2022-6-24 **（会议论文）** （ 本人标注：唯一第一作者 ）

(4) Jiaming Chu; **Lei Jin**; Xiaojin Fan; Yinglei Teng; Yunchao Wei; Yuqiang Fang; Junliang Xing; Jian Zhao ; Single-Stage Multi-human Parsing via Point Sets and Center-based Offsets, *The 31st ACM International Conference on Multimedia (ACM MM)*, Ottawa, Canada, 2023-11-1至2023-11-5 **（会议论文）** （ 本人标注：共同第一作者，共同通讯作者 ）

(5) Tao Wang; **Lei Jin**; Zhang Wang; Xiaojin Fan; Yu Cheng; Yinglei Teng; Junliang Xing; Jian Zhao ; DecenterNet: Bottom-Up Human Pose Estimation Via Decentralized Pose Representation, *The 31st ACM International Conference on Multimedia (ACM MM)*, Ottawa, Canada, 2023-11-1至2023-11-5 **（会议论文）** （ 本人标注：共同第一作者，共同通讯作者 ）

二、论著之外的代表性研究成果和学术奖励：

(1) **金磊**(1/1)；3S杯第七届全国大学生物联网技术与应用“三创”大赛一等奖，中国通信学会/中国电子学会，*发明*，其他，2021(**金磊**) **（科研奖励）**

(2) **金磊**(1/1)；北京市“千人进千企”专项行动产业特派员，北京市科学技术协会，*其他*，其他，2023(**金磊**) **（科研奖励）**

(3) **金磊**；吴昊；淦子良；王小娟；何明枢 ；一种基于多模态融合的人体动作识别方法及装置，2023-5-29，中国，CN202310615495.8 **（专利）**

(4) 王小娟；何明枢；**金磊**；阳柳；余赛赛；任传伦；魏鹏；王欣蕾 ；基于深度强化学习的可迁移性网络流行为异常检测方法及装置，2022-12-9，中国，CN202210224580.7 **（专利）**

(5) 王小娟；**金磊**；何明枢；初佳明；阳柳 ；动作识别处理方法、装置及设备，2021-11-2，中国，CN202111291956.8 **（专利）**

(6) 王小娟；何明枢；**金磊**；滕颖蕾；徐晨阳 ；人体姿态估计分组模型训练方法、姿态估计方法及装置，2021-5-7，中国，CN202110497324.0 **（专利）**

(7) 王小娟；何明枢；**金磊** ；视频中人体动作切分方法及装置，2021-8-31，中国，CN202011415844.4 **（专利）**

(8) 王小娟；何明枢；**金磊** ；关键帧识别模型训练方法、识别方法及装置，2020-12-7，中国，CN202011415820.9 **（专利）**

(9) 王小娟；张勇；**金磊**；王得福；宋佳明；陈墨；宋梅 ；一种异常流量行为判别方法和装置，2019-11-30，中国，CN201810443326 **（专利）**

NSFC 2024

赵昊 （ BRID: 01236.00.77955 ） 简历 2024版

清华大学， 智能产业院， 助理研究员

教育经历：

(1) 2013-08 至 2020-06，清华大学，信息与通信工程，博士

(2) 2009-08 至 2013-06，清华大学，电子信息科学与技术，学士

博士后工作经历：

(1) 2020-10 至 2023-01，北京大学，英特尔研究院

科研与学术工作经历（博士后工作经历除外）：

(1) 2023-02 至 今，清华大学，智能产业研究院，助理研究员

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

(1) 国家自然科学基金委员会，面上项目，61871248，同种异体骨移植手术中应力分析与三维特征匹配研究，2019-01-01 至 2022-12-31，67万元，结题，参与

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

无

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

(1) Zirui Wu; Tianyu Liu; Liyi Luo; Zhide Zhong; Jianteng Chen; Hongmin Xiao; Chao Hou; Haozhe Lou; Yuantao Chen; Runyi Yang; Yuxin Huang; Xiaoyu Ye; Zike Yan; Yongliang Shi; Yiyi Liao; **Hao Zhao** ; Mars: An instance-aware, modular and realistic simulator for autonomous driving, *2023 CAAI International Conference on Artificial Intelligence (CICAI)*, Fuzhou, 2023-7-22至2023-7-23 （**会议论文**） （ 本人标注：唯一通讯作者 ）

(2) Chengliang Zhong; Yuhang Zheng; Yupeng Zheng; **Hao Zhao**; Li Yi; Xiaodong Mu; Ling Wang; Pengfei Li; Guyue Zhou; Chao Yang; Xinliang Zhang; Jian Zhao ; 3D Implicit Transporter for Temporally Consistent Keypoint Discovery, *2023 ICCV/CVF International Conference on Computer Vision (ICCV)*, Paris, 2023-10-2至2023-10-6 （**会议论文**） （ 本人标注：唯一通讯作者 ）

(3) Bu Jin; Xinyu Liu; Yupeng Zheng; Pengfei Li; **Hao Zhao**; Tong Zhang; Yuhang Zheng; Guyue Zhou; Jingjing Liu ; ADAPT: Action-aware Driving Caption Transformer, *2023 IEEE International Conference on Robotics and Automation (ICRA)*, London, 2023-5-29至2023-6-2 （**会议论文**） （ 本人标注：唯一通讯作者 ）

(4) Zhijie Yan; Pengfei Li; Zheng Fu; Shaocong Xu; Yongliang Shi; Xiaoxue Chen; Yuhang Zheng; Hang Li; Tianyu Liu; Chuxuan Li; Nairui Luo; Xu Gao; Yilun Chen; Zuoxu Wang; Yifeng Shi; Pengfei

Huang; Zhengxiao Han; Jirui Yuan; Jiangtao Gong; Guyue Zhou; Hang Zhao; **Hao Zhao** ; INT2: Interactive Trajectory Prediction at Intersections, *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, Paris, 2023-10-2至2023-10-6 （**会议论文**） （ 本人标注：唯一通讯作者 ）

(5) Xin Wu; **Hao Zhao**; Shunkai Li; Yingdian Cao; Hongbin Zha ; SC-wLS Towards Interpretable Feed-forward Camera Re-localization, *2022 European Conference on Computer Vision (ECCV)*, Tel Aviv, 2022-10-23至2022-10-27 （**会议论文**） （ 本人标注：共同第一作者 ）

二、论著之外的代表性研究成果和学术奖励：

(1) Anbang Yao; **Hao Zhao**; Ming Lu; Yiwen Guo; Yurong Chen ; Methods and apparatus for discriminative semantic transfer and physics-inspired optimization of features in deep learning, 2023-6-6, 美国, 16609732 （**专利**）

NSFC 2024

杨园 （ BRID：08625.00.32602 ） 简历 2024版

华南师范大学， 体育科学学院， 研究员

教育经历：

(1) 2017-09 至 2020-06，武汉体育学院，运动人体科学，博士

(2) 2013-09 至 2016-06，湖北中医药大学，中医临床基础，硕士

(3) 2008-09 至 2013-06，湖北中医药大学，中医学，学士

博士后工作经历：

(1) 2020-07 至 2022-09，广州中医药大学第二附属医院

科研与学术工作经历（博士后工作经历除外）：

(1) 2023-03 至 今，华南师范大学，体育科学学院，研究员

(2) 2016-07 至 2017-09，武汉科技大学城市学院，医学部，助理实验师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

(1) 国家自然科学基金委员会，青年科学基金项目，82205147，基于联合组学技术探讨补肾活血祛湿中药介导“TRPs-脂代谢-炎症”信号轴治疗湿邪所致KOA的机制研究，2023-01-01 至 2025-12-31，30万元，在研，主持

(2) 国家自然科学基金委员会，面上项目，81970261，适度运动调节脂肪组织的巨噬细胞外泌体及其保护糖尿病血管功能的作用机制研究，2020-01-01 至 2023-12-31，55万元，资助期满，参与

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

(1) 广东省中医药局，科研项目，20225016，基于“湿邪”诱导OA软骨细胞铁死亡探讨川芎嗪保护关节软骨的作用机制，2022-01 至 2024-12，1万元，在研，参与

(2) 广东省自然科学基金，面上项目，2022A1515010385，补肾活血中药上调GPX4抑制脂代谢异常诱导的软骨细胞铁死亡的机制研究，2022-01 至 2024-12，10万元，在研，参与

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

(1) **Yuan Yang**; Yanping Zhou ; Shashen-Maidong Decoction-Mediated IFN-ɣ and IL-4 on the Regulation of Th1/Th2 Imbalance in RP Rats, *BioMed Research International*, 2019.夏季, Volume2019: 1-7 （**期刊论文**） （ 本人标注：唯一第一作者 ）

(2) **Yuan Yang**; Jia-Hui Li; Nan-Jun Xu; Wei-Yi Yang; Jun LIU ; Meta-Analysis of Elderly Lower Body Strength Different Effects of Tai Chi Exercise on the Knee Joint-Related Muscle Groups, *Evidence-Based Complementary and Alternative Medicine*, 2021.秋季, Volume 2021 （**期刊论文**） （

本人标注：共同第一作者 ）

(3) **杨园**；叶啟发；杨翼 ；运动调节衰老的表观遗传机制研究进展，*中国运动医学杂志*，2019.夏季，38(8)：712-716 （**期刊论文**） （ 本人标注：唯一第一作者 ）

(4) **Yuan Yang**；Nan-Jun Xu；Jia-Hui Li；Ling-Feng Zeng；Gui-Hong Liang；Feng Zhang；Ming-Hui Luo；Jian-Ke Pan；He-Tao H；Jin-Long Zhao；Xiao Xiao；Chunlian Ma；Hua Liu；Yi Yang；Wei-Yi Yang；Jun Liu ；Exercise or Dietotherapy Is Not Better than Returning to a Regular Diet to Rebuild Lipid Homeostasis of Rats，*BioMed Research International*，2021.秋季，2021(2021) （**期刊论文**） （ 本人标注：共同第一作者 ）

(5) Wenbin He；Ting Liu；Yongjie Han；Wuyi Ming；Jinguang Du；Yinxia Liu；**Yuan Yang**；Leijie Wang；Zhiwen Jiang；Yongqiang Wang；Jie Yuan；Chen Cao ；A review: The detection of cancer cells in histopathology based on machine vision，*Computers in Biology and Medicine*，2022，146：105636-105636 （**期刊论文**） （ 本人标注：共同通讯作者 ）

二、论著之外的代表性研究成果和学术奖励：

(1) 中国标准，杨伟毅；刘 军；黄和涛；潘建科；罗明辉；韩燕鸿；马元琛；王广积；王武炼；王培民；韦兴德；方 锐；朱立国；向 明；刘文刚；刘国彬；刘建平；刘爱峰；刘培来；闫 辉；李 刚；李 想；李义凯；**杨 园**；吴 淮；何剑颖；张 民；陈 锋；陈广祥；陈红云；陈定家；陈德生；林方政；林定坤；欧爱华；周明旺；郑小飞；赵 第；赵立连；赵金龙；洪坤豪；袁普卫；徐南俊；唐 新；黄永明；曹厚然；盛璞义；梁桂洪；曾令烽；赖胤桦；詹红生；魏 力；魏 戍 ；肩袖损伤中西医结合诊疗指南（2023年版），临床指南，中华中医药学会，2024-1-20 （**标准**）

(2) 明五一；谢卓斌；张亚琳；曹晨；**杨园**；马军；徐颖杰；何文斌；李晓科；都金光；刘琨；段留洋 ；一种磁场调控超音速等离子体热喷涂装置，2024-2-02，中国，ZL 2022 1 0195987.1 （**专利**）

NSFC 2024

王广进 （ BRID：03288.00.62639 ） 简历 2024版

华南师范大学， 体育科学学院， 副教授

教育经历：

（1）2003-07 至 2006-07，华南师范大学，体育人文社会学，博士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

（1）2009-01 至 今，华南师范大学，体育科学学院，副教授

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

无

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

（1）**王广进** ；文化人类学视野中的游戏、体育与民族传统体育，*体育与科学*，2010，31(182)：33-36 （**期刊论文**） （ 本人标注：唯一第一作者 ）

（2）**胡小明 王广进** ；体育休闲概论，高等教育出版社，370千字，2016 （**学术专著**）

二、论著之外的代表性研究成果和学术奖励：

（1）**王广进** ；智能体测存证安全监控平台，9624523，原始取得，全部权利，2022-3-1 （**软件著作权**）

（2）**王广进** ；AI体适能测评自动配置系统，9624524，原始取得，全部权利，2022-3-1 （**软件著作权**）

（3）**王广进** ；体测辅助分析系统V1.0，9408223，原始取得，全部权利，2022-3-1 （**软件著作权**）

（4）**邓星华 杨晓生 王广进**(1/1)；广东省一流本科课程：体育概论，广东省教育厅，*其他*，其他，2022(**邓星华 杨晓生 王广进**) （**科研奖励**）

NSFC 2024

附件信息

序号	附件名称	备注	附件类型
1	代表作1论文（TMM）		代表性论著
2	代表作2论文（TMM）		代表性论著
3	代表作3论文（CVPR）		代表性论著
4	代表作4论文（ACM MM）		代表性论著
5	代表作5论文（ACM MM）		代表性论著
6	学术交流活动合集		其他

NSFC 2024

项目名称： 面向主动健康的高性能人体运动感知与理解技术

资助类型： 面上项目

申请代码： F0215.计算机与其他领域交叉

国家自然科学基金项目申请人和参与者承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，本人**在此郑重承诺：**严格遵守《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求；申请材料信息真实准确，不含任何涉密信息或敏感信息，不含任何违反法律法规或违反科研伦理规范的内容；在国家自然科学基金项目申请、评审和执行全过程中，恪守职业规范和科学道德，遵守评审规则和工作纪律，杜绝以下行为：

（一）抄袭、剽窃他人申请书、论文等科研成果或者伪造、篡改研究数据、研究结论；

（二）购买、代写申请书；购买、代写、代投论文，虚构同行评议专家及评议意见；购买实验数据；

（三）违反成果发表规范、署名规范、引用规范，擅自标注或虚假标注获得科技计划等资助；

（四）在项目申请书中以高指标通过评审，在项目计划书中故意篡改降低相应指标；

（五）以任何形式探听或散布尚未公布的评审专家名单及其他评审过程中的保密信息；

（六）本人或委托他人通过各种方式和途径联系有关专家进行请托、游说、“打招呼”，违规到评审会议驻地窥探、游说、询问等干扰评审或可能影响评审公正性的行为；

（七）向工作人员、评审专家等提供任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包，或提供宴请、旅游、娱乐健身等任何可能影响评审公正性的活动；

（八）违反财经纪律和相关管理规定的行为；

（九）其他弄虚作假行为。

如违背上述承诺，本人愿接受国家自然科学基金委员会和相关部门做出的各项处理决定，包括但不限于撤销科学基金资助项目，追回项目资助经费，向社会通报违规情况，取消一定期限国家自然科学基金项目申请资格，记入科研诚信严重失信行为数据库以及接受相应的党纪政务处分等。

申请人签字：

编号	参与者姓名 / 工作单位名称（应与加盖公章一致）/ 证件号码	签字
1	**赵昊** / 清华大学 / 3**********5	
2	**杨园** / 华南师范大学 / 4**********3	
3	**王广进** / 华南师范大学 / 4**********7	
4		
5		
6		
7		
8		
9		

项目名称： 面向主动健康的高性能人体运动感知与理解技术
资助类型： 面上项目
申请代码： F0215.计算机与其他领域交叉

国家自然科学基金项目申请单位承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，**本单位郑重承诺：**申请材料中不存在违背《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求的情况；申请材料符合《中华人民共和国保守国家秘密法》和《科学技术保密规定》等有关法律法规和规章制度要求，不含任何涉密信息或敏感信息；申请材料不含任何违反法律法规或违反科研伦理规范的内容；申请人符合相应项目的申请资格；依托单位、合作研究单位、申请人及主要参与者不在限制申报、承担或参与财政性资金支持的科技活动的期限内；在项目申请和评审活动全过程中，遵守有关评审规则和工作纪律，杜绝以下行为：

（一）以任何形式探听或公布未公开的项目评审信息、评审专家信息及其他评审过程中的保密信息，干扰评审专家的评审工作；

（二）组织或协助申请人/参与者向工作人员、评审专家等给予任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包等；宴请工作人员、评审专家，或组织任何可能影响科学基金评审公正性的活动；

（三）支持、放任或对申请人/参与者抄袭、剽窃、重复申报、提供虚假信息（含身份和学术信息）等不当手段申报国家自然科学基金项目疏于管理；

（四）支持或协助申请人/参与者采取“打招呼”“围会”等方式影响科学基金项目评审；

（五）其他违反财经纪律和相关管理规定的行为。

如违背上述承诺，本单位愿接受自然科学基金委和相关部门做出的各项处理决定，包括但不限于停拨或核减经费、追回项目已拨经费、取消本单位一定期限国家自然科学基金项目申请资格、记入科研诚信严重失信行为数据库以及主要责任人接受相应党纪政务处分等。

依托单位公章:
日期： 年 月 日

合作研究单位公章:
日期： 年 月 日

合作研究单位公章:
日期： 年 月 日